UNIJORGE

TRABALHO DE CONCLUSÃO DE CURSO

CIÊNCIA DA COMPUTAÇÃO

BRAINSNIFFER

Uma CNN compacta e causal para estimar a referência BIS a partir de EEG frontal

2026

TRABALHO DE CONCLUSÃO DE CURSO · CIÊNCIA DA COMPUTAÇÃO

BRAINSNIFFER

Uma CNN compacta e causal para estimar a referência BIS a partir de EEG frontal

BRUNO ROCHA GUIMARÃES

ORIENTADOR(A): IGOR GONZALEZ PIMENTA

Centro Universitário Jorge Amado · Salvador, BA

SUMÁRIO

01 Problema e perguntas de pesquisa

02 Como o EEG funciona

03 EEG na anestesia e o índice BIS

04 Dados e pré-processamento

05 A rede convolucional

06 Resultados

07 Conclusão e limitações

08 Referências (anexo)

01 · PROBLEMA

POR QUE ESTIMAR A PROFUNDIDADE ANESTÉSICA?

Dose na medida

Na anestesia geral o paciente precisa estar hipnotizado o suficiente, sem excesso de fármaco.

O BIS é fechado

O índice mais usado à beira do leito é proprietário: a regra que o calcula não é publicada.

Vazamento silencioso

Janelas vizinhas da mesma cirurgia são quase iguais; dividir ao acaso mede memória, não generalização.

Lacuna: um estimador compacto e causal, avaliado com partição por caso e em mais de uma fonte de dados.

Fonte: Johansen; Sebel (2000); Avidan et al. (2008; 2011); Saeb et al. (2017).

01 · PERGUNTAS

TRÊS PERGUNTAS DE PESQUISA

i Uma CNN 1-D compacta, sob validação agrupada, aproxima o rótulo BIS na faixa de variabilidade do próprio monitor?

ii É competitiva com um modelo publicado ~7× maior, mantendo uma cadeia exportável para uso ao vivo?

iii O desempenho se mantém ao trocar a fonte dos dados, do Figshare para o VitalDB?

Métricas primárias definidas de antemão: MAE por janela (erro em pontos BIS) e PK (ordenação).

Fonte: Smith et al. (1996); Collins et al. (2024).

02 · COMO O EEG FUNCIONA

COMO O EEG É GERADO E MEDIDO

01

Neurônios piramidais

Células do córtex alinhadas perpendicularmente à superfície.

02

Atividade sincronizada

Potenciais pós-sinápticos de milhões de neurônios se somam.

03

Volume condutor

O campo atravessa meninges, crânio e couro cabeludo e chega atenuado.

04

Eletrodos e conversor

A diferença de potencial é amplificada, filtrada e digitalizada.

10–100 µV

Amplitude típica no couro cabeludo
Fonte: Purdon et al. (2015); Craik et al. (2019).

milissegundos

Resolução temporal do sinal

1 canal · 128 Hz

EEG frontal usado neste trabalho

03 · EEG NA ANESTESIA

O QUE MUDA NO EEG SOB ANESTESIA

Faixa BIS	Estado	Padrão no EEG
80–100	Acordado	Ritmos rápidos (beta, gama) e de baixa amplitude.
60–80	Sedação	Aumento paradoxal de beta e início da lentificação.
40–60	Anestesia geral	Alfa frontal (~10 Hz) somado a ondas lentas de alta amplitude.
0–40	Profunda	Surto-supressão: rajadas entre trechos quase isoelétricos.

Faixas usadas só para comunicação (acurácia e macro-F1 em 4 classes), não como limiares clínicos validados.

Fonte: Purdon et al. (2015); Shi et al. (2023).

03 · O ÍNDICE BIS

BIS: A REFERÊNCIA À BEIRA DO LEITO

0 – 40

Hipnose profunda → EEG isoelétrico (0)

40 – 60

Anestesia geral

60 – 80

Sedação

80 – 100

Acordado (100)

Proprietário

Combina atributos temporais, espectrais e bispectrais por regra não publicada (Johansen; Sebel, 2000).

Sensível a confundidores

EMG, bloqueio neuromuscular e cetamina alteram a leitura (Schuller et al., 2015; Hans et al., 2005).

Suavizado e com atraso

O índice chega com atraso de cálculo (Pilge et al., 2006): motiva a suavização causal.

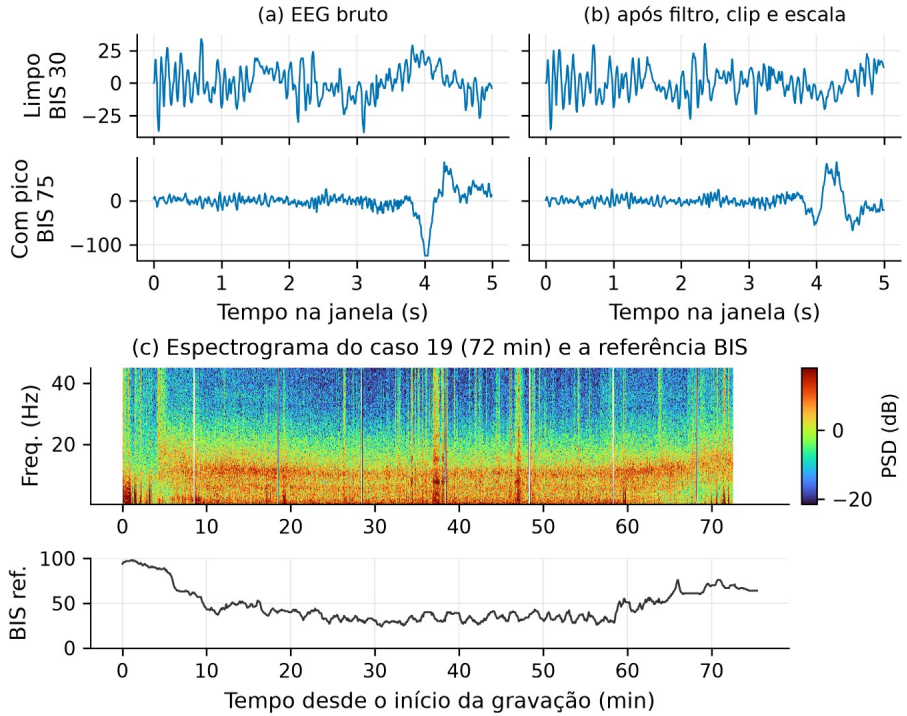
Um rótulo, não a verdade

Estimamos um rótulo de referência BIS — não consciência nem efeito do fármaco.

Fonte: Johansen; Sebel (2000); Myles et al. (2004); Hans et al. (2005); Schuller et al. (2015); Pilge et al. (2006); Connor (2022); Dahaba et al. (2010); Shiraishi et al. (2004).

03 · CASO REAL

O EEG REAL DE UM CASO DO CORPUS



Fonte: Ma (2017), caso 19 do corpus; figura produzida neste trabalho.

(a, b) Pré-processamento

Trecho limpo (BIS 30) quase não muda; um pico de 125 µV (BIS 75) é contido para 88 µV.

(c) Espectro × BIS

Quando o BIS sobe, a potência relativa em teta cai e a de beta e gama sobe — a relação que a rede explora.

Faixas brancas

Quedas de eletrodo a cada ~10 min, rejeitadas pelos gates de qualidade.

04 · DADOS

DUAS FONTES PÚBLICAS, PARTIÇÃO POR CASO

Figshare — EEG and BIS raw data

Ma (2017) · CC BY 4.0

24 casos anônimos de EEG frontal + BIS

Sensor BIS Quatro, BIS a cada 5 s

Sem identificador de participante

VitalDB

Lee et al. (2022) · CC BY-NC-SA 4.0

Milhares de cirurgias (Seul), sinais perioperatórios

Monitor BIS Vista, BIS a cada 1 s

Agrupado por participante (reoperações juntas)

59

arquivos no corpus

33

casos elegíveis (23 Figshare + 10 VitalDB)

55.471

janelas de 5 s

Regra: nenhum caso cruza treino, validação e teste.

Fonte: Ma (2017); Lee et al. (2022); VitalDB.

04 · PRÉ-PROCESSAMENTO

DO SINAL BRUTO À JANELA DE ENTRADA

1
EEG frontal
1 canal, em µV

2
Gates
Rejeita trechos ruins

3
Filtro causal
0,5–45 Hz + notch 50 Hz

4
Amplitude
Clip ±100 µV, ÷ 50 µV

5
Janela
5 s = 640 amostras a 128 Hz

Gates de qualidade (heurísticos)

≥ 90% de EEG finito; lacuna máxima de 2 s

Qualidade global ≥ 0,35

≥ 80% de BIS válido no caso

Alvo e causalidade

Alvo: BIS no instante t + offset (0 s)

Filtro usa só passado e presente, com estado por caso

Replay: buffer de 5 s, atualização a cada 1 s

Fonte: Nsugbe; Connelly (2022); Purdon et al. (2015).

05 · A REDE

UMA CNN 1-D COMPACTA

Entrada

5 s de EEG

1 × 640

Convolução

4 blocos: 1→32→64→128→128 canais

Kernels 7, 7, 5, 5 · BN · GELU · pooling nos 3 primeiros (640 → 80)

Cabeça

Média global

128 → 64 → 1 · dropout 0,2

Saída

Sigmoide × 100

BIS 0–100 por janela

0,15 M

parâmetros — roda em CPU

4

blocos convolucionais com batch norm + GELU

1

número por janela: o BIS estimado

Fonte: Kiranyaz et al. (2021); Craik et al. (2019).

05 · TREINO

TREINO E CHECKPOINTS

Treino

Smooth L1 · 10 épocas · batch 128

lr 10^{-3} · weight decay 10^{-4} · seed 42 · CPU

Dois checkpoints

Ativo: só Figshare, 13 / 5 / 5 casos (treino / validação / teste).

Misto: Figshare + parte do VitalDB; ajuste com 12 + 4 casos.

Pós-processamento (EWMA)

Média móvel exponencial causal, por caso, sobre predições congeladas — sem retreino.

$s[t] = \alpha \cdot y[t] + (1 - \alpha) \cdot s[t-1]$, com $\alpha = 2 / (span + 1)$

Fonte: Sukriti et al. (2026).

06 · RESULTADOS — HOLDOUT FIGSHARE

O ERRO FICA ABAIXO DA ESCALA DE LEITURA

7,03
MAE da CNN (pontos BIS)

0,773
PK (0,5 = acaso; 1 = ordem perfeita)

0,784
Pearson

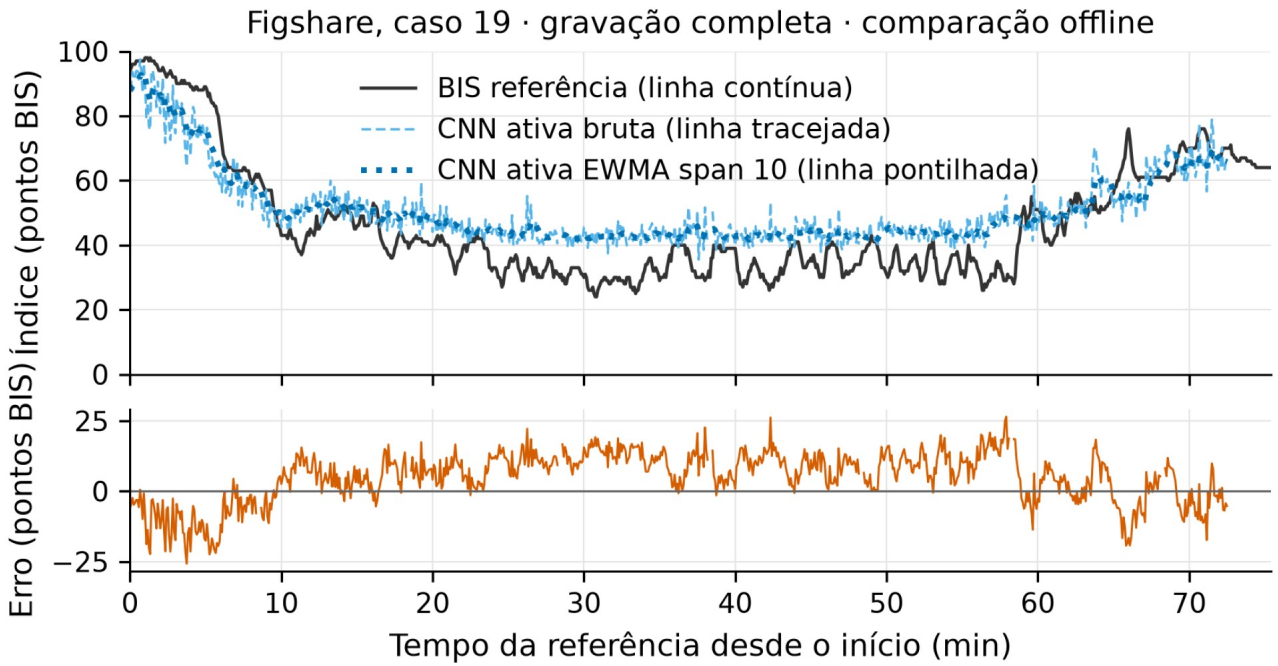
Abaixo da escala de leitura de 10 pontos · 5 casos, 5.523 janelas · leitura exploratória

RMSE 11,08 · acurácia por faixa 0,585 · macro-F1 0,548

Fonte: Smith et al. (1996); resultados deste trabalho.

06 · RESULTADOS — TRAJETÓRIA

TRAJETÓRIA AO LONGO DE UMA CIRURGIA



850
janelas aceitas (caso 19)

8,72
MAE no caso

+4,79
viés: superestima

0,910
Pearson intra-caso

Acompanha a queda inicial e a elevação final, mas superestima o patamar intermediário.

Fonte: dados deste trabalho (caso 19); Smith et al. (1996).

06 · RESULTADOS — BENCHMARKS

COMPARAÇÃO NOS DOIS BENCHMARKS

Benchmark	Modelo (fontes vistas)	MAE (IC 95%)	Pearson	PK
Figshare	Ativo (Figshare)	7,03 (6,38–8,24)	0,784	0,773
Figshare	Misto (Figshare + VitalDB)	6,69 (5,65–8,53)	0,818	0,774
VitalDB	Ativo (Figshare)	12,43 (11,05–14,45)	0,024	0,515
VitalDB	Misto (Figshare + VitalDB)	8,60 (7,57–9,95)	0,688	0,672

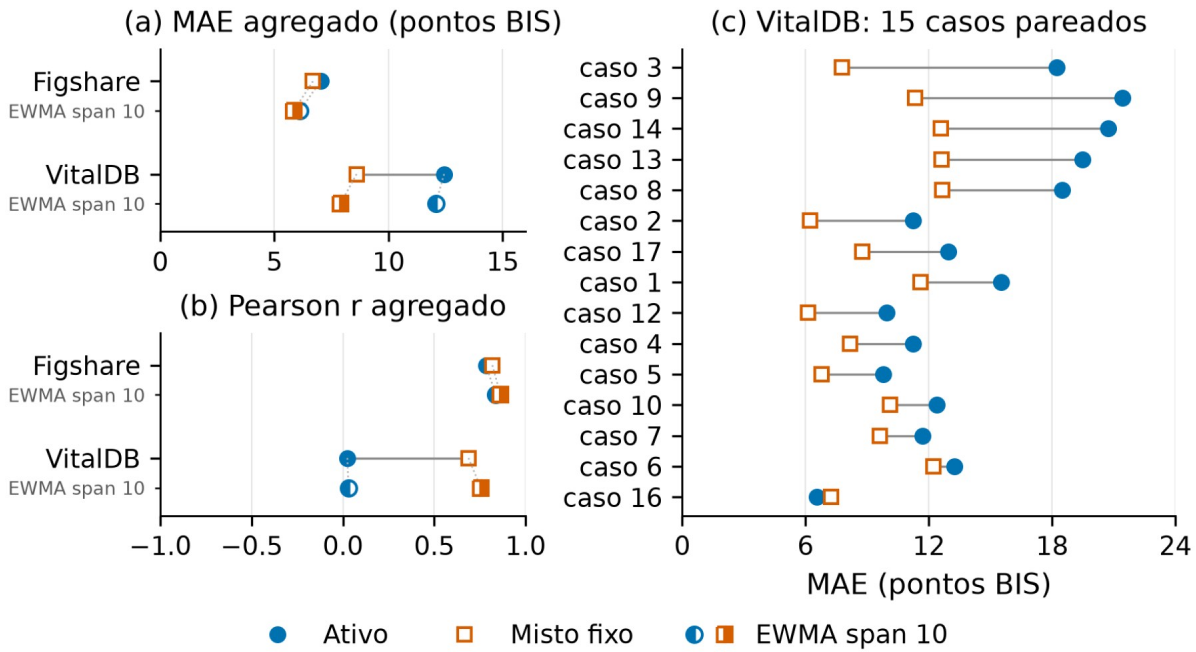
3 de 4 MAE abaixo de 10 pontos: escala de leitura adotada a partir de estudos de comparação de montagens do BIS (Harada et al., 2021), não variabilidade geral do monitor nem critério clínico.

Misto vs. ativo no Figshare: ΔMAE 0,34 (IC −0,28 a 0,81) — diferença não sustentada.

Fonte: Harada et al. (2021); Field; Welsh (2007); resultados deste trabalho.

06 · RESULTADOS — VITALDB

O DESEMPENHO NÃO TRANSPORTA ENTRE FONTES



12,43

MAE do ativo no VitalDB (era 7,03)

0,515

PK: indistinguível do acaso

14 / 15

casos melhoram com o misto — que já viu a fonte

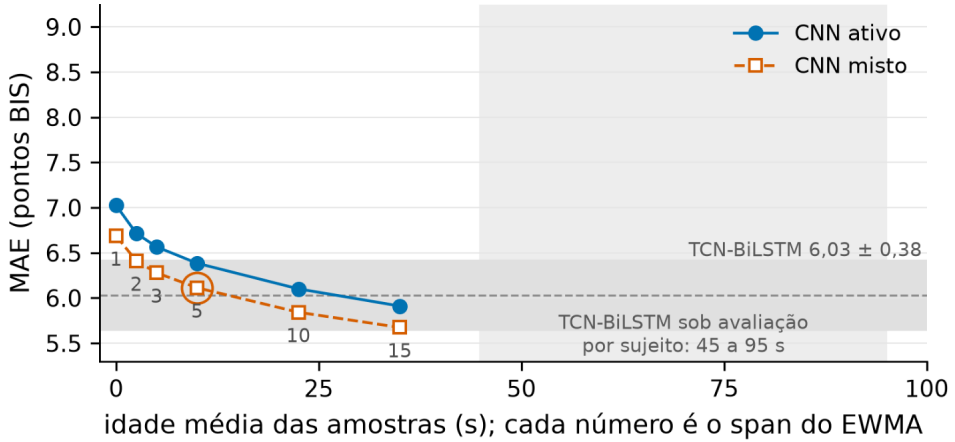
Fonte: Lee et al. (2022); Saeb et al. (2017); resultados deste trabalho.

06 · RESULTADOS — IMPLANTABILIDADE

ORDEM DE GRANDEZA DE UM MODELO 7× MAIOR

Cada ponto é um span do EWMA. Comparação de ordem de grandeza, não ranking: protocolos, seleção da suavização e avaliação diferem; o span 5 foi escolhido pós-hoc.

Métrica	BrainSniffer	TCN-BiLSTM
MAE Figshare	6,11 (span 5)	6,03 ± 0,38
Memória	10 s	45–95 s
Parâmetros	0,15 M	1,07 M
Causal ao vivo	Sim	Não



TCN-BiLSTM — BiLSTM bidirecional e filtro de fase zero. Com span 10, o misto chega a 5,84 (22,5 s).

Fonte: Sukriti et al. (2026); Park et al. (2020); Kiranyaz et al. (2021).

07 · CONCLUSÃO

O QUE ESTE TRABALHO ENTREGA

i

Aproxima o rótulo BIS

MAE 7,03, abaixo da escala de leitura de 10 pontos, com validação por caso, e ordena a cirurgia como a referência (PK 0,773).

ii

Competitiva e implantável

Com EWMA causal, 6,11 em 10 s — na faixa de um modelo 7× maior, em CPU e sem acesso ao futuro.

iii

Não transporta entre fontes

No VitalDB, PK 0,515. A prioridade passa de “modelo maior” para “dados da fonte”.

> **Contribuição:** uma cadeia compacta, causal e auditável (hashes, partições, replay) para testar hipóteses — não um sistema clínico.

Fonte: resultados deste trabalho; Sukriti et al. (2026).

07 · LIMITAÇÕES

LIMITAÇÕES E PRÓXIMOS PASSOS

Limitações

Retrospectivo e exploratório: 5 casos no holdout Figshare

Benchmark VitalDB reusado após exposição ao domínio

Imputação offline pode usar amostras futuras

Alvo é o BIS: sensível a EMG, cetamina e atrasos

EWMA pós-hoc, com span escolhido após os resultados

Próximos passos

Coorte travada de outra fonte, partição definida antes

Métricas primárias pré-registradas (MAE e PK)

Treinar com mais fontes, auditando por hashes

Medir sensibilidade a EMG e ao notch por centro

Avaliação prospectiva da cadeia ao vivo

Importante: o BrainSniffer não mede consciência, não prescreve dose e não deve acionar alarme ou conduta clínica.

Fonte: Collins et al. (2024); Archer et al. (2021); Saeb et al. (2017); Garbe et al. (2026).

UNIJORGE

BRAINSNIFFER · TCC

OBRIGADO

Perguntas?

Bruno Rocha Guimarães

ANEXO · REFERÊNCIAS (1/3)

REFERÊNCIAS

ARCHER, L. et al. Minimum sample size for external validation of a clinical prediction model with a continuous outcome. *Statistics in Medicine*, v. 40, n. 1, p. 133–146, 2021.

AVIDAN, M. S. et al. Anesthesia awareness and the bispectral index. *New England Journal of Medicine*, v. 358, p. 1097–1108, 2008.

AVIDAN, M. S. et al. Prevention of intraoperative awareness in a high-risk surgical population. *New England Journal of Medicine*, v. 365, p. 591–600, 2011.

COLLINS, G. S. et al. TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, v. 385, e078378, 2024.

CONNOR, C. W. Open reimplementation of the BIS algorithms for depth of anesthesia. *Anesthesia & Analgesia*, v. 135, n. 4, p. 855–864, 2022.

CRAIK, A.; HE, Y.; CONTRERAS-VIDAL, J. L. Deep learning for electroencephalogram (EEG) classification tasks: a review. *Journal of Neural Engineering*, v. 16, n. 3, 031001, 2019.

DAHABA, A. A. et al. BIS-vista occipital montage in patients undergoing neurosurgical procedures during propofol-remifentanil anesthesia. *Anesthesiology*, v. 112, n. 3, p. 645–651, 2010.

FIELD, C. A.; WELSH, A. H. Bootstrapping clustered data. *Journal of the Royal Statistical Society: Series B*, v. 69, n. 3, p. 369–390, 2007.

GARBE, J. et al. *DOSE-I: a multimodal biosignal dataset of procedural sedation for endoscopy*. Zenodo, 2026. Conjunto de dados.

HANS, P. et al. Comparative effects of ketamine on Bispectral Index and spectral entropy of the electroencephalogram under sevoflurane anaesthesia. *British Journal of Anaesthesia*, v. 94, n. 3, p. 336–340, 2005.

ANEXO · REFERÊNCIAS (2/3)

REFERÊNCIAS

HARADA, H. et al. Accuracy of BIS monitoring using a novel interface device connecting conventional needle-electrodes and BIS sensors during frontal neurosurgical procedures. *PLoS ONE*, v. 16, n. 10, e0258647, 2021.

JOHANSEN, J. W.; SEBEL, P. S. Development and clinical application of electroencephalographic bispectrum monitoring. *Anesthesiology*, v. 93, n. 5, p. 1336–1344, 2000.

KIRANYAZ, S. et al. 1D convolutional neural networks and applications: a survey. *Mechanical Systems and Signal Processing*, v. 151, 107398, 2021.

LEE, H.-C. et al. VitalDB, a high-fidelity multi-parameter vital signs database in surgical patients. *Scientific Data*, v. 9, 279, 2022.

LIU, Q. et al. Sample entropy analysis for the estimating depth of anaesthesia through human EEG signal at different levels of unconsciousness during surgeries. *PeerJ*, v. 6, e4817, 2018.

MA, L. *EEG and BIS raw data*. Figshare, 2017. Conjunto de dados, v1. DOI: 10.6084/m9.figshare.5589841.v1.

MYLES, P. S. et al. Bispectral index monitoring to prevent awareness during anaesthesia: the B-Aware randomised controlled trial. *The Lancet*, v. 363, p. 1757–1763, 2004.

NSUGBE, E.; CONNELLY, S. Multiscale depth of anaesthesia prediction for surgery using frontal cortex electroencephalography. *Healthcare Technology Letters*, v. 9, p. 43–53, 2022.

PARK, Y. et al. A real-time depth of anesthesia monitoring system based on deep neural network with large EDO tolerant EEG analog front-end. *IEEE Transactions on Biomedical Circuits and Systems*, v. 14, p. 825–837, 2020.

ANEXO · REFERÊNCIAS (3/3)

REFERÊNCIAS

PILGE, S. et al. Time delay of index calculation: analysis of cerebral state, bispectral, and Narcotrend indices. *Anesthesiology*, v. 104, n. 3, p. 488–494, 2006.

PURDON, P. L. et al. Clinical electroencephalography for anesthesiologists: part I: background and basic signatures. *Anesthesiology*, v. 123, n. 4, p. 937–960, 2015.

SAEB, S. et al. The need to approximate the use-case in clinical machine learning. *GigaScience*, v. 6, 2017.

SCHULLER, P. J. et al. Response of bispectral index to neuromuscular block in awake volunteers. *British Journal of Anaesthesia*, v. 115, supl. 1, p. i95–i103, 2015.

SHI, M. et al. Estimating the depth of anesthesia from EEG signals based on a deep residual shrinkage network. *Sensors*, v. 23, n. 2, 1008, 2023.

SHIRAISHI, T. et al. A comparison of frontal and occipital bispectral index values obtained during neurosurgical procedures. *Anesthesia & Analgesia*, v. 98, n. 6, p. 1773–1775, 2004.

SMITH, W. D.; DUTTON, R. C.; SMITH, N. T. Measuring the performance of anesthetic depth indicators. *Anesthesiology*, v. 84, n. 1, p. 38–51, 1996.

SUKRITI et al. Predicting depth of anaesthesia from single-channel EEG using a deep TCN-BiLSTM-attention model with EWMA. *Scientific Reports*, v. 16, 25470, 2026.

VITALDB. *Open Dataset: overview and track list*. 2026. Disponível em: vitaldb.net/dataset.