TRABALHO DE CONCLUSÃO DE CURSO · CIÊNCIA DA COMPUTAÇÃO

BrainSniffer

Uma CNN compacta e causal para estimar a referência BIS a partir de EEG frontal

Bruno Rocha Guimarães

Orientador(a): [nome do orientador]

Centro Universitário Jorge Amado · Salvador, BA · [data da defesa]



ROTEIRO

Sumário

01 Problema e perguntas de pesquisa

02 Como o EEG funciona

03 EEG na anestesia e o índice BIS

04 Dados e pré-processamento

05 A rede convolucional

06 Resultados

07 Conclusão e limitações

08 Referências

01 · PROBLEMA

Por que estimar a profundidade anestésica?

Dose na medida

Na anestesia geral o paciente precisa estar hipnotizado o suficiente, sem excesso de fármaco.

O BIS é fechado

O índice mais usado à beira do leito é proprietário: a regra que o calcula não é publicada.

Vazamento silencioso

Janelas vizinhas da mesma cirurgia são quase iguais; dividir ao acaso mede memória, não generalização.

Lacuna: um estimador compacto e causal, avaliado com partição por caso e contra um controle espectral, em mais de uma fonte de dados.

Três perguntas de pesquisa

i	Uma CNN 1-D compacta, sob validação agrupada, aproxima o rótulo BIS e supera um baseline espectral?
ii	É competitiva com um modelo publicado ~7× maior, mantendo uma cadeia exportável para uso ao vivo?
iii	O desempenho se mantém ao trocar a fonte dos dados, do Figshare para o VitalDB?

Métricas primárias definidas de antemão: **MAE por janela** (erro em pontos BIS) e **PK** (ordenação).

Como o EEG é gerado e medido

01

Neurônios piramidais

Células do córtex alinhadas perpendicularmente à superfície.

02

Atividade sincronizada

Potenciais pós-sinápticos de milhões de neurônios se somam.

03

Volume condutor

O campo atravessa meninges, crânio e couro cabeludo e chega atenuado.

04

Eletrodos e conversor

A diferença de potencial é amplificada, filtrada e digitalizada.

10–100 µV

Amplitude típica no couro cabeludo

milissegundos

Resolução temporal do sinal

1 canal · 128 Hz

EEG frontal usado neste trabalho

Ritmos do EEG em bandas de frequência

Banda	Faixa	Associação típica
Delta	0,5–4 Hz	Ondas lentas: sono profundo e anestesia profunda
Teta	4–8 Hz	Sonolência e transições de estado
Alfa	8–13 Hz	Vigília relaxada; alfa frontal sob propofol
Beta	13–30 Hz	Vigília ativa e atenção
Gama	30–45 Hz	Atividade rápida; contaminada por EMG na fronte

O baseline espectral resume cada janela nessas 5 bandas (potência absoluta e relativa) + SEF90, entropia espectral, RMS e line length = **14 atributos**.

O que muda no EEG sob anestesia

Mais acordado → Mais profundo

BIS 80–100

Acordado

Ritmos rápidos (beta, gama) e de baixa amplitude.

BIS 60–80

Sedação

Aumento paradoxal de beta e início da lentificação.

BIS 40–60

Anestesia geral

Alfa frontal (~10 Hz) somado a ondas lentas de alta amplitude.

BIS 0–40

Profunda

Surto-supressão: rajadas entre trechos quase isoelétricos.

Faixas usadas só para comunicação (acurácia e macro-F1 em 4 classes), não como limiares clínicos validados.

BIS: a referência à beira do leito



Proprietário

Combina atributos temporais, espectrais e bispectrais por regra não publicada (Johansen; Sebel, 2000).

Sensível a confundidores

EMG, bloqueio neuromuscular e cetamina alteram a leitura (Schuller et al., 2015; Hans et al., 2005).

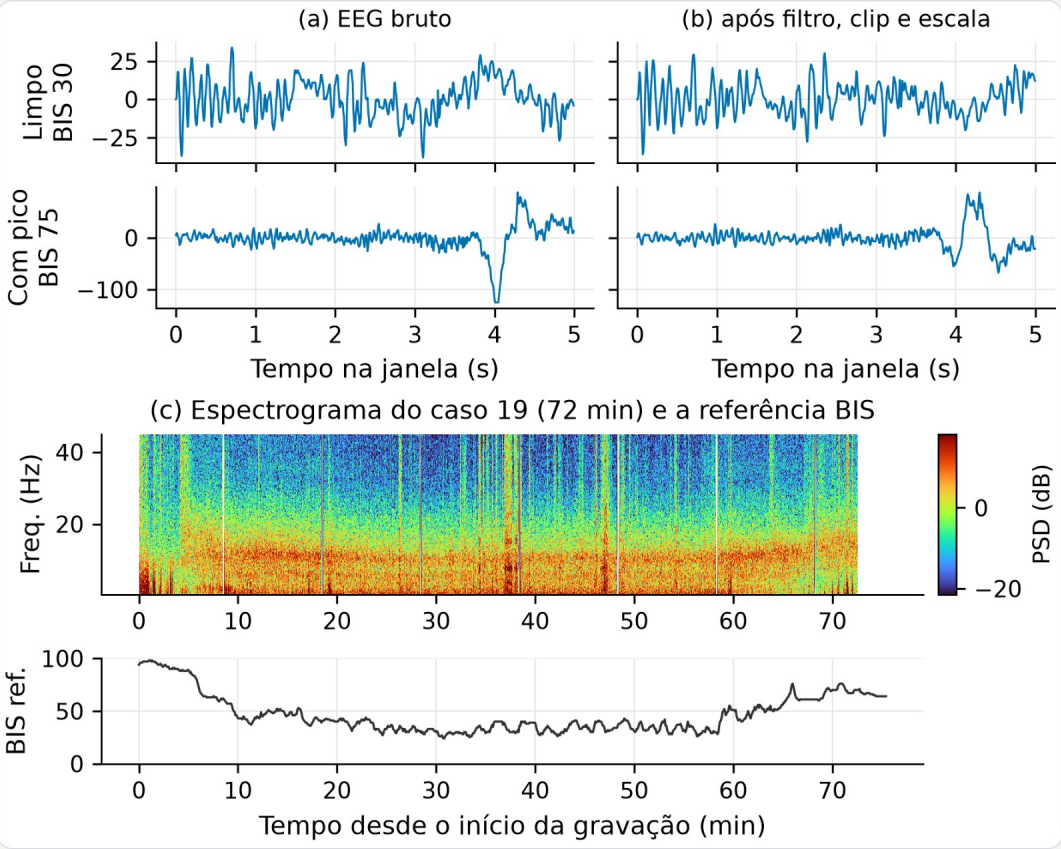
Suavizado e com atraso

O índice chega com atraso de cálculo (Pilge et al., 2006): motiva a suavização causal.

Um rótulo, não a verdade

Estimamos um rótulo de referência BIS — não consciência nem efeito do fármaco.

O EEG real de um caso do corpus



(a, b) Pré-processamento

Trecho limpo (BIS 30) quase não muda; um pico de 125 µV (BIS 75) é contido para 88 µV.

(c) Espectro × BIS

Quando o BIS sobe, a potência relativa em teta cai e a de beta e gama sobe — a relação que a rede explora.

Faixas brancas

Quedas de eletrodo a cada ~10 min, rejeitadas pelos gates de qualidade.

04 · DADOS

Duas fontes públicas, partição por caso

Figshare — EEG and BIS raw data

Ma (2017) · CC BY 4.0

- 24 casos anônimos de EEG frontal + BIS
- Sensor BIS Quatro, BIS a cada 5 s
- Sem identificador de participante

VitalDB

Lee et al. (2022) · CC BY-NC-SA 4.0

- Milhares de cirurgias (Seul), sinais perioperatórios
- Monitor BIS Vista, BIS a cada 1 s
- Agrupado por participante (reoperações juntas)

59

arquivos no corpus

33

casos elegíveis (23 Figshare + 10 VitalDB)

55.471

janelas de 5 s

Regra: nenhum caso cruza treino, validação e teste.

04 · PRÉ-PROCESSAMENTO

Do sinal bruto à janela de entrada

1
EEG frontal
1 canal, em µV

→

2
Gates
Rejeita trechos ruins

→

3
Filtro causal
0,5–45 Hz + notch 50 Hz

→

4
Amplitude
Clip ±100 µV, ÷ 50 µV

→

5
Janela
5 s = 640 amostras a 128 Hz

Gates de qualidade (heurísticos)

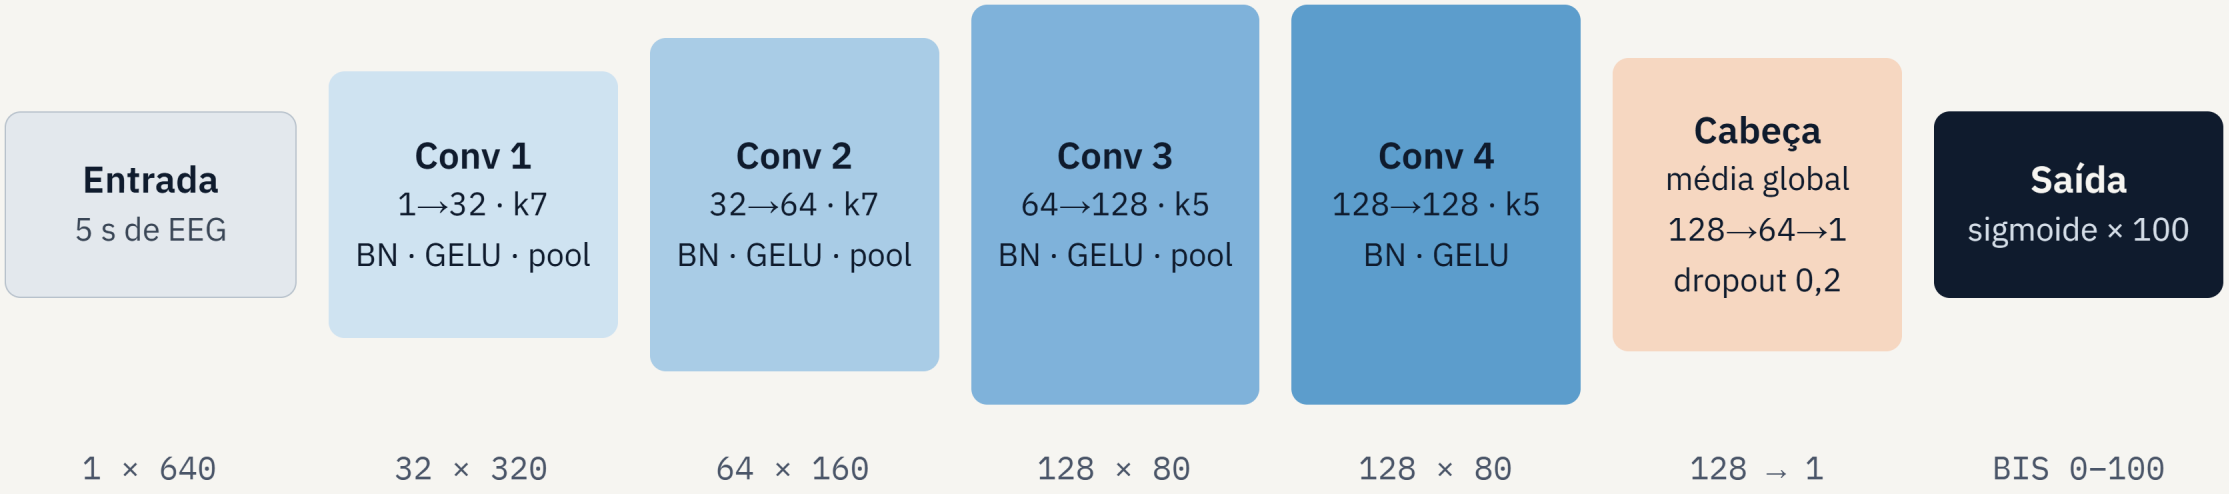
- ≥ 90% de EEG finito; lacuna máxima de 2 s
- Qualidade global ≥ 0,35
- ≥ 80% de BIS válido no caso

Alvo e causalidade

- Alvo: BIS no instante t + offset (0 s)
- Filtro usa só passado e presente, com estado por caso
- Replay: buffer de 5 s, atualização a cada 1 s

05 · A REDE

Uma CNN 1-D compacta



0,15 M

parâmetros — roda em CPU

4 blocos

convolucionais com batch norm + GELU

1 número

por janela: o BIS estimado

Treino, checkpoints e controles

Treino

- Perda Smooth L1
- 10 épocas · batch 128
- lr 10^{-3} · weight decay 10^{-4}
- Seed 42 · CPU

Dois checkpoints

● **Ativo:** só Figshare, 13 / 5 / 5 casos (treino / validação / teste).

□ **Misto:** Figshare + parte do VitalDB; ajuste com 12 + 4 casos.

Controle espectral

Random Forest (100 árvores) sobre os 14 atributos espectrais, nas mesmas janelas de treino e teste.

PÓS-PROCESSAMENTO

Média móvel exponencial causal (EWMA), por caso, sobre predições congeladas — sem retreino.

$$s[t] = \alpha \cdot y[t] + (1 - \alpha) \cdot s[t-1]$$

$$\alpha = 2 / (\text{span} + 1)$$

A CNN supera o controle espectral

7,03

MAE da CNN (pontos BIS)

8,86

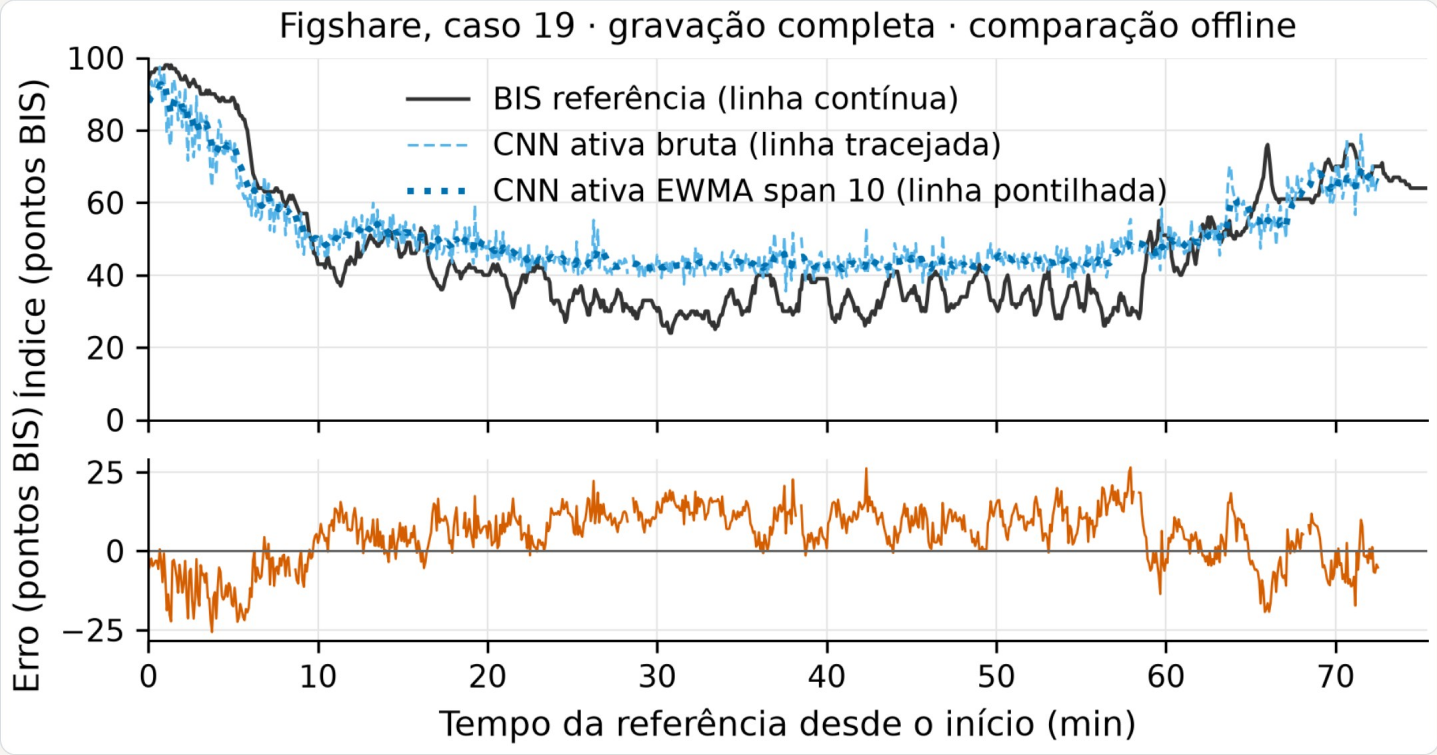
MAE do baseline espectral

0,773

PK da CNN (0,5 = acaso; 1 = ordem perfeita)

ΔMAE pareado **−1,84** (IC 95% −2,37 a −0,66) · 5 casos, 5.523 janelas · leitura exploratória

Trajetória ao longo de uma cirurgia



Acompanha a queda inicial e a elevação final, mas superestima o patamar intermediário.

850

janelas aceitas (caso 19)

8,72

MAE no caso

+4,79

viés: superestima

0,910

Pearson intra-caso

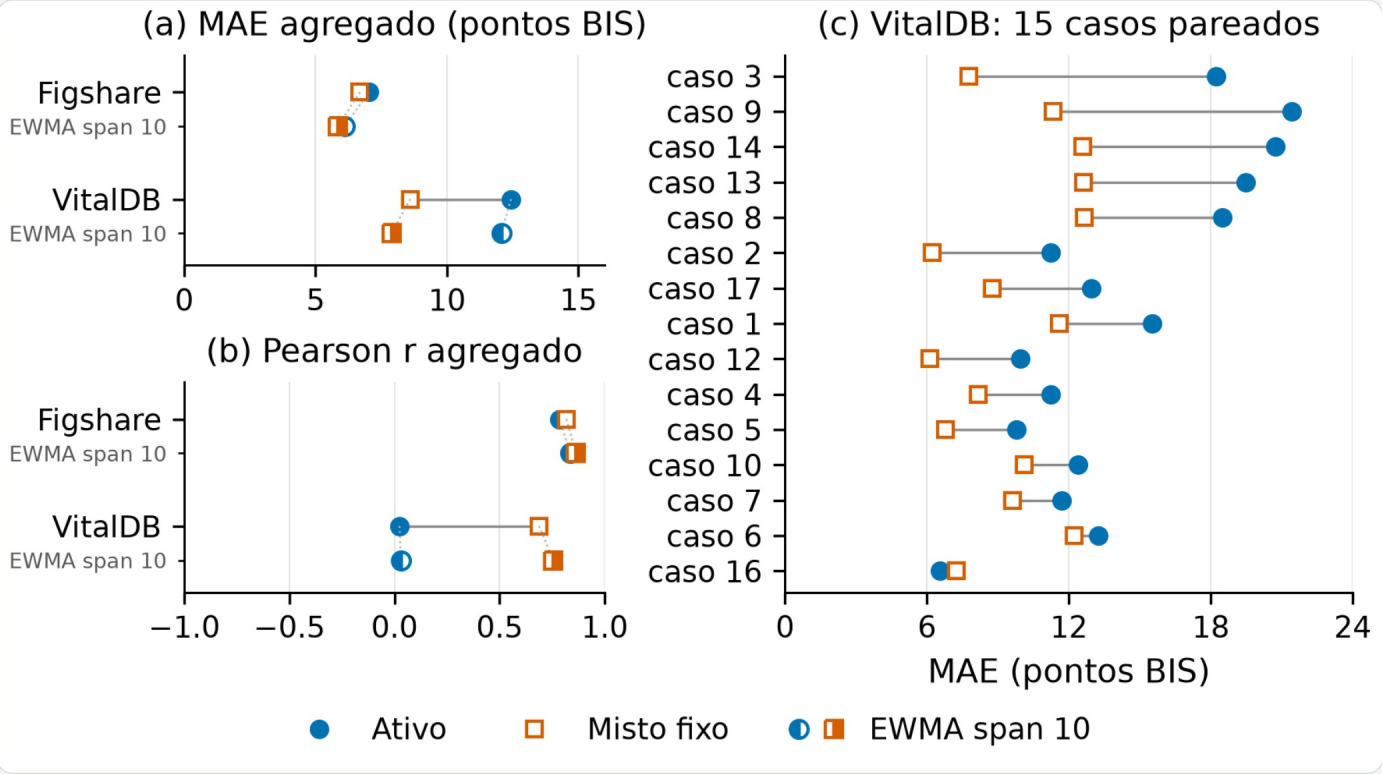
Comparação nos dois benchmarks

Benchmark	Modelo (fontes vistas)	MAE (IC 95%)	Pearson	PK
Figshare	Ativo (Figshare)	7,03 (6,38–8,24)	0,784	0,773
Figshare	Misto (Figshare + VitalDB)	6,69 (5,65–8,53)	0,818	0,774
VitalDB	Ativo (Figshare)	12,43 (11,05–14,45)	0,024	0,515
VitalDB	Misto (Figshare + VitalDB)	8,60 (7,57–9,95)	0,688	0,672
VitalDB	RF espectral (Figshare)	13,62 (11,98–16,01)	−0,036	0,502

3 de 4 MAE abaixo de 10 pontos — a variabilidade entre medições do próprio monitor (Harada et al., 2021). É régua de leitura, não critério clínico.

Misto vs. ativo no Figshare: ΔMAE 0,34 (IC −0,28 a 0,81) — diferença não sustentada.

O desempenho não transporta entre fontes



12,43

MAE do ativo no VitalDB (era 7,03)

0,515

PK: indistinguível do acaso

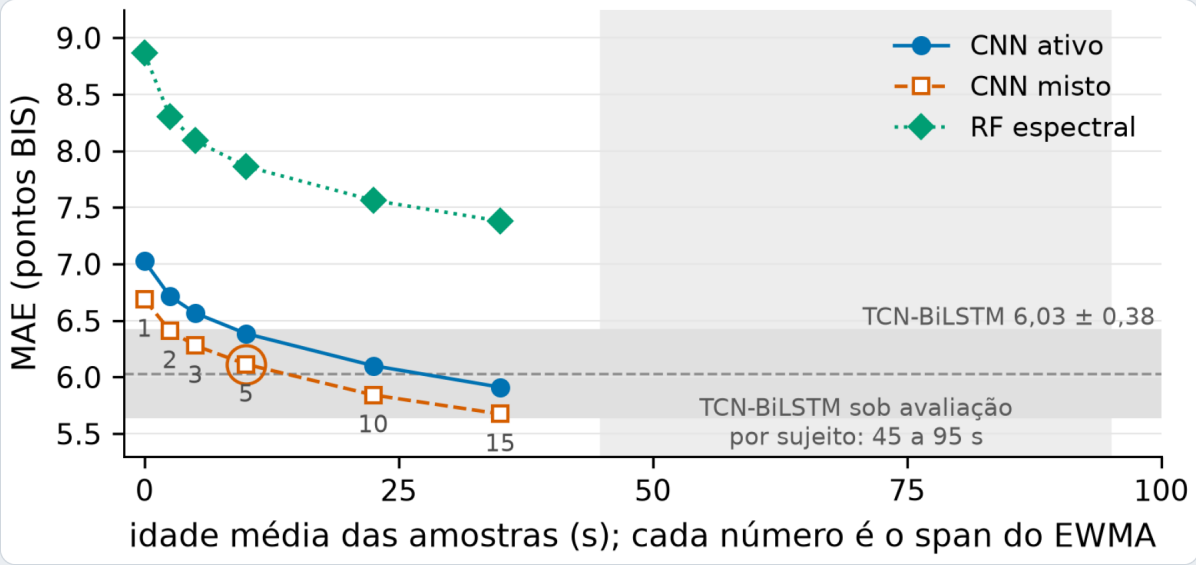
13,62

RF espectral colapsa igual (PK 0,502)

14 / 15

casos melhoram com o misto — que já viu a fonte

Na faixa do estado da arte, 7× menor



	BrainSniffer	TCN-BiLSTM
MAE Figshare	6,11 (span 5)	6,03 ± 0,38
Memória	10 s	45–95 s
Parâmetros	0,15 M	1,07 M
Causal ao vivo	Sim	Não

Cada ponto é um span do EWMA. Comparação de ordem de grandeza, não ranking: os protocolos diferem.

TCN-BiLSTM: Sukriti et al. (2026) — BiLSTM bidirecional e filtro de fase zero. Com span 10, o misto chega a 5,84 (22,5 s).

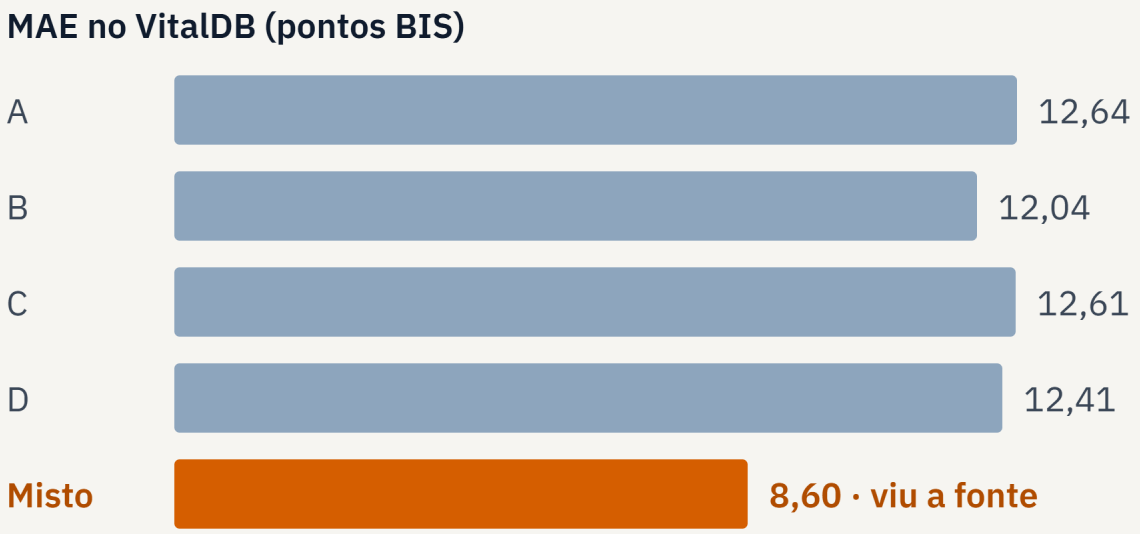
Mudar o treino não resolveu o transporte

A · reprodução
Valida o harness: 7,03 no Figshare

B · winsor ±200 µV
Piora o Figshare (8,19)

C · Huber + treino longo
Único ganho interno (6,63)

D · z-score por sujeito
Sobe Pearson e CCC, não o MAE



O que separa os resultados é a **exposição ao domínio** — não arquitetura, perda ou normalização.

O que este trabalho entrega

i

Supera o controle espectral

MAE 7,03 contra 8,86, com validação por caso, e ordena a cirurgia como a referência (PK 0,773).

ii

Competitiva e implantável

Com EWMA causal, 6,11 em 10 s — na faixa de um modelo 7× maior, em CPU e sem acesso ao futuro.

iii

Não transporta entre fontes

No VitalDB, PK 0,515. A prioridade passa de "modelo maior" para "dados da fonte".

Contribuição: uma cadeia compacta, causal e auditável (hashes, partições, replay) para testar hipóteses — não um sistema clínico.

Limitações e próximos passos

Limitações

- Retrospectivo e exploratório: 5 casos no holdout Figshare
- Benchmark VitalDB reusado após exposição ao domínio
- Imputação offline pode usar amostras futuras
- Alvo é o BIS: sensível a EMG, cetamina e atrasos
- EWMA pós-hoc, com span escolhido após os resultados

Próximos passos

- Coorte travada de outra fonte, partição definida antes
- Métricas primárias pré-registradas (MAE e PK)
- Treinar com mais fontes, auditando por hashes
- Medir sensibilidade a EMG e ao notch por centro
- Avaliação prospectiva da cadeia ao vivo

⚠ O BrainSniffer não mede consciência, não prescreve dose e não deve acionar alarme ou conduta clínica.

Referências

ARCHER, L. et al. Minimum sample size for external validation of a clinical prediction model with a continuous outcome. *Statistics in Medicine*, v. 40, n. 1, p. 133–146, 2021.

AVIDAN, M. S. et al. Anesthesia awareness and the bispectral index. *New England Journal of Medicine*, v. 358, p. 1097–1108, 2008.

AVIDAN, M. S. et al. Prevention of intraoperative awareness in a high-risk surgical population. *New England Journal of Medicine*, v. 365, p. 591–600, 2011.

COLLINS, G. S. et al. TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, v. 385, e078378, 2024.

CONNOR, C. W. Open reimplementation of the BIS algorithms for depth of anesthesia. *Anesthesia & Analgesia*, v. 135, n. 4, p. 855–864, 2022.

DAHABA, A. A. et al. BIS-vista occipital montage in patients undergoing neurosurgical procedures during propofol-remifentanil anesthesia. *Anesthesiology*, v. 112, n. 3, p. 645–651, 2010.

FIELD, C. A.; WELSH, A. H. Bootstrapping clustered data. *Journal of the Royal Statistical Society: Series B*, v. 69, n. 3, p. 369–390, 2007.

GARBE, J. et al. *DOSE-I: a multimodal biosignal dataset of procedural sedation for endoscopy*. Zenodo, 2026. Conjunto de dados.

HANS, P. et al. Comparative effects of ketamine on Bispectral Index and spectral entropy of the electroencephalogram under sevoflurane anaesthesia. *British Journal of Anaesthesia*, v. 94, n. 3, p. 336–340, 2005.

HARADA, H. et al. Accuracy of BIS monitoring using a novel interface device connecting conventional needle-electrodes and BIS sensors during frontal neurosurgical procedures. *PLoS ONE*, v. 16, n. 10, e0258647, 2021.

Referências

INTERNATIONAL MEDICAL DEVICE REGULATORS FORUM. *Good machine learning practice for medical device development: guiding principles*. IMDRF/AIML WG/N88 FINAL:2025, 2025.

JOHANSEN, J. W.; SEBEL, P. S. Development and clinical application of electroencephalographic bispectrum monitoring. *Anesthesiology*, v. 93, n. 5, p. 1336–1344, 2000.

LEE, H.-C. et al. VitalDB, a high-fidelity multi-parameter vital signs database in surgical patients. *Scientific Data*, v. 9, 279, 2022.

LIU, Q. et al. Sample entropy analysis for the estimating depth of anaesthesia through human EEG signal at different levels of unconsciousness during surgeries. *PeerJ*, v. 6, e4817, 2018.

MA, L. *EEG and BIS raw data*. Figshare, 2017. Conjunto de dados, v1. DOI: 10.6084/m9.figshare.5589841.v1.

MOONS, K. G. M. et al. PROBAST+AI: an updated quality, risk of bias, and applicability assessment tool for prediction models using regression or artificial intelligence methods. *BMJ*, v. 388, e082505, 2025.

MYLES, P. S. et al. Bispectral index monitoring to prevent awareness during anaesthesia: the B-Aware randomised controlled trial. *The Lancet*, v. 363, p. 1757–1763, 2004.

NSUGBE, E.; CONNELLY, S. Multiscale depth of anaesthesia prediction for surgery using frontal cortex electroencephalography. *Healthcare Technology Letters*, v. 9, p. 43–53, 2022.

PARK, Y. et al. A real-time depth of anesthesia monitoring system based on deep neural network with large EDO tolerant EEG analog front-end. *IEEE Transactions on Biomedical Circuits and Systems*, v. 14, p. 825–837, 2020.

Referências

PILGE, S. et al. Time delay of index calculation: analysis of cerebral state, bispectral, and Narcotrend indices. *Anesthesiology*, v. 104, n. 3, p. 488–494, 2006.

SAEB, S. et al. The need to approximate the use-case in clinical machine learning. *GigaScience*, v. 6, 2017.

SCHULLER, P. J. et al. Response of bispectral index to neuromuscular block in awake volunteers. *British Journal of Anaesthesia*, v. 115, supl. 1, p. i95–i103, 2015.

SHI, M. et al. Estimating the depth of anesthesia from EEG signals based on a deep residual shrinkage network. *Sensors*, v. 23, n. 2, 1008, 2023.

SHIRAISHI, T. et al. A comparison of frontal and occipital bispectral index values obtained during neurosurgical procedures. *Anesthesia & Analgesia*, v. 98, n. 6, p. 1773–1775, 2004.

SMITH, W. D.; DUTTON, R. C.; SMITH, N. T. Measuring the performance of anesthetic depth indicators. *Anesthesiology*, v. 84, n. 1, p. 38–51, 1996.

SUKRITI et al. Predicting depth of anaesthesia from single-channel EEG using a deep TCN-BiLSTM-attention model with EWMA. *Scientific Reports*, v. 16, 25470, 2026.

VASEY, B. et al. Reporting guideline for the early-stage clinical evaluation of decision support systems driven by artificial intelligence: DECIDE-AI. *Nature Medicine*, v. 28, p. 924–933, 2022.

VITALDB. *Open Dataset: overview and track list*. 2026. Disponível em: vitaldb.net/dataset.

BRAINSNIFFER · TCC

Obrigado!

Perguntas?

Bruno Rocha Guimarães

github.com/Bruno-BRG/brainsniffer

Código sob licença MIT · dados não redistribuídos · relatórios com hashes