

BrainSniffer: um protótipo reproduzível para estimativa da profundidade anestésica a partir de EEG

Nome do Autor¹

¹Curso de Computação – Nome da Instituição
Cidade – Estado – Brasil

email@exemplo.com

Abstract. *This paper presents BrainSniffer, an open research prototype for estimating an operational anesthesia-depth reference from frontal electroencephalography (EEG). The system downloads a public EEG and bispectral-index (BIS) corpus, applies documented causal preprocessing, trains a compact one-dimensional convolutional neural network (CNN), and exposes replay and laboratory streaming interfaces. Evaluation is performed by case-level split, avoiding leakage when adjacent windows from the same surgery are distributed across partitions. In the engineering run, the CNN obtained MAE 7.03, RMSE 11.08, Pearson correlation 0.784, stage accuracy 0.585, and macro-F1 0.548 in a five-case holdout. An exploratory evaluation on 15 VitalDB cases without retraining obtained MAE 12.43 and Pearson correlation 0.024, highlighting domain-shift limitations. The prototype is not a clinical decision system and does not prescribe anesthetic dose; it provides an auditable basis for future validation with real hardware, anesthesiology supervision, ethics approval, and a prospective protocol [Ma 2017, Nsugbe and Connelly 2022, Collins et al. 2024].*

Resumo. *Este trabalho apresenta o BrainSniffer, um protótipo aberto de pesquisa para estimar, a partir de eletroencefalografia (EEG) frontal, uma referência operacional relacionada à profundidade anestésica. O sistema baixa um corpus público de EEG e índice bispectral (BIS), aplica pré-processamento causal documentado, treina uma rede neural convolucional unidimensional (CNN) compacta e oferece interfaces de replay e streaming em laboratório. A avaliação usa separação por caso para evitar vazamento entre janelas da mesma cirurgia. Na execução de engenharia, a CNN obteve MAE 7,03, RMSE 11,08, correlação de Pearson 0,784, acurácia de estágio 0,585 e macro-F1 0,548 no holdout. Em uma avaliação exploratória de 15 casos VitalDB sem retreino, obteve MAE 12,43 e correlação 0,024, evidenciando limitações de mudança de domínio. O protótipo não é um sistema de decisão clínica, não recomenda dose e requer validação futura com hardware real, supervisão de anestesiologia, ética e protocolo prospectivo [Ma 2017, Nsugbe and Connelly 2022, Collins et al. 2024].*

Palavras-chave: EEG; anestesia; BIS; CNN; aprendizado profundo; tempo real; validação por paciente.

1. Introdução

A avaliação do componente hipnótico da anestesia é um problema de sinais fisiológicos com implicações clínicas e técnicas. O EEG varia com agente anestésico, idade, comorbidades, estímulo cirúrgico, atividade muscular, montagem dos eletrodos e qualidade da aquisição. Monitores de EEG processado, como o BIS, oferecem uma referência operacional útil, mas seus valores dependem do algoritmo, da instrumentação e do contexto. A literatura enfatiza que um índice processado não deve ser interpretado isoladamente como medida universal de consciência ou como substituto do julgamento clínico [Hajat et al. 2017, Connor 2022].

Ao mesmo tempo, estudos de aprendizado profundo mostram que redes convolucionais podem extrair informação temporal e espectral de EEG para tarefas de estimativa de profundidade anestésica [Nsugbe and Connelly 2022, Park et al. 2020, Shi et al. 2023]. O desafio, porém, não é apenas obter uma métrica alta em janelas de um conjunto de dados. Janelas adjacentes da mesma cirurgia são correlacionadas; portanto, uma divisão aleatória por janela pode inflar artificialmente a generalização. Também é necessário tratar explicitamente artefatos, atrasos do monitor, mudança de equipamento, perda de amostras e incerteza de domínio [Hajat et al. 2017, Collins et al. 2024].

Este trabalho descreve o BrainSniffer, uma implementação em Python 3.12 que organiza essas preocupações em um pipeline reproduzível. O objetivo do protótipo é avaliar se uma CNN compacta consegue estimar um valor contínuo semelhante ao BIS e derivá-lo em estágios de pesquisa, preservando a distinção entre previsão de um rótulo de monitor e avaliação clínica do paciente. As contribuições são [FDA, Health Canada and MHRA 2021, Vasey et al. 2022]:

- um fluxo reproduzível de download, integridade, pré-processamento causal e treinamento;
- uma avaliação agrupada por caso, com baseline espectral e métricas contínuas e discretas;
- um caminho de replay e uma interface de streaming por Lab Streaming Layer (LSL), com auditoria e abstenção sob baixa qualidade;
- uma avaliação externa exploratória em VitalDB que explicita mudança de domínio e limites de extrapolação.

2. Fundamentação e trabalhos relacionados

O corpus inicial é o conjunto “EEG and BIS raw data”, disponibilizado por Ma no Figshare, que associa EEG frontal a valores BIS [Ma 2017]. O trabalho de Nsugbe e Connelly descreve problema relacionado usando EEG frontal amostrado a 128 Hz, valores BIS em intervalos de 5 s e faixas de pesquisa derivadas do índice [Nsugbe and Connelly 2022]. Esses elementos orientaram a taxa, o tamanho de janela e a apresentação dos estágios no BrainSniffer, sem reutilizar como validação os resultados publicados por outros autores [Ma 2017, Nsugbe and Connelly 2022].

Abordagens anteriores incluem decomposição multiescala, redes convolucionais e arquiteturas de supressão de ruído. O AnesNET, por exemplo, combina uma cadeia de aquisição e uma rede profunda para monitoramento em tempo real [Park et al. 2020]; o trabalho de Shi et al. investiga uma rede de residual shrinkage para estimativa de profundidade anestésica [Shi et al. 2023]. Neste TCC, a escolha é mais conservadora: uma



Figura 1. Pipeline do BrainSniffer e a barreira de segurança de engenharia.
Fonte: elaboração própria a partir das decisões de projeto e dos princípios de desenvolvimento documentados em [FDA, Health Canada and MHRA 2021, Lab Streaming Layer 2026].

CNN 1-D pequena sobre a janela temporal pré-processada, acompanhada de um base-line espectral auditável. Essa escolha permite medir o ganho da rede antes de adicionar atenção, decomposição ou modelos multitarefa [Park et al. 2020, Shi et al. 2023].

O BIS é um índice proprietário. Uma reimplementação aberta dos algoritmos do BIS é relevante para discutir auditabilidade, mas não transforma uma rede treinada sobre o rótulo BIS em uma reimplementação certificada do monitor [Connor 2022]. A revisão de Hajat, Ahmad e Andrzejowski também destaca artefatos, paralisia, agentes farmacológicos e contexto clínico como fontes de interpretação inadequada [Hajat et al. 2017]. Por isso, a interface do BrainSniffer utiliza a expressão “referência BIS estimada” e exibe qualidade e origem do dado [Connor 2022, Hajat et al. 2017].

3. Materiais e métodos

3.1. Dados e tarefa de predição

O downloader consulta a API do Figshare, confere tamanho e MD5 do manifesto e armazena os arquivos de forma atômica. O corpus contém 24 casos anônimos. O caso 24 foi reprovado pelo gate padrão de qualidade por apresentar escala de amplitude incompatível com os demais arquivos: 99,87% das amostras ficaram fora do limite de aproximadamente $\pm 62,5$ observado no corpus. Como não existe metadado confiável para converter essa escala, o caso não é reinserido silenciosamente; o modo de qualidade zero fica restrito à auditoria exploratória [Ma 2017].

Cada janela contém 640 amostras, correspondentes a 5 s em 128 Hz. O rótulo contínuo é o valor BIS associado ao início da janela no modo padrão, com `label_offset_seconds=0`. O pipeline permite registrar explicitamente um deslocamento para estudos de sensibilidade, pois um monitor processado pode apresen-

tar atraso e suavização. Valores fora de $[0, 100]$, não finitos ou associados a janelas abaixo do limiar de qualidade são descartados [Ma 2017, Nsugbe and Connelly 2022, Hajat et al. 2017].

Para a análise discreta, o valor contínuo é convertido nos quatro estágios mostrados na Tabela 1. A conversão é um recurso de interpretação e avaliação; não é uma classificação clínica independente [Nsugbe and Connelly 2022, Hajat et al. 2017].

Tabela 1. Estágios de pesquisa derivados do valor BIS [Nsugbe and Connelly 2022].

Estágio	Intervalo	Interpretação no protótipo
Profundo	$[0, 40)$	referência de pesquisa
Geral	$[40, 60)$	referência de pesquisa
Leve	$[60, 80)$	referência de pesquisa
Acordado	$[80, 100]$	referência de pesquisa

3.2. Pré-processamento causal e modelo

O sinal é limitado a uma faixa de segurança, filtrado entre 0,5 e 45 Hz e submetido a notch de 50 Hz. A escala de amplitude é registrada na configuração do checkpoint. O treinamento e o replay usam o mesmo pré-processador causal, preservando o estado do filtro entre chunks e por caso. Uma rota zero-phase existe apenas para análise offline explícita; ela não é usada no caminho de streaming, pois teria acesso a amostras futuras [Nsugbe and Connelly 2022, Park et al. 2020].

O score de qualidade combina verificações de finitude, saturação e linha plana. O limiar padrão é 0,20. Abaixo desse limiar, a janela não entra no treinamento e a inferência pode emitir ABSTAIN, sem valor BIS visível. O score é uma barreira heurística de engenharia, não uma confiança calibrada e não deve acionar dose, alarme ou conduta [FDA, Health Canada and MHRA 2021, Vasey et al. 2022].

A entrada da rede tem forma (batch, 1, 640). A CNN possui quatro blocos convolucionais 1-D com normalização, ativação GELU e pooling. Em seguida, utiliza pooling adaptativo, camadas densas e dropout. A saída é limitada ao intervalo $[0, 100]$ por uma sigmoide escalada. O treinamento usa perda Smooth L1. A arquitetura foi mantida compacta para permitir comparação com um baseline e medição de latência; não se afirma que ela seja superior a redes temporais dilatadas, atenção, espectrogramas ou modelos multitarefa [Park et al. 2020, Shi et al. 2023].

O baseline espectral extrai potência absoluta e relativa nas bandas delta, teta, alfa, beta e gama, frequência de borda de 90%, entropia espectral, RMS e comprimento de linha. Um Random Forest recebe essas características. CNN e baseline usam as mesmas janelas, a mesma separação por caso e o mesmo pré-processamento causal [Nsugbe and Connelly 2022, Hajat et al. 2017].

3.3. Protocolo de avaliação

Os casos são embaralhados com semente 42 e divididos em treinamento, validação e teste, mantendo todas as janelas de um caso em uma única partição. As métricas contínuas são erro absoluto médio (MAE), raiz do erro quadrático médio (RMSE), viés e correlação de

Pearson. Essa unidade de separação é uma decisão conservadora para reduzir dependência entre janelas da mesma cirurgia [Collins et al. 2024, Vasey et al. 2022]:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (1)$$

As métricas discretas são acurácia e macro-F1 nos quatro estágios. O número de casos, o número de janelas, a semente e os hashes dos arquivos são registrados nos relatórios JSON. Quando há pelo menos dois casos de teste, o projeto também calcula bootstrap agrupado por caso para indicar incerteza preliminar [Collins et al. 2024, Vasey et al. 2022].

3.4. Inferência em fluxo e auditoria

O replay mantém uma janela circular de 5 s e emite uma previsão a cada 1 s. O valor bruto, o valor suavizado por EWMA, a qualidade, o timestamp e a origem do dado permanecem separados. A interface LSL utiliza descoberta de streams, chunks, timestamps e seleção de canal. LSL é uma camada de transporte e sincronização para pesquisa, não um driver de monitor nem uma garantia de que o canal seja EEG válido [Lab Streaming Layer 2026, Kothe et al. 2025].

Antes e durante o consumo, o sistema audita metadados, taxa de amostragem, timestamps, lacunas, pontos não finitos, saturação, linha plana e qualidade. Em caso de silêncio superior ao timeout de 2 s ou de falha de auditoria, a saída fica stale/abstain e o estado causal é reiniciado. Essa política evita manter uma estimativa baseada em janela antiga. A latência medida com sinal sintético representa somente o custo de software na máquina local, não a latência de um sistema clínico [FDA, Health Canada and MHRA 2021, Vasey et al. 2022].

4. Interface e reprodutibilidade

O aplicativo Streamlit organiza o fluxo em abas de visão geral, dados, exploração, treinamento, replay e EEG ao vivo. A visão geral confronta os resultados dos dois cor-pora; a aba de dados baixa o Figshare e permite selecionar casos VitalDB para avaliação externa. A aba de treinamento registra configuração, semente, partições, versão do ambiente e hashes. A aba LSL exige uma ficha de entrada com fabricante, modelo, montagem, unidade, taxa declarada, canal escolhido, bridge e responsável pela sessão [FDA, Health Canada and MHRA 2021, Vasey et al. 2022].

O VitalDB foi usado somente como fonte externa exploratória. Trata-se de um banco perioperatório independente, com milhares de casos e numerosos tracks de sinais, incluindo dados relacionados à cirurgia e à anestesia [Lee et al. 2022, VitalDB 2026]. O BrainSniffer baixa seletivamente BIS/EEG1_WAV e BIS/BIS, preserva a unidade declarada e não mistura esses arquivos no treinamento do Figshare. Essa separação impede que uma diferença de aparelho, ganho, montagem ou população seja escondida por re-treino automático [Lee et al. 2022, VitalDB 2026].

5. Resultados

Os resultados desta seção são uma execução de engenharia reproduzível e não uma validação clínica. O treinamento completo usou 23 casos efetivos, após o gate de qualidade, e 31.055 janelas válidas. A divisão produziu 13 casos de treinamento, 5 de validação e 5 de teste. A Tabela 2 resume o holdout Figshare conforme a recomendação de explicitar população, partição e unidade de análise [Ma 2017, Collins et al. 2024].

Tabela 2. Holdout Figshare por caso, seed 42, CNN causal [Ma 2017, Collins et al. 2024].

Item	Resultado
Casos treinamento / validação / teste	13 / 5 / 5
Janelas treinamento / validação / teste	15.894 / 9.638 / 5.523
MAE / RMSE	7,03 / 11,08
Viés / Pearson	0,79 / 0,784
Acurácia / macro-F1	0,585 / 0,548

Na mesma partição, o baseline espectral obteve MAE 8,86, RMSE 13,23, correlação 0,667, acurácia 0,540 e macro-F1 0,480. A CNN apresentou vantagem nas métricas contínuas desse split, enquanto o resultado por estágio não deve ser tratado como evidência de superioridade geral. Não houve ajuste de hiperparâmetros, calibração ou seleção de protocolo depois de observar um conjunto externo [Collins et al. 2024].




Figura 2. Comparação entre o holdout Figshare e a avaliação VitalDB sem re-treino. Fonte: relatórios JSON do projeto; a leitura deve respeitar a mudança de domínio descrita em [Lee et al. 2022, VitalDB 2026].

O bootstrap exploratório de 1.000 reamostragens por caso no holdout estimou Pearson médio 0,789, intervalo de 95% entre 0,703 e 0,881, e MAE médio 7,11, intervalo entre 6,38 e 8,24. Esses intervalos refletem somente a variabilidade dos cinco casos de teste e não substituem uma coorte externa maior [Collins et al. 2024, Vasey et al. 2022].

O benchmark de processamento sintético mediu p50 de 0,57 ms e p95 de 0,79 ms por emissão, com passo de 1 s e CPU local. A medida não inclui aquisição, resampling, rede, visualização, carga do sistema operacional, concorrência ou um dispositivo de EEG; portanto, não é uma garantia de tempo real clínico [FDA, Health Canada and MHRA 2021].

5.1. Sensibilidade exploratória ao alinhamento

O comando `evaluate-offset` reaplicou o checkpoint congelado aos mesmos cinco casos de teste sem retreino, variando apenas o instante do rótulo BIS. Os valores foram MAE 7,22, 7,03 e 6,76 para offsets de -20, 0 e +20 s, respectivamente; a correlação correspondente foi 0,766, 0,784 e 0,799. O crescimento gradual com um rótulo posterior é compatível com uma hipótese de atraso do monitor, mas a análise foi pós-hoc. Portanto, ela não seleciona o offset final nem demonstra uma medida clínica de consciência [Hajat et al. 2017, Nsugbe and Connelly 2022].




Figura 3. Sensibilidade exploratória ao alinhamento do rótulo BIS. Fonte: relatório de offsets do projeto; a tendência não deve ser usada para escolher atraso em pacientes [Hajat et al. 2017, Nsugbe and Connelly 2022].

5.2. Avaliação externa exploratória

Quinze casos VitalDB compatíveis foram normalizados e avaliados sem retreino, totalizando 38.730 janelas. A CNN obteve MAE 12,43, RMSE 18,80, viés 1,40, correlação 0,024, acurácia de estágio 0,420 e macro-F1 0,398. O bootstrap de 1.000 reamostragens por caso estimou Pearson 0,023, com intervalo de 95% entre -0,126 e 0,193. O resultado é uma avaliação out-of-dataset e deve ser reportado junto com a população e a partição, não como validação clínica [Lee et al. 2022, VitalDB 2026, Collins et al. 2024].

O caso 11 foi rejeitado porque não continha simultaneamente os tracks BIS/EEG1_WAV e BIS/BIS. Os diagnósticos agregados encontraram pontos não finitos nos 15 arquivos; eles foram tratados somente na preparação offline das janelas. No




Figura 4. Intervalos exploratórios por caso para Pearson e MAE. Fonte: relatórios JSON do projeto; as linhas representam reamostragem de cirurgias inteiras [Collins et al. 2024, Vasey et al. 2022].

caminho online, entradas não finitas são rejeitadas antes do filtro causal. O resultado externo é, portanto, evidência de mudança de domínio e de necessidade de validação, não uma conclusão sobre o VitalDB inteiro [VitalDB 2026, Vasey et al. 2022].

6. Discussão e limitações

O resultado interno demonstra que o software consegue executar download, integridade, treinamento, avaliação, replay e streaming sintético sob um protocolo registrado. Isso não prova que a CNN mede profundidade anestésica em paciente novo. O corpus inicial é pequeno, usa um canal, depende de um índice processado como referência e pode carregar vieses de aparelho, centro, montagem e população. O BIS também pode ser afetado por artefatos, atividade muscular, fármacos, paralisia e atrasos de processamento [Hajat et al. 2017].

A baixa correlação no VitalDB sem retreino é coerente com a hipótese de mudança de domínio. Ela impede apresentar a métrica interna como generalização. Também não é lícito melhorar o número externo por adaptação sem antes definir protocolo independente, partição travada e justificativa de transferência. O projeto registra essa limitação e mantém os datasets separados [Lee et al. 2022, FDA, Health Canada and MHRA 2021].

Do ponto de vista de segurança, o aplicativo não controla bombas, não gera recomendação de dose e não aciona alarme clínico. A abstenção sob baixa qualidade reduz uma classe de falhas de software, mas não cria segurança clínica. A próxima etapa deve incluir estudo com hardware específico, verificação de taxa e unidade, sincronização com o monitor, teste de perdas e reconexão, anotação de qualidade e revisão por anesthesiologists [FDA, Health Canada and MHRA 2021, Vasey et al. 2022].

O planejamento de validação segue uma progressão de pesquisa: replay, bancada com sinal conhecido, teste externo travado, modo sombra e somente depois estudo pros-

pectivo supervisionado. Essa postura é consistente com princípios de desenvolvimento de aprendizado de máquina para dispositivos médicos e com orientações de avaliação transparente de sistemas de suporte à decisão [FDA, Health Canada and MHRA 2021, Vasey et al. 2022, Collins et al. 2024].

7. Conclusão

O BrainSniffer fornece uma base em Python 3.12 para investigar estimativa de uma referência BIS a partir de EEG frontal com CNN 1-D, pré-processamento causal, separação por paciente, baseline espectral, interface Streamlit e entrada de pesquisa via LSL. O holdout Figshare mostrou uma execução interna reproduzível, enquanto a avaliação VitalDB revelou que o desempenho não se transfere automaticamente para outro corpus [Ma 2017, Lee et al. 2022].

Assim, a contribuição atual é metodológica e de engenharia: tornar explícitos dados, rótulos, qualidade, latência, partições, artefatos e limites de interpretação. Os próximos experimentos devem pré-especificar alinhamento, incluir baseline de entropia e modelos temporais, ampliar a validação externa, calibrar a política de abstenção, medir o hardware alvo e conduzir avaliação prospectiva com equipe de anestesiologia. Até que essas etapas sejam concluídas, o sistema deve permanecer restrito à pesquisa e não pode ser usado para decidir a profundidade anestésica ou a dose de um paciente [FDA, Health Canada and MHRA 2021, Collins et al. 2024].

Agradecimentos

O autor agradece às equipes que disponibilizaram os datasets públicos utilizados para desenvolvimento e avaliação exploratória. Os termos de uso de cada corpus devem ser consultados antes de redistribuição ou novo estudo [Ma 2017, VitalDB 2026].

Referências

- Ma, L. (2017). *EEG and BIS raw data*. Figshare. DOI: 10.6084/m9.figshare.5589841.v1.
- Nsugbe, E. and Connelly, S. (2022). Multiscale depth of anaesthesia prediction for surgery using frontal cortex electroencephalography. *Healthcare Technology Letters*, 9, 43–53.
- Park, Y. et al. (2020). A real-time depth of anesthesia monitoring system based on deep neural network with large EDO tolerant EEG analog front-end. *IEEE Transactions on Biomedical Circuits and Systems*, 14, 825–837.
- Shi, M. et al. (2023). Estimating the depth of anesthesia from EEG signals based on a deep residual shrinkage network. *Sensors*, 23(2), 1008.
- Hajat, Z., Ahmad, N. and Andrzejowski, J. (2017). The role and limitations of EEG-based depth of anaesthesia monitoring in theatres and intensive care. *Anaesthesia*, 72, 38–47.
- Connor, C. W. (2022). Open reimplementations of the BIS algorithms for depth of anaesthesia. *Scientific Reports*.
- Lee, H.-C. et al. (2022). VitalDB, a high-fidelity multi-parameter vital signs database in surgical patients. *Scientific Data*, 9.

- VitalDB (2026). Open Dataset: overview, track units and data-use terms. Documentação online.
- Lab Streaming Layer (2026). Introduction to Lab Streaming Layer. Documentação online.
- Kothe, C. et al. (2025). The Lab Streaming Layer for synchronized multimodal recording. *Frontiers in Neuroscience*.
- FDA, Health Canada and MHRA (2021). Good machine learning practice for medical device development: guiding principles. Guidance online.
- Vasey, B. et al. (2022). Reporting guideline for the early-stage clinical evaluation of decision support systems driven by artificial intelligence: DECIDE-AI. *Nature Medicine*, 28, 924–933.
- Collins, G. S. et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385.