

BrainSniffer: protótipo reproduzível para estimar uma referência BIS a partir de EEG frontal

Bruno Rocha Guimarães¹

¹Ciência da Computação – Centro Universitário Jorge Amado
Salvador, Bahia – Brasil

Abstract. *This paper describes BrainSniffer, a reproducible engineering prototype that estimates a Bispectral Index (BIS) reference label from frontal electroencephalography (EEG). The pipeline uses five-second windows at 128 Hz, a compact one-dimensional convolutional neural network, and partitions grouped by case or subject. The active Figshare-only checkpoint reached mean absolute error (MAE) 7.03 and Pearson correlation 0.784 in a five-case Figshare holdout, but 12.43 and 0.024 in a 15-case VitalDB cross-dataset assessment, where ordinal prediction probability (P_k) dropped to 0.515, indistinguishable from chance. A mixed candidate trained with Figshare and part of VitalDB reached 6.69/0.818 on the Figshare benchmark and 8.60/0.688 on the historical VitalDB participant holdout, with no sustained difference from the active checkpoint on Figshare (paired Δ MAE 0.34, 95% CI $-0.28-0.81$); a causal per-case exponential smoothing (EWMA, exploratory, no retraining) lowers the mixed candidate to 5.84 (95% CI 4.56–7.62) and 7.89 (95% CI 6.86–9.38) (reference span 10), respectively. These results are retrospective and exploratory; Pearson is interpreted as association, not agreement. BrainSniffer neither measures consciousness nor supports clinical decisions, alarms, or drug dosing.*

Keywords: frontal EEG; BIS reference label; one-dimensional CNN; grouped validation; domain shift; causal smoothing; reproducibility.

Resumo. *Este artigo descreve o BrainSniffer, protótipo de engenharia reproduzível que estima, a partir de eletroencefalografia (EEG) frontal, um rótulo de referência do Índice Bispectral (BIS). O pipeline usa janelas de cinco segundos a 128 Hz, uma rede neural convolucional unidimensional compacta (1-D CNN) e partições agrupadas por caso ou pessoa. O checkpoint ativo, treinado apenas no Figshare, obteve erro absoluto médio (MAE) 7,03 e correlação de Pearson 0,784 em cinco casos Figshare, mas 12,43 e 0,024 na avaliação com 15 casos VitalDB, com P_K 0,515, indistinguível do acaso. Um candidato misto, treinado com Figshare e parte do VitalDB, obteve 6,69/0,818 no benchmark Figshare e 8,60/0,688 no holdout histórico VitalDB por participante, sem diferença sustentada em relação ao ativo no Figshare (Δ MAE pareado 0,34; IC 95% $-0,28-0,81$); uma suavização exponencial causal por caso (EWMA, exploratória, sem retreino) reduz o misto para 5,84 (IC 95% 4,56–7,62) e 7,89 (IC 95% 6,86–9,38) (span de referência 10). Os resultados são retrospectivos e exploratórios; Pearson é tratado como associação, não acordo. O BrainSniffer não mede consciência nem apoia decisão clínica, alarme ou dose.*

Palavras-chave: EEG frontal; rótulo BIS; CNN 1-D; validação agrupada; reprodutibilidade.

1. Introdução

Na anestesia geral, é preciso saber se o paciente está suficientemente hipnotizado sem exagerar na dose, e para isso usam-se referências objetivas de profundidade. O Índice Bispectral (Bispectral Index, BIS), calculado a partir da eletroencefalografia (EEG) frontal, é a referência mais usada à beira do leito, mas é uma saída proprietária: sua regra de combinação não é publicada e não pode ser reproduzida exatamente a partir do sinal. Modelos que tentam aproximar esse rótulo enfrentam ainda um risco metodológico silencioso: janelas vizinhas da mesma cirurgia são quase idênticas, então uma partição aleatória entre treino e teste mede o reconhecimento de casos já vistos, não a generalização. Falta um protótipo reproduzível com partições por caso, controle espectral e avaliação entre fontes: este trabalho apresenta o BrainSniffer.

A pesquisa responde a duas perguntas. (i) Quanto uma rede neural convolucional unidimensional compacta (1-D CNN) aproxima o rótulo BIS em casos não usados no ajuste, comparada a um controle mais simples baseado em medidas espectrais (baseline espectral)? (ii) Esse desempenho se mantém ao trocar a fonte dos dados, do Figshare para o VitalDB, com outro equipamento, montagem e população? O objetivo geral é avaliar essa aproximação de forma reproduzível. Os objetivos específicos são: comparar a CNN ao baseline no holdout Figshare; quantificar a queda no VitalDB; testar se o candidato misto reduz o erro; e caracterizar ordenação (P_K) e incerteza (bootstrap por caso), além do efeito da suavização causal (EWMA).

Vale fixar o vocabulário: o modelo estima um rótulo de referência derivado do BIS, não o BIS como grandeza independente, porque o próprio BIS é a saída de um monitor sobre o mesmo sinal. A contribuição é uma cadeia com partições por grupo, controle espectral, comparação entre fontes, incerteza e suavização causal exploratória. O escopo é avaliar essa cadeia, não desenvolver um dispositivo médico. A Seção 2 fundamenta o BIS e o vazamento; a Seção 3 descreve os métodos; a Seção 4 traz os resultados; a Seção 5 discute limitações; e a Seção 6 conclui.

2. Fundamentação e trabalhos relacionados

2.1. O índice BIS e seus limites

O Índice Bispectral (BIS) é uma saída proprietária do EEG frontal, em escala de 0 a 100, com a faixa intermediária como referência de hipnose [Johansen and Sebel 2000]. O cálculo combina características temporais, espectrais e bispectrais por regra não publicada; por ser fechado, não pode ser reproduzido do EEG. O BIS é só auxílio sob supervisão, não medida de consciência ou dose. Sua leitura varia com EMG, fármacos e atrasos [Schuller et al. 2015, Hans et al. 2005, Pilge et al. 2006], e ensaios guiados tiveram resultados dependentes do comparador [Myles et al. 2004, Avidan et al. 2008, Avidan et al. 2011]. O BIS chega suavizado e com atraso [Pilge et al. 2006], e a sua suavização causal é prática comum no corpus [Sukriti et al. 2026].

2.2. Vazamento entre janelas e partição por grupo

Redes profundas já foram estudadas com alvos, canais, populações e equipamentos distintos para aproximar índices derivados de EEG [Park et al. 2020, Shi et al. 2023]. O problema é que janelas vizinhas da mesma cirurgia são parecidas entre si em amplitude,

espectro e nível de BIS, porque refletem o mesmo paciente no mesmo plano anestésico. Se essas janelas forem espalhadas aleatoriamente entre treino e teste, o teste contém trechos quase idênticos aos de treino: é o vazamento (*leakage*), que infla o desempenho. Para evitá-lo, os dados são separados por caso ou pessoa (o grupo), ao custo de uma estimativa mais pessimista e mais realista para um caso novo [Sukriti et al. 2026, Saeb et al. 2017].

2.3. Corpora, transparência e relato de modelos

O conjunto “EEG and BIS raw data” reúne 24 casos anônimos com EEG frontal e valores BIS, publicado no repositório Figshare sob licença CC BY 4.0 [Ma 2017]. Um estudo anterior no mesmo corpus usou características multiescala com análise discriminante linear (LDA) e sustenta a descrição do corpus, mas não é evidência de rede convolucional [Nsugbe and Connelly 2022]. Outros estudos estimaram a concentração anestésica derivada de EEG com cadeia dedicada e o índice de estado do paciente (Patient State Index, PSI) com quatro canais em 18 idosos sedados; ambos demonstram viabilidade em configurações específicas, sem comparabilidade direta com o rótulo, o canal ou a população deste trabalho [Park et al. 2020, Shi et al. 2023].

O VitalDB é um banco de sinais perioperatórios de milhares de cirurgias e inclui os canais de EEG frontal e de BIS usados aqui [Lee et al. 2022, VitalDB 2026]. O conjunto aberto exige licença CC BY-NC-SA 4.0 e acordo de uso de dados, sem redistribuição. Escala, equipamento, montagem e população diferem do Figshare; o VitalDB informa a sensibilidade à troca de fonte, sem isolar a causa. O rótulo também difere no instrumento: BIS a cada 5 s por sensor BIS Quatro no Figshare [Ma 2017, Sukriti et al. 2026] contra BIS de 1 s de monitores BIS Vista no VitalDB [VitalDB 2026, Lee et al. 2022], com algoritmo e suavização não públicos. O DOSE-I não foi incorporado por usar escala observacional MOAA/S, não conversível em BIS [Garbe et al. 2026].

Uma reimplementação aberta do algoritmo do índice não torna um regressor treinado contra o BIS equivalente a um monitor [Connor 2022]. Independência entre desenvolvimento e avaliação, descrição de grupos e análise de acordo e calibração são centrais no relato de modelos [Collins et al. 2024, Archer et al. 2021].

3. Materiais e métodos

A Tabela 1 resume os dois checkpoints. O “ativo” foi ajustado só no Figshare e testa o limite interno e a queda ao mudar de corpus; o “misto” viu também parte do VitalDB, de modo que seu desempenho nessa fonte não mede transporte para fonte nova.

Tabela 1. Definição conceitual dos dois checkpoints.

Modelo	Treinado com	Avaliado em
Modelo A – Figshare (ativo)	Figshare	Figshare (holdout por caso) e VitalDB (avaliação cruzada de dataset)
Modelo B – misto	Figshare + parte do VitalDB	Figshare (benchmark histórico) e VitalDB (holdout histórico por participante)

A Figura 1 resume esse fluxo retrospectivo, da composição do pool à avaliação sem reajuste.




Figura 1. Fluxo retrospectivo auditável do BrainSniffer.

3.1. Fontes, unidades de agrupamento e partições

Cada arquivo é uma gravação inteira, tratada como um caso; de cada caso saem janelas de 5 s, unidades de treino e de métrica. O grupo é a unidade que nunca cruza partições. O corpus tem 59 arquivos: 44 no pool de desenvolvimento e 15 casos VitalDB congelados. Após os gates de qualidade, 23 casos Figshare e dez VitalDB ficaram elegíveis (33 casos, 55.471 janelas). No Figshare não há identificador de participante; no VitalDB o agrupamento usa o identificador e reúne reoperações [Ma 2017, Lee et al. 2022].

O ativo usou os 23 Figshare elegíveis (13/5/5 com seed 42). O misto fixo excluiu o holdout Figshare e usou 18 grupos Figshare mais dez VitalDB (28 grupos, 49.948 janelas; ajuste com 12 Figshare e quatro VitalDB). Só o teste interno é lido como resultado; as janelas de validação não aparecem nas tabelas.

Os mesmos cinco Figshare (casos 3, 4, 5, 9 e 19) servem aos dois checkpoints. Para o misto, os 15 VitalDB (arquivos 1–17, sem 11 e 15, que não têm os tracks requeridos) vêm da mesma fonte do desenvolvimento e já haviam sido inspecionados: é um holdout histórico após exposição ao domínio, não validação externa confirmatória [Collins et al. 2024, International Medical Device Regulators Forum 2025].

3.2. Tarefa, pré-processamento e qualidade

Cada exemplo é um trecho curto de EEG: 640 amostras, isto é, uma janela de 5 segundos amostrada a 128 Hz, com passo de 5 s na construção offline. Para cada início t , o alvo corresponde a $t + \text{offset}$ (offset padrão 0 s), arredondado ao intervalo do BIS do caso. O pipeline mantém a banda de 0,5–45 Hz, notch de 50 Hz de quarta ordem e a escala registrada; o filtro usa só passado e presente (estado causal por caso), com rota de fase zero apenas para análise offline [Ma 2017, Nsugbe and Connelly 2022].

Os gates exigem 90% de EEG finito, lacuna máxima de 2 s, qualidade global 0,35, 80% de BIS válido e 0,20 por janela (heurísticas sem calibração clínica; o Figshare 24 está em quarentena). Nos 15 VitalDB do benchmark, a construção offline interpola não finitos

(podendo usar amostras futuras) e interpola o BIS para grade de 1 s sem máscara persistente: difere da rejeição do replay e limita a interpretação, mas foi mantida por fidelidade histórica.

3.3. Modelos e treinamento

A CNN histórica recebe a janela de 640 amostras em um canal, é treinada com perda Smooth L1 (os braços novos do experimento fatorial usam Huber com $\delta = 5$) e tem saída sigmoidal escalada para $[0, 100]$. A Tabela 2 explicita a arquitetura e os parâmetros registrados no protocolo, sem carregar pesos. Recursos posteriores do treinador e arquiteturas opcionais não são atribuídos retroativamente a esses pesos.

Tabela 2. Configuração histórica dos checkpoints.

Item	Configuração registrada
Convolucionais	Canais $1 \rightarrow 32 \rightarrow 64 \rightarrow 128 \rightarrow 128$; <i>kernel</i> 7, 7, 5, 5; <i>padding</i> 3, 3, 2, 2; <i>stride</i> 1; normalização em lote + GELU
<i>Pooling</i> e cabeça	max-pooling de fator 2 nos 3 primeiros blocos; pooling médio global; camada densa 128–64–1, GELU, <i>dropout</i> 0,20
Treino (ambos)	10 <i>epochs</i> , <i>batch</i> 128, <i>lr</i> 10^{-3} , <i>wd</i> 10^{-4} , <i>seed</i> 42; validação/teste: 20% dos grupos em cada partição
Amostragem	Misto: balanceada por grupo/fonte; ativo: não registrada
Amplitude e <i>notch</i>	<i>Clip</i> $\pm 100 \mu V$, divisor de escala $50 \mu V$, saída em $[-5, 5]$; <i>notch</i> 50 Hz, $Q=30$
<i>Random Forest</i>	100 árvores, profundidade máxima 12, mínimo de 2 amostras por folha, semente 42

A arquitetura compacta permite replay em CPU, sem implicar superioridade sobre alternativas temporais [Park et al. 2020, Shi et al. 2023].

Como controle, o baseline espectral resume cada janela em 14 atributos clássicos (potências absoluta e relativa de delta a gama, SEF90, entropia, RMS e *line length*) com floresta aleatória (Tabela 2), nas mesmas janelas e partição do holdout: se o espectro já alcança erro parecido, a CNN precisa se justificar.

3.4. Métricas, incerteza e análises exploratórias

O desfecho primário é o MAE agregado por janela (casos longos pesam mais); demais métricas são secundárias, sem correção para multiplicidade. Foram calculados MAE, RMSE, viés, Pearson e CCC de Lin para o rótulo contínuo, além de acurácia e macro-F1 em quatro faixas ($[0, 40)$, $[40, 60)$, $[60, 80)$, $[80, 100]$), lidas com rótulos curtos só para comunicação, sem validar limiar clínico [Collins et al. 2024]. Pearson mede associação, não acordo; a concordância usa inclinação de calibração, limites de concordância, ICC(2,1) e fração de $|erro| \leq 10$, tudo exploratório. O P_K e o Pearson agregados empilham todas as janelas (pares entre casos distintos entram na conta); por isso a Seção 4 traz também mediana e amplitude por caso.

A ordenação é medida pela probabilidade de predição P_K de Smith, Dutton e Smith [Smith et al. 1996]: sorteados dois momentos com BIS distintos, qual a chance de o indicador ordená-los como a referência? Vale 1 na ordem perfeita e 0,5 no acaso; empates no alvo são excluídos e no indicador contam 0,5. Por depender só da ordem, P_K ignora erro de escala. A incerteza usa bootstrap de casos inteiros ($B = 1.000$, *seed* 42, percentis

2,5/97,5); com cinco casos Figshare, é exploratória (1.000 réplicas não equivalem a 1.000 casos) [Field and Welsh 2007, Archer et al. 2021].

Como referência externa, estudos de acurácia do próprio BIS tratam diferenças de até 10 unidades entre duas medições do monitor como aceitáveis [Dahaba et al. 2010, Shiraishi et al. 2004, Harada et al. 2021]; como o alvo já varia nessa ordem, um MAE da mesma magnitude fica dentro da variabilidade do rótulo; o valor é escala de leitura, não limiar clínico.

A comparação VitalDB também foi calculada por caso, pareando as janelas de cada caso. A análise de sensibilidade reaplicou o checkpoint ativo aos mesmos cinco casos Figshare, sem retreino, em uma grade de -20 a $+20$ s. Como a grade foi examinada após o treinamento, ela formula hipótese sobre alinhamento e não escolhe o atraso do rótulo [Pilge et al. 2006]. Deslocamentos positivos associam cada janela a um BIS futuro, indisponível no instante de emissão, e por isso não alteram o offset zero do replay.

3.5. Replay retrospectivo e trajetória ilustrativa

Replay é percorrer uma gravação existente (buffer de 5 s, atualização a cada 1 s), sem EEG físico. Para visualizar o comportamento temporal, fixou-se antes da inferência o caso 19 do holdout (4.355 s), com a configuração do checkpoint ativo em CPU, sem treino; a curva bruta posiciona-se no instante do alvo offline, sem representar disponibilidade sem atraso.

3.6. Suavização causal (EWMA) das predições

Como o alvo é uma saída já suavizada pelo monitor, o pipeline também permite uma média móvel exponencial causal por caso (EWMA), aplicada às predições congeladas, sem retreino: $s_t = \alpha y_t + (1 - \alpha)s_{t-1}$, com $\alpha = 2/(\text{span} + 1)$ e reinício por caso; o *span* é medido em janelas de 5 s e $\text{span} = 1$ reproduz a predição bruta. Usar apenas amostras passadas mantém o caminho compatível com o replay. A varredura de spans é retrospectiva e exploratória (examinada após os resultados; não reescolhe checkpoint, treino ou arquitetura), seguindo a prática de suavização temporal de trabalhos contemporâneos [Sukriti et al. 2026, Pilge et al. 2006].

4. Resultados

4.1. Checkpoint ativo e baseline no Figshare

No holdout Figshare do checkpoint ativo, cinco casos e 5.523 janelas produziram MAE 7,03, RMSE 11,08, viés 0,79 e Pearson 0,784. A acurácia por faixa foi 0,585 e o macro-F1 0,548. O baseline espectral, na mesma partição, obteve MAE 8,86, RMSE 13,23, Pearson 0,667, acurácia 0,540 e macro-F1 0,480. No bootstrap pareado por caso, o ΔMAE favorável à CNN é $-1,84$ (IC 95% $-2,37$ — $-0,66$) e o ΔP_K é $+0,051$ ($0,012$ — $0,081$); os intervalos excluem zero, mas com cinco casos o teste é exploratório. A Tabela 3 resume o agregado.

A Figura 2 mostra que a CNN superestima o patamar intermediário (850 janelas: MAE 8,72, viés $+4,79$, Pearson 0,910): associação alta não elimina erro sistemático; é ilustração, não evidência de generalização.

Tabela 3. Holdout Figshare comum (5 casos, 5.523 janelas; MAE e RMSE em pontos BIS).

Modelo	MAE	RMSE	Pearson	Acurácia	Macro-F1
CNN ativa	7,03	11,08	0,784	0,585	0,548
Baseline espectral	8,86	13,23	0,667	0,540	0,480




Figura 2. Trajetória offline do caso 19 do Figshare: referência e predição bruta (topo) e erro por janela (base).

4.2. Comparação dos checkpoints nos benchmarks históricos

O misto obteve 6,69/10,67/2,12/0,818/0,574 no Figshare e 8,60/11,74/−1,01/0,688/0,486 no VitalDB; o ativo, 7,03/11,08/0,79/0,784/0,548 e 12,43/18,80/1,40/0,024/0,398 (Tabela 4). Três dos quatro MAE ficam abaixo das 10 unidades de variabilidade do monitor [Harada et al. 2021]; o ativo no VitalDB (12,43) a ultrapassa, com P_K no acaso. No mesmo corpus, a entropia amostral reportou MAE 5,22 [Liu et al. 2018] (baseline aqui: 8,86 agrupado), e um modelo contemporâneo maior (TCN-BiLSTM com atenção, 1,07M parâmetros, Huber $\delta = 5$) reportou 4,499 por segmentos e $6,03 \pm 0,38$ em GroupK-Fold com EWMA e CCC 0,819 [Sukriti et al. 2026]; este trabalho (0,15M parâmetros, dez épocas, Smooth L1) fica em 6,69–7,03 brutos. A comparação é de ordem de grandeza: diferem normalização, seleção da suavização, agregação e medida de acordo, e lá a diferença entre kernels não foi significativa (Friedman $p = 0,453$).

Tabela 4. Comparação retrospectiva nos benchmarks históricos; 5 casos no benchmark Figshare e 15 no VitalDB; MAE em pontos BIS; IC 95% por bootstrap agrupado por caso; o RF espectral viu apenas o Figshare.

Benchmark	Modelo (fontes vistas)	MAE (IC 95%)	Pearson (IC 95%)	P_K (IC 95%)
Figshare	ativo (Figshare)	7,03 (6,38–8,24)	0,784 (0,703–0,881)	0,773 (0,679–0,828)
Figshare	misto (Figshare+VitalDB)	6,69 (5,65–8,53)	0,818 (0,751–0,890)	0,774 (0,676–0,835)
VitalDB	ativo (Figshare)	12,43 (11,05–14,45)	0,024 (−0,126–0,193)	0,515 (0,434–0,581)
VitalDB	misto (Figshare+VitalDB)	8,60 (7,57–9,95)	0,688 (0,606–0,752)	0,672 (0,591–0,737)
VitalDB	RF espectral	13,62 (11,98–16,01)	−0,036 (−0,162–0,111)	0,502 (0,447–0,551)

O baseline espectral também foi reavaliado nos 15 casos VitalDB, com o mesmo

ajuste e protocolo: MAE 13,62 (11,98–16,01), Pearson $-0,04$ e P_K 0,502, no nível do acaso, e a CNN ativa ainda o supera ($\Delta\text{MAE} -1,19$; IC $-2,13$ – $-0,34$); o colapso no transporte não é específico da CNN. No bootstrap pareado por caso ($\Delta = \text{ativo} - \text{misto}$), o misto melhora o VitalDB ($\Delta\text{MAE} +3,83$, IC $2,95$ – $4,94$; $\Delta P_K -0,157$, IC $-0,216$ – $-0,083$; 14/15 casos, $p < 0,001$), enquanto no Figshare MAE e P_K não sustentam ganho ($\Delta\text{MAE} 0,34$, IC $-0,28$ – $0,81$; ΔP_K IC $-0,013$ – $0,007$).

No VitalDB, o misto venceu em 14 dos 15 casos pareados (piora de 0,67 ponto só no caso 16; Figura 3c): ganho heterogêneo, que descreve adaptação após exposição ao domínio, não transporte.

4.3. Probabilidade de predição P_K

No Figshare, ativo e misto têm P_K idêntico (0,773 contra 0,774): o misto reduz MAE e eleva Pearson sem mudar a ordenação (Tabela 4, Figura 4). No VitalDB, o ativo fica no acaso (0,515) e o misto em 0,672; por caso, medianas 0,48 e 0,67 [Smith et al. 1996].

4.4. Bootstrap agrupado e sensibilidade ao offset

A Tabela 4 reúne os intervalos de 95%; na Figura 5, as barras são réplicas e os marcadores, as métricas observadas.

Na grade de offset (-20 a $+20$ s, sem retreino), o MAE variou de 7,22 a 6,76 (Figura 6): tendência pós-hoc, sem valor causal e sem mudar o offset zero [Pilge et al. 2006].

4.5. Experimento fatorial inspirado no modelo contemporâneo

Quatro braços novos foram treinados do zero no Figshare (mesmo split, seed 42): A (reprodução); B (A com winsor $\pm 200 \mu V$ e clip $\pm 300 \mu V$); C (B com Huber $\delta = 5$, até 120 épocas, batch 64); D (C com z-score por sujeito, split-safe). Avaliados nos mesmos benchmarks, A reproduziu o histórico (7,03/12,64), B piorou o Figshare (8,19, viés $-3,17$), C foi o único ganho real (6,63; IC 6,03–7,67; CCC 0,820) sem mover o VitalDB (12,61), e D elevou Pearson/CCC (0,833/0,830) sem reduzir o MAE (7,14; VitalDB 12,41). Nenhum braço restaurou o transporte (Tabela 5).

Tabela 5. Braços fatoriais novos (brutos, sem EWMA); MAE em pontos BIS; IC 95% por bootstrap agrupado por caso; CCC é o coeficiente de Lin.

Benchmark	Braço	MAE (IC 95%)	Pearson	CCC	P_K
Figshare	A (reprodução)	7,03 (6,36–8,27)	0,780	0,777	0,773
Figshare	B (winsor)	8,19 (6,78–10,01)	0,699	0,661	0,758
Figshare	C (Huber+longo)	6,63 (6,03–7,67)	0,824	0,820	0,780
Figshare	D (z por sujeito)	7,14 (5,75–7,86)	0,833	0,830	0,772
VitalDB	A (reprodução)	12,64 (11,38–14,43)	0,056	0,051	0,524
VitalDB	B (winsor)	12,04 (10,89–13,74)	0,238	0,194	0,528
VitalDB	C (Huber+longo)	12,61 (11,40–14,22)	0,145	0,134	0,553
VitalDB	D (z por sujeito)	12,41 (11,35–13,67)	0,185	0,168	0,536

O treino longo aproxima esta cadeia da faixa publicada (6,63 contra $6,03 \pm 0,38$), mas o transporte genuíno Figshare–VitalDB segue ausente (12,4–12,6 contra 8,60 do misto, que viu a fonte). O CCC acompanha o Pearson (fenda máxima de 0,04), salvo no B com viés alto.




Figura 3. Agregados por janela e MAE pareado por caso; em (c), cada ponto é um caso e linhas à esquerda indicam menor MAE do misto.




Figura 4. Probabilidade de predição P_K , ativo vs. misto.




Figura 5. Bootstrap agrupado por caso.




Figura 6. Sensibilidade ao offset do rótulo; eixos ampliados (variação total $\leq 0,5$ ponto de MAE e 0,04 de Pearson).

4.6. Suavização EWMA das predições

O EWMA reduz o MAE no Figshare (ativo 7,03 para 5,91; misto 6,69 para 5,68; span 10 como referência, lag médio de 22 s) e, no VitalDB, só o misto responde (8,60 para 7,89; IC 6,86–9,38; P_K 0,703): onde a ordenação morreu (ativo), suavizar não ressuscita (Tabela 6, Figura 7). Parte do ganho é esperada (alvo autocorrelacionado; o baseline também melhora), e o ICC do misto sobe de 0,81 para 0,86 no Figshare e de 0,67 para 0,71 no VitalDB. O misto suavizado (5,68–5,84) situa-se na faixa dos trabalhos no corpus [Liu et al. 2018, Sukriti et al. 2026], com 0,15M parâmetros e sem ranking.

Tabela 6. Efeito do EWMA causal por caso; MAE em pontos BIS; predições congeladas, sem retreino.

Benchmark	Braço	Bruto	Span 5	Span 10	Span 15
Figshare	ativo	7,03	6,39	6,10	5,91
Figshare	misto	6,69	6,11	5,84	5,68
Figshare	RF espectral	8,86	7,86	7,56	7,38
VitalDB	ativo	12,43	12,11	12,06	12,06
VitalDB	misto	8,60	7,95	7,89	7,93
VitalDB	RF espectral	13,62	12,75	12,62	12,58




Figura 7. Varredura de spans do EWMA causal por braço: MAE e P_K no Figshare e no VitalDB.

4.7. Corpus e calibração

O corpus tem 59 casos: 33 elegíveis (23 Figshare e dez VitalDB), 11 em quarentena e 15 VitalDB congelados para o benchmark, dos quais 9 reprovam nos gates internos por desenho (Figura 8). No treino do ativo, a perda cai de 6,2 para 4,7 em dez épocas (melhor validação na época 3); a inclinação predito–referência cai de 0,72 no Figshare ativo para 0,02 no VitalDB ativo, com o misto recuperando 0,55 (Figura 9).

5. Discussão e limitações

A degradação do ativo do Figshare para o VitalDB é evidência interna de sensibilidade à troca de fonte, não prova de qual diferença (equipamento, ganho, montagem, população ou BIS) a causou. A redução de erro do misto é compatível com adaptação após incorporar participantes VitalDB; como o benchmark é da mesma fonte e já havia sido observado, ele gera hipótese para uma nova coorte travada, não generalização externa [Lee et al. 2022, Collins et al. 2024, International Medical Device Regulators Forum 2025].

Os agregados por janela privilegiam cirurgias longas (medianas por caso acima do agregado em todos os braços); a referência de 10 unidades é escala de concordância do monitor, não limiar para MAE [Harada et al. 2021]. Concordância e calibração são exploratórias [Collins et al. 2024, Archer et al. 2021].

O bootstrap cobre só a reamostragem dos casos disponíveis; n pequeno e reuso do benchmark impedem leitura confirmatória [Field and Welsh 2007, Archer et al. 2021, Moons et al. 2025]; a avaliação é pré-clínica [Vasey et al. 2022].

O alvo BIS é sensível a EMG, fármacos e atrasos; baixo erro não equivale a medir consciência [Schuller et al. 2015, Hans et al. 2005, Pilge et al. 2006]. A banda inclui gama frontal e o *notch* fixo pode não valer para cada centro; gates e faixas são heurísticas sem validação clínica [Garbe et al. 2026].




Figura 8. Composição e qualidade do corpus (59 casos).




Figura 9. Treinamento do ativo e calibração por braço.

A leitura ordinal separa dois diagnósticos: no VitalDB o ativo tem P_K no acaso e o misto eleva o Pearson sem mover o P_K no Figshare, o que não caracteriza ganho de ordenação [Smith et al. 1996]. O EWMA é pós-hoc e não substitui os números brutos; a comparação com publicados situa ordem de grandeza, sem ranking. A amostragem do ativo não foi registrada, limitação histórica [Collins et al. 2024].

6. Conclusão

O BrainSniffer estima uma referência BIS a partir de EEG frontal de forma reproduzível. O ativo superou o baseline internamente, mas perdeu associação no VitalDB; o misto reduziu o erro após exposição ao domínio, sem independência confirmatória. Com EWMA exploratório, o misto alcança 5,68–5,84 no Figshare (dentro das 10 unidades do monitor [Harada et al. 2021]), e o treino longo com Huber chega a 6,63 brutos com 0,15M parâmetros. Resultados retrospectivos, limitados por rótulo, casos, reuso de benchmarks e imputação.

A contribuição defensável é uma base auditável para formular e testar hipóteses, não um sistema clínico. O software não mede consciência, não prescreve dose, não controla bomba e não deve acionar alarme ou conduta; uma futura alegação de generalização exigiria avaliação independente [Collins et al. 2024].

Disponibilidade

Código em <https://github.com/Bruno-BRG/brainsniffer> (MIT); dados não redistribuídos; relatórios com hashes.

Referências

- Archer, L., Snell, K. I. E., Ensor, J., Hudda, M. T., Collins, G. S., and Riley, R. D. (2021). Minimum sample size for external validation of a clinical prediction model with a continuous outcome. *Statistics in Medicine*, 40(1):133–146. DOI: 10.1002/sim.8766.
- Avidan, M. S., Jacobsohn, E., Glick, D., et al. (2011). Prevention of intraoperative awareness in a high-risk surgical population. *New England Journal of Medicine*, 365:591–600. DOI: 10.1056/NEJMoa1100403.
- Avidan, M. S., Zhang, L., Burnside, B. A., et al. (2008). Anesthesia awareness and the bispectral index. *New England Journal of Medicine*, 358:1097–1108. DOI: 10.1056/NEJMoa0707361.
- Collins, G. S., Moons, K. G. M., Dhiman, P., et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378. DOI: 10.1136/bmj-2023-078378.
- Connor, C. W. (2022). Open reimplementations of the BIS algorithms for depth of anesthesia. *Anesthesia & Analgesia*, 135(4):855–864. DOI: 10.1213/ANE.0000000000006119.
- Dahaba, A. A., Xue, J. X., Zhao, G. G., Liu, Q. H., et al. (2010). BIS-vista occipital montage in patients undergoing neurosurgical procedures during propofol-remifentanyl anesthesia. *Anesthesiology*, 112(3):645–651. DOI: 10.1097/ALN.0b013e3181cf4111.

- Field, C. A. and Welsh, A. H. (2007). Bootstrapping clustered data. *Journal of the Royal Statistical Society: Series B*, 69(3):369–390. DOI: 10.1111/j.1467-9868.2007.00593.x.
- Garbe, J., Nguyen, Q. V., Kantelhardt, J. W., Dünninghaus, F., Erffmeier, K., Seeliger, K., and Schmid, T. (2026). DOSE-I: A multimodal biosignal dataset of procedural sedation for endoscopy. Dataset, v1, 171 gravações; licença CC BY 4.0 com acordo de uso; escala MOAA/S.
- Hans, P., Dewandre, P.-Y., Brichant, J. F., and Bonhomme, V. (2005). Comparative effects of ketamine on bispectral index and spectral entropy of the electroencephalogram under sevoflurane anaesthesia. *British Journal of Anaesthesia*, 94(3):336–340. DOI: 10.1093/bja/aei047.
- Harada, H., Muta, S., Kakuma, T., et al. (2021). Accuracy of BIS monitoring using a novel interface device connecting conventional needle-electrodes and BIS sensors during frontal neurosurgical procedures. *PLoS ONE*, 16(10):e0258647. DOI: 10.1371/journal.pone.0258647.
- International Medical Device Regulators Forum (2025). Good machine learning practice for medical device development: Guiding principles. IMDRF/AIML WG/N88 FINAL:2025. Final de 29 jan. 2025. Portal: <https://www.imdrf.org>.
- Johansen, J. W. and Sebel, P. S. (2000). Development and clinical application of electroencephalographic bispectrum monitoring. *Anesthesiology*, 93(5):1336–1344.
- Lee, H.-C., Park, Y., Yoon, S. B., Yang, S. M., Park, D., and Jung, C.-W. (2022). VitalDB, a high-fidelity multi-parameter vital signs database in surgical patients. *Scientific Data*, 9:279. DOI: 10.1038/s41597-022-01411-5.
- Liu, Q., Ma, L., Fan, S.-Z., Abbod, M. F., and Shieh, J.-S. (2018). Sample entropy analysis for the estimating depth of anaesthesia through human EEG signal at different levels of unconsciousness during surgeries. *PeerJ*, 6:e4817.
- Ma, L. (2017). EEG and BIS raw data. Dataset, v1, 24 arquivos; licença CC BY 4.0.
- Moons, K. G. M. et al. (2025). PROBAST+AI: an updated quality, risk of bias, and applicability assessment tool for prediction models using regression or artificial intelligence methods. *BMJ*, 388:e082505. DOI: 10.1136/bmj-2024-082505.
- Myles, P. S., Leslie, K., McNeil, J., Forbes, A., and Chan, M. T. V. (2004). Bispectral index monitoring to prevent awareness during anaesthesia: the B-Aware randomised controlled trial. *The Lancet*, 363:1757–1763. DOI: 10.1016/S0140-6736(04)16300-9.
- Nsugbe, E. and Connelly, S. (2022). Multiscale depth of anaesthesia prediction for surgery using frontal cortex electroencephalography. *Healthcare Technology Letters*, 9:43–53. DOI: 10.1049/htl2.12025.
- Park, Y., Han, S.-H., Byun, W., Kim, J.-H., Lee, H.-C., and Kim, S.-J. (2020). A real-time depth of anesthesia monitoring system based on deep neural network with large EDO tolerant EEG analog front-end. *IEEE Transactions on Biomedical Circuits and Systems*, 14:825–837. DOI: 10.1109/TBCAS.2020.2998172.

- Pilge, S., Zanner, R., Schneider, G., Blum, J., Kreuzer, M., and Kochs, E. F. (2006). Time delay of index calculation: analysis of cerebral state, bispectral, and Narcotrend indices. *Anesthesiology*, 104(3):488–494. DOI: 10.1097/00000542-200603000-00016.
- Saeb, S., Lonini, L., Jayaraman, A., Mohr, D. C., and Kording, K. P. (2017). The need to approximate the use-case in clinical machine learning. *GigaScience*, 6. DOI: 10.1093/gigascience/gix019.
- Schuller, P. J., Newell, S., Strickland, P. A., and Barry, J. J. (2015). Response of bispectral index to neuromuscular block in awake volunteers. *British Journal of Anaesthesia*, 115(Suppl 1):i95–i103. DOI: 10.1093/bja/aev072.
- Shi, M., Huang, Z., Xiao, G., Xu, B., Ren, Q., and Zhao, H. (2023). Estimating the depth of anesthesia from EEG signals based on a deep residual shrinkage network. *Sensors*, 23(2):1008. DOI: 10.3390/s23021008.
- Shiraishi, T., Uchino, H., Sagara, T., and Ishii, N. (2004). A comparison of frontal and occipital bispectral index values obtained during neurosurgical procedures. *Anesthesia & Analgesia*, 98(6):1773–1775. DOI: 10.1213/01.ANE.0000121344.69058.09.
- Smith, W. D., Dutton, R. C., and Smith, N. T. (1996). Measuring the performance of anesthetic depth indicators. *Anesthesiology*, 84(1):38–51. DOI: 10.1097/00000542-199601000-00005.
- Sukriti, Kriplani, C., Kumar, S., and Singh, A. (2026). Predicting depth of anaesthesia from single-channel EEG using a deep TCN-BiLSTM-attention model with EWMA. *Scientific Reports*, 16:25470. DOI: 10.1038/s41598-026-54608-8.
- Vasey, B., Nagendran, M., Campbell, B., Clifton, D. A., et al. (2022). Reporting guideline for the early-stage clinical evaluation of decision support systems driven by artificial intelligence: DECIDE-AI. *Nature Medicine*, 28:924–933. DOI: 10.1038/s41591-022-01772-9.
- VitalDB (2026). Open dataset: overview and track list. <https://vitaldb.net/dataset/>. Licença CC BY-NC-SA 4.0 e acordo de uso de dados.