

BrainSniffer: um protótipo reproduzível para estimativa da profundidade anestésica a partir de EEG

Nome do Autor¹

¹Curso de Computação – Nome da Instituição
Cidade – Estado – Brasil

email@exemplo.com

Abstract. *This paper presents BrainSniffer, an open research prototype for estimating an operational anesthesia-depth reference from frontal electroencephalography (EEG). The system audits a mixed development corpus from Figshare and VitalDB, applies documented causal preprocessing, trains a compact one-dimensional convolutional neural network (CNN), and exposes replay and laboratory streaming interfaces. Evaluation is performed by case- or subject-level split, avoiding leakage when adjacent windows or reoperations are distributed across partitions. In a fixed exploratory comparison, the mixed candidate obtained MAE 6.69 and Pearson correlation 0.818 in a five-case Figshare holdout and MAE 8.60 and Pearson correlation 0.688 in 15 frozen VitalDB cases, compared with 7.03/0.784 and 12.43/0.024 for the active checkpoint. The prototype is not a clinical decision system and does not prescribe anesthetic dose; it provides an auditable basis for future validation with real hardware, anesthesiology supervision, ethics approval, and a prospective protocol [Ma 2017, Lee et al. 2022, Collins et al. 2024].*

Resumo. *Este trabalho apresenta o BrainSniffer, um protótipo aberto de pesquisa para estimar, a partir de eletroencefalografia (EEG) frontal, uma referência operacional relacionada à profundidade anestésica. O sistema audita um corpus de desenvolvimento misto de Figshare e VitalDB, aplica pré-processamento causal documentado, treina uma rede neural convolucional unidimensional (CNN) compacta e oferece interfaces de replay e streaming em laboratório. A avaliação usa separação por caso ou sujeito para evitar vazamento entre janelas da mesma cirurgia e reoperações. Na comparação exploratória com holdouts fixos, o candidato misto obteve MAE 6,69 e Pearson 0,818 no holdout Figshare e MAE 8,60 e Pearson 0,688 nos 15 casos VitalDB congelados, contra 7,03/0,784 e 12,43/0,024 do checkpoint ativo. O protótipo não é um sistema de decisão clínica, não recomenda dose e requer validação futura com hardware real, supervisão de anestesiologia, ética e protocolo prospectivo [Ma 2017, Lee et al. 2022, Collins et al. 2024].*

Palavras-chave: EEG; anestesia; BIS; CNN; aprendizado profundo; tempo real; validação por paciente.

1. Introdução

A avaliação do componente hipnótico da anestesia é um problema de sinais fisiológicos com implicações clínicas e técnicas. O EEG varia com agente anestésico, idade,

comorbidades, estímulo cirúrgico, atividade muscular, montagem dos eletrodos e qualidade da aquisição. Monitores de EEG processado, como o BIS, oferecem uma referência operacional útil, mas seus valores dependem do algoritmo, da instrumentação e do contexto. A literatura enfatiza que um índice processado não deve ser interpretado isoladamente como medida universal de consciência ou como substituto do julgamento clínico [Hajat et al. 2017, Connor 2022].

Ao mesmo tempo, estudos de aprendizado profundo mostram que redes convolucionais podem extrair informação temporal e espectral de EEG para tarefas de estimativa de profundidade anestésica [Nsugbe and Connelly 2022, Park et al. 2020, Shi et al. 2023]. O desafio, porém, não é apenas obter uma métrica alta em janelas de um conjunto de dados. Janelas adjacentes da mesma cirurgia são correlacionadas; portanto, uma divisão aleatória por janela pode inflar artificialmente a generalização. Também é necessário tratar explicitamente artefatos, atrasos do monitor, mudança de equipamento, perda de amostras e incerteza de domínio [Hajat et al. 2017, Collins et al. 2024].

Este trabalho descreve o BrainSniffer, uma implementação em Python 3.12 que organiza essas preocupações em um pipeline reproduzível. O objetivo do protótipo é avaliar se uma CNN compacta consegue estimar um valor contínuo semelhante ao BIS e derivá-lo em estágios de pesquisa, preservando a distinção entre previsão de um rótulo de monitor e avaliação clínica do paciente. As contribuições são [FDA, Health Canada and MHRA 2021, Vasey et al. 2022]:

- um fluxo reproduzível de download, integridade, pré-processamento causal e treinamento;
- uma avaliação agrupada por caso, com baseline espectral e métricas contínuas e discretas;
- um caminho de replay e uma interface de streaming por Lab Streaming Layer (LSL), com auditoria e abstenção sob baixa qualidade;
- um corpus misto auditável, com VitalDB tratado no desenvolvimento, holdout externo congelado e decisão explícita sobre uma terceira fonte incompatível.

2. Fundamentação e trabalhos relacionados

O corpus inicial é o conjunto “EEG and BIS raw data”, disponibilizado por Ma no Figshare, que associa EEG frontal a valores BIS [Ma 2017]. O trabalho de Nsugbe e Connelly descreve problema relacionado usando EEG frontal amostrado a 128 Hz, valores BIS em intervalos de 5 s e faixas de pesquisa derivadas do índice [Nsugbe and Connelly 2022]. Esses elementos orientaram a taxa, o tamanho de janela e a apresentação dos estágios no BrainSniffer, sem reutilizar como validação os resultados publicados por outros autores [Ma 2017, Nsugbe and Connelly 2022].

Abordagens anteriores incluem decomposição multiescala, redes convolucionais e arquiteturas de supressão de ruído. O AnesNET, por exemplo, combina uma cadeia de aquisição e uma rede profunda para monitoramento em tempo real [Park et al. 2020]; o trabalho de Shi et al. investiga uma rede de residual shrinkage para estimativa de profundidade anestésica [Shi et al. 2023]. Neste TCC, a escolha é mais conservadora: uma CNN 1-D pequena sobre a janela temporal pré-processada, acompanhada de um baseline espectral auditável. Essa escolha permite medir o ganho da rede antes de adicionar atenção, decomposição ou modelos multitarefa [Park et al. 2020, Shi et al. 2023].



Figura 1. Pipeline do BrainSniffer e a barreira de segurança de engenharia.
Fonte: elaboração própria a partir das decisões de projeto e dos princípios de desenvolvimento documentados em [FDA, Health Canada and MHRA 2021, Lab Streaming Layer 2026].

O BIS é um índice proprietário. Uma reimplementação aberta dos algoritmos do BIS é relevante para discutir auditabilidade, mas não transforma uma rede treinada sobre o rótulo BIS em uma reimplementação certificada do monitor [Connor 2022]. A revisão de Hajat, Ahmad e Andrzejowski também destaca artefatos, paralisia, agentes farmacológicos e contexto clínico como fontes de interpretação inadequada [Hajat et al. 2017]. Por isso, a interface do BrainSniffer utiliza a expressão “referência BIS estimada” e exhibe qualidade e origem do dado [Connor 2022, Hajat et al. 2017].

3. Materiais e métodos

3.1. Dados e tarefa de predição

O downloader consulta a API do Figshare, confere tamanho e MD5 do manifesto e armazena os arquivos de forma atômica. O corpus contém 24 casos anônimos. O caso 24 foi reprovado pelo gate padrão de qualidade por apresentar escala de amplitude incompatível com os demais arquivos: 99,87% das amostras ficaram fora do limite de aproximadamente $\pm 62,5$ observado no corpus. Como não existe metadado confiável para converter essa escala, o caso não é reinserido silenciosamente; o modo de qualidade zero fica restrito à auditoria exploratória [Ma 2017].

Cada janela contém 640 amostras, correspondentes a 5 s em 128 Hz. O rótulo contínuo é o valor BIS associado ao início da janela no modo padrão, com `label_offset_seconds=0`. O pipeline permite registrar explicitamente um deslocamento para estudos de sensibilidade, pois um monitor processado pode apresentar atraso e suavização. Valores fora de $[0, 100]$, não finitos ou associados a janelas abaixo do limiar de qualidade são descartados [Ma 2017, Nsugbe and Connolly 2022, Hajat et al. 2017].

Para a análise discreta, o valor contínuo é convertido nos quatro estágios mostrados na Tabela 1. A conversão é um recurso de interpretação e avaliação; não é uma classificação clínica independente [Nsugbe and Connelly 2022, Hajat et al. 2017].

Tabela 1. Estágios de pesquisa derivados do valor BIS [Nsugbe and Connelly 2022].

Estágio	Intervalo	Interpretação no protótipo
Profundo	[0, 40)	referência de pesquisa
Geral	[40, 60)	referência de pesquisa
Leve	[60, 80)	referência de pesquisa
Acordado	[80, 100]	referência de pesquisa

3.2. Pré-processamento causal e modelo

O sinal é limitado a uma faixa de segurança, filtrado entre 0,5 e 45 Hz e submetido a notch de 50 Hz. A escala de amplitude é registrada na configuração do checkpoint. O treinamento e o replay usam o mesmo pré-processador causal, preservando o estado do filtro entre chunks e por caso. Uma rota zero-phase existe apenas para análise offline explícita; ela não é usada no caminho de streaming, pois teria acesso a amostras futuras [Nsugbe and Connelly 2022, Park et al. 2020].

O score de qualidade combina verificações de finitude, saturação e linha plana. O limiar padrão é 0,20. Abaixo desse limiar, a janela não entra no treinamento e a inferência pode emitir ABSTAIN, sem valor BIS visível. O score é uma barreira heurística de engenharia, não uma confiança calibrada e não deve acionar dose, alarme ou conduta [FDA, Health Canada and MHRA 2021, Vasey et al. 2022].

A entrada da rede tem forma (batch, 1, 640). A CNN possui quatro blocos convolucionais 1-D com normalização, ativação GELU e pooling. Em seguida, utiliza pooling adaptativo, camadas densas e dropout. A saída é limitada ao intervalo [0, 100] por uma sigmoide escalada. O treinamento usa perda Smooth L1. A arquitetura foi mantida compacta para permitir comparação com um baseline e medição de latência; não se afirma que ela seja superior a redes temporais dilatadas, atenção, espectrogramas ou modelos multitarefa [Park et al. 2020, Shi et al. 2023].

O baseline espectral extrai potência absoluta e relativa nas bandas delta, teta, alfa, beta e gama, frequência de borda de 90%, entropia espectral, RMS e comprimento de linha. Um Random Forest recebe essas características. CNN e baseline usam as mesmas janelas, a mesma separação por caso e o mesmo pré-processamento causal [Nsugbe and Connelly 2022, Hajat et al. 2017].

3.3. Corpus misto e gates de qualidade

O manifesto do corpus reúne 24 casos Figshare no pool de desenvolvimento, 20 casos VitalDB candidatos ao treino e 15 casos VitalDB mantidos como avaliação externa congelada. Depois da auditoria, 23 casos Figshare e 10 VitalDB ficaram elegíveis, 11 casos de desenvolvimento foram colocados em quarentena e 55.471 janelas permaneceram disponíveis para treinamento. O identificador de grupo usa `subjectid` quando disponível e um identificador prefixado por fonte como fallback, reduzindo o risco de vazamento por reoperação [Ma 2017, Lee et al. 2022, VitalDB 2026, VitalDB PhysioNet 2026].

O gate padrão exige pelo menos 90% de amostras EEG finitas, nenhuma lacuna não finita maior que 2 s, qualidade global mínima de 0,35, pelo menos 80% de BIS válido e qualidade mínima de 0,20 por janela. Lacunas longas são quarentenadas, não preenchidas silenciosamente para fabricar uma trajetória de treino; a política separa imputação offline de rejeição no caminho online e deixa a decisão revisável no manifesto [VitalDB 2026, Lee et al. 2022, FDA, Health Canada and MHRA 2021].

Uma terceira fonte foi catalogada, mas não foi misturada à regressão EEG-BIS. O DOSE-I oferece EEG frontotemporal de dois canais e rótulos como MOAA/S e estado de consciência em sedação com propofol; convertê-los para BIS criaria um alvo incompatível. O uso futuro deve ser uma tarefa ordinal ou multitarefa separada, com adaptador, divisão por pessoa e protocolo próprios [DOSE-I 2026, Collins et al. 2024].

3.4. Protocolo de avaliação

Os casos são embaralhados com semente 42 e divididos em treinamento, validação e teste, mantendo todas as janelas de um caso em uma única partição. As métricas contínuas são erro absoluto médio (MAE), raiz do erro quadrático médio (RMSE), viés e correlação de Pearson. Essa unidade de separação é uma decisão conservadora para reduzir dependência entre janelas da mesma cirurgia [Collins et al. 2024, Vasey et al. 2022]:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (1)$$

As métricas discretas são acurácia e macro-F1 nos quatro estágios. O número de casos, o número de janelas, a semente e os hashes dos arquivos são registrados nos relatórios JSON. Quando há pelo menos dois casos de teste, o projeto também calcula bootstrap agrupado por caso para indicar incerteza preliminar [Collins et al. 2024, Vasey et al. 2022].

3.5. Inferência em fluxo e auditoria

O replay mantém uma janela circular de 5 s e emite uma previsão a cada 1 s. O valor bruto, o valor suavizado por EWMA, a qualidade, o timestamp e a origem do dado permanecem separados. A interface LSL utiliza descoberta de streams, chunks, timestamps e seleção de canal. LSL é uma camada de transporte e sincronização para pesquisa, não um driver de monitor nem uma garantia de que o canal seja EEG válido [Lab Streaming Layer 2026, Kothe et al. 2025].

Antes e durante o consumo, o sistema audita metadados, taxa de amostragem, timestamps, lacunas, pontos não finitos, saturação, linha plana e qualidade. Em caso de silêncio superior ao timeout de 2 s ou de falha de auditoria, a saída fica stale/abstain e o estado causal é reiniciado. Essa política evita manter uma estimativa baseada em janela antiga. A latência medida com sinal sintético representa somente o custo de software na máquina local, não a latência de um sistema clínico [FDA, Health Canada and MHRA 2021, Vasey et al. 2022].

4. Interface e reprodutibilidade

O aplicativo Dash + Plotly organiza o fluxo em abas de visão geral, trajetória completa, replay causal, dados da rede, corpus, estatística, método e cobertura. A visão geral confronta o checkpoint ativo com o holdout externo; a aba Corpus mostra fontes, gates, quarentena e comparação do candidato misto; o replay revela EEG, BIS, predição bruta, suavização e qualidade sem recalculer a rede a cada avanço do navegador. A aba LSL exige uma ficha de entrada com fabricante, modelo, montagem, unidade, taxa declarada, canal escolhido, bridge e responsável pela sessão [FDA, Health Canada and MHRA 2021, Vasey et al. 2022].

O VitalDB é um banco perioperatório independente, com milhares de casos e numerosos tracks de sinais, incluindo dados relacionados à cirurgia e à anestesia [Lee et al. 2022, VitalDB 2026]. O BrainSniffer baixa seletivamente BIS/EEG1_WAV e BIS/BIS, preserva a unidade declarada e inclui no desenvolvimento somente os casos aprovados pelo manifesto; os 15 casos externos permanecem congelados. Assim, a mistura testa robustez de domínio sem apagar a diferença entre aparelho, ganho, montagem ou população [Lee et al. 2022, VitalDB 2026, VitalDB PhysioNet 2026].

5. Resultados

Os resultados desta seção são uma execução de engenharia reproduzível e não uma validação clínica. O treinamento completo usou 23 casos efetivos, após o gate de qualidade, e 31.055 janelas válidas. A divisão produziu 13 casos de treinamento, 5 de validação e 5 de teste. A Tabela 2 resume o holdout Figshare conforme a recomendação de explicitar população, partição e unidade de análise [Ma 2017, Collins et al. 2024].

Tabela 2. Holdout Figshare por caso, seed 42, CNN causal [Ma 2017, Collins et al. 2024].

Item	Resultado
Casos treinamento / validação / teste	13 / 5 / 5
Janelas treinamento / validação / teste	15.894 / 9.638 / 5.523
MAE / RMSE	7,03 / 11,08
Viés / Pearson	0,79 / 0,784
Acurácia / macro-F1	0,585 / 0,548

Na mesma partição, o baseline espectral obteve MAE 8,86, RMSE 13,23, correlação 0,667, acurácia 0,540 e macro-F1 0,480. A CNN apresentou vantagem nas métricas contínuas desse split, enquanto o resultado por estágio não deve ser tratado como evidência de superioridade geral. Não houve ajuste de hiperparâmetros, calibração ou seleção de protocolo depois de observar um conjunto externo [Collins et al. 2024].

Para a comparação justa, o candidato misto foi treinado com 28 casos: os cinco casos do holdout Figshare histórico ficaram fora do ajuste, junto com os 15 casos VitalDB externos. A amostragem foi balanceada por grupo e fonte, e o checkpoint recebeu o manifesto e os hashes dos arquivos de entrada [FDA, Health Canada and MHRA 2021, Collins et al. 2024].

No holdout Figshare fixo, o candidato teve MAE 6,69, RMSE 10,67, Pearson 0,818 e macro-F1 0,574, contra 7,03, 11,08, 0,784 e 0,548 do checkpoint ativo. Nos 15

Tabela 3. Composição e comparação do corpus misto em execução exploratória [Ma 2017, Lee et al. 2022, Collins et al. 2024].

Item	Desenvolvimento	Holdout
Casos Figshare	23 elegíveis	5
Casos VitalDB	10 elegíveis	15 congelados
Janelas do candidato fixo	49.948	—
MAE ativo / misto	—	7,03 / 6,69
Pearson ativo / misto	—	0,784 / 0,818

casos VitalDB externos, sem retreino, obteve MAE 8,60, RMSE 11,74, Pearson 0,688 e macro-F1 0,486, contra 12,43, 18,80, 0,024 e 0,398 do ativo. A melhora relativa de MAE foi de aproximadamente 4,8% no Figshare e 30,8% no VitalDB; esses números são exploratórios e não constituem validação clínica [Lee et al. 2022, VitalDB 2026, Collins et al. 2024].




Figura 2. Comparação do checkpoint ativo com o candidato misto nos holdouts Figshare e VitalDB. Fonte: relatórios JSON do projeto; a leitura deve respeitar a mudança de domínio descrita em [Lee et al. 2022, VitalDB 2026].

O bootstrap exploratório de 1.000 reamostragens por caso no holdout estimou Pearson médio 0,789, intervalo de 95% entre 0,703 e 0,881, e MAE médio 7,11, intervalo entre 6,38 e 8,24. Esses intervalos refletem somente a variabilidade dos cinco casos de teste e não substituem uma coorte externa maior [Collins et al. 2024, Vasey et al. 2022].

O benchmark de processamento sintético mediu p50 de 0,57 ms e p95 de 0,79 ms por emissão, com passo de 1 s e CPU local. A medida não inclui aquisição, resampling, rede, visualização, carga do sistema operacional, concorrência ou um dispositivo de EEG; portanto, não é uma garantia de tempo real clínico [FDA, Health Canada and MHRA 2021].

5.1. Sensibilidade exploratória ao alinhamento

O comando `evaluate-offset` reaplicou o checkpoint congelado aos mesmos cinco casos de teste sem retreino, variando apenas o instante do rótulo BIS. Os valores foram MAE 7,22, 7,03 e 6,76 para offsets de -20, 0 e +20 s, respectivamente; a correlação correspondente foi 0,766, 0,784 e 0,799. O crescimento gradual com um rótulo posterior é compatível com uma hipótese de atraso do monitor, mas a análise foi pós-hoc. Portanto, ela não seleciona o offset final nem demonstra uma medida clínica de consciência [Hajat et al. 2017, Nsugbe and Connelly 2022].




Figura 3. Sensibilidade exploratória ao alinhamento do rótulo BIS. Fonte: relatório de offsets do projeto; a tendência não deve ser usada para escolher atraso em pacientes [Hajat et al. 2017, Nsugbe and Connelly 2022].

5.2. Avaliação externa exploratória

Quinze casos VitalDB compatíveis foram normalizados e avaliados sem retreino, totalizando 38.730 janelas. No checkpoint ativo, a CNN obteve MAE 12,43, RMSE 18,80, viés 1,40, correlação 0,024, acurácia de estágio 0,420 e macro-F1 0,398; no candidato misto, obteve 8,60, 11,74, -1,01, 0,688, 0,573 e 0,486, respectivamente. O resultado é uma avaliação out-of-dataset e deve ser reportado junto com a população e a partição, não como validação clínica [Lee et al. 2022, VitalDB 2026, Collins et al. 2024].

O caso 11 foi rejeitado porque não continha simultaneamente os tracks BIS/EEG1_WAV e BIS/BIS. Os diagnósticos agregados encontraram pontos não finitos nos 15 arquivos; eles foram tratados somente na preparação offline das janelas. No caminho online, entradas não finitas são rejeitadas antes do filtro causal. O resultado externo é, portanto, evidência de mudança de domínio e de necessidade de validação, não uma conclusão sobre o VitalDB inteiro [VitalDB 2026, Vasey et al. 2022].

6. Discussão e limitações

O resultado interno demonstra que o software consegue executar download, integridade, treinamento, avaliação, replay e streaming sintético sob um protocolo registrado. Isso




Figura 4. Intervalos exploratórios por caso para Pearson e MAE. Fonte: relatórios JSON do projeto; as linhas representam reamostragem de cirurgias inteiras [Collins et al. 2024, Vasey et al. 2022].

não prova que a CNN mede profundidade anestésica em paciente novo. O corpus inicial é pequeno, usa um canal, depende de um índice processado como referência e pode carregar vieses de aparelho, centro, montagem e população. O BIS também pode ser afetado por artefatos, atividade muscular, fármacos, paralisia e atrasos de processamento [Hajat et al. 2017].

A baixa correlação do checkpoint ativo no VitalDB sem retreino é coerente com a hipótese de mudança de domínio. O ganho do candidato misto é uma evidência exploratória de que dados VitalDB aprovados podem ajudar, mas não autoriza apresentar a métrica interna como generalização. Também não é lícito promover o candidato por uma única execução sem ablação, seeds independentes, partição travada e justificativa de transferência; o projeto mantém o holdout externo separado [Lee et al. 2022, FDA, Health Canada and MHRA 2021, Vasey et al. 2022].

Do ponto de vista de segurança, o aplicativo não controla bombas, não gera recomendação de dose e não aciona alarme clínico. A abstenção sob baixa qualidade reduz uma classe de falhas de software, mas não cria segurança clínica. A próxima etapa deve incluir estudo com hardware específico, verificação de taxa e unidade, sincronização com o monitor, teste de perdas e reconexão, anotação de qualidade e revisão por anestesiológicos [FDA, Health Canada and MHRA 2021, Vasey et al. 2022].

O planejamento de validação segue uma progressão de pesquisa: replay, bancada com sinal conhecido, teste externo travado, modo sombra e somente depois estudo prospectivo supervisionado. Essa postura é consistente com princípios de desenvolvimento de aprendizado de máquina para dispositivos médicos e com orientações de avaliação transparente de sistemas de suporte à decisão [FDA, Health Canada and MHRA 2021, Vasey et al. 2022, Collins et al. 2024].

7. Conclusão

O BrainSniffer fornece uma base em Python 3.12 para investigar estimativa de uma referência BIS a partir de EEG frontal com CNN 1-D, pré-processamento causal, separação por paciente, baseline espectral, interface Dash + Plotly e entrada de pesquisa via LSL. O corpus misto melhorou a execução exploratória nos dois holdouts, mas a avaliação ainda não demonstra transferência automática para novas populações ou hardware [Ma 2017, Lee et al. 2022].

Assim, a contribuição atual é metodológica e de engenharia: tornar explícitos dados, rótulos, qualidade, latência, partições, artefatos e limites de interpretação. Os próximos experimentos devem pré-especificar alinhamento, incluir baseline de entropia e modelos temporais, ampliar a validação externa, calibrar a política de abstenção, medir o hardware alvo e conduzir avaliação prospectiva com equipe de anestesiologia. Até que essas etapas sejam concluídas, o sistema deve permanecer restrito à pesquisa e não pode ser usado para decidir a profundidade anestésica ou a dose de um paciente [FDA, Health Canada and MHRA 2021, Collins et al. 2024].

Agradecimentos

O autor agradece às equipes que disponibilizaram os datasets públicos utilizados para desenvolvimento e avaliação exploratória. Os termos de uso de cada corpus devem ser consultados antes de redistribuição ou novo estudo [Ma 2017, VitalDB 2026].

Referências

- Ma, L. (2017). *EEG and BIS raw data*. Figshare. DOI: 10.6084/m9.figshare.5589841.v1.
- Nsugbe, E. and Connelly, S. (2022). Multiscale depth of anaesthesia prediction for surgery using frontal cortex electroencephalography. *Healthcare Technology Letters*, 9, 43–53.
- Park, Y. et al. (2020). A real-time depth of anesthesia monitoring system based on deep neural network with large EDO tolerant EEG analog front-end. *IEEE Transactions on Biomedical Circuits and Systems*, 14, 825–837.
- Shi, M. et al. (2023). Estimating the depth of anesthesia from EEG signals based on a deep residual shrinkage network. *Sensors*, 23(2), 1008.
- Hajat, Z., Ahmad, N. and Andrzejowski, J. (2017). The role and limitations of EEG-based depth of anaesthesia monitoring in theatres and intensive care. *Anaesthesia*, 72, 38–47.
- Connor, C. W. (2022). Open reimplementations of the BIS algorithms for depth of anesthesia. *Scientific Reports*.
- Lee, H.-C. et al. (2022). VitalDB, a high-fidelity multi-parameter vital signs database in surgical patients. *Scientific Data*, 9.
- VitalDB (2026). Open Dataset: overview, track units and data-use terms. Documentação online.
- VitalDB (2026). VitalDB public clinical data and case-to-subject mapping. PhysioNet.

- DOSE-I (2026). EEG and clinical annotations for propofol sedation. Zenodo. DOI: 10.5281/zenodo.18483292.
- Lab Streaming Layer (2026). Introduction to Lab Streaming Layer. Documentação online.
- Kothe, C. et al. (2025). The Lab Streaming Layer for synchronized multimodal recording. *Frontiers in Neuroscience*.
- FDA, Health Canada and MHRA (2021). Good machine learning practice for medical device development: guiding principles. Guidance online.
- Vasey, B. et al. (2022). Reporting guideline for the early-stage clinical evaluation of decision support systems driven by artificial intelligence: DECIDE-AI. *Nature Medicine*, 28, 924–933.
- Collins, G. S. et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385.