

BrainSniffer: protótipo reproduzível para estimar uma referência BIS a partir de EEG frontal

Bruno Rocha Guimarães¹

¹Ciência da Computação – Centro Universitário Jorge Amado
Salvador, Bahia – Brasil

Abstract. *This paper describes BrainSniffer, a reproducible engineering prototype that estimates a Bispectral Index (BIS) reference label from frontal electroencephalography (EEG). The pipeline uses five-second windows at 128 Hz, a compact one-dimensional convolutional neural network, and partitions grouped by case or subject. The active Figshare-only checkpoint reached mean absolute error (MAE) 7.03 and Pearson correlation 0.784 in a five-case Figshare holdout, but 12.43 and 0.024 in a 15-case VitalDB cross-dataset assessment. A mixed candidate trained with Figshare and part of VitalDB reached 6.69/0.818 on the Figshare benchmark and 8.60/0.688 on the historical VitalDB participant holdout. These results are retrospective and exploratory; Pearson is interpreted as association, not agreement. BrainSniffer neither measures consciousness nor supports clinical decisions, alarms, or drug dosing. Implementation and results are documented in internal artifacts [Guimarães sd].*

Resumo. *Este artigo descreve o BrainSniffer, protótipo de engenharia reproduzível que estima, a partir de eletroencefalografia (EEG) frontal, um rótulo de referência do Índice Bispectral (BIS). O pipeline usa janelas de cinco segundos a 128 Hz, uma rede neural convolucional unidimensional compacta (compact 1-D CNN, `Conv1DDepthEstimator`) e partições agrupadas por caso ou pessoa. O checkpoint ativo, treinado apenas no Figshare, obteve erro absoluto médio (MAE) 7,03 e correlação de Pearson 0,784 em cinco casos Figshare, mas 12,43 e 0,024 em uma avaliação cruzada com 15 casos VitalDB. Um candidato misto, treinado com Figshare e parte do VitalDB, obteve 6,69/0,818 no benchmark Figshare e 8,60/0,688 no holdout histórico VitalDB por participante. Os resultados são retrospectivos e exploratórios; Pearson é tratado como associação, não acordo. O BrainSniffer não mede consciência nem apoia decisão clínica, alarme ou dose. Implementação e resultados constam de artefatos internos [Guimarães sd].*

Palavras-chave: EEG frontal; rótulo BIS; CNN 1-D; validação agrupada; mudança de domínio; reprodutibilidade.

1. Introdução

O Índice Bispectral (Bispectral Index, BIS) é uma saída proprietária calculada a partir da eletroencefalografia (EEG), o registro da atividade elétrica cerebral captada no couro cabeludo. O BIS é apresentado em uma escala de 0 a 100 e é indicado apenas como auxílio, em contexto e sob supervisão definidos, não como medida direta de consciência, de adequação anestésica ou de dose. Sua leitura pode variar com a atividade elétrica muscular (eletromiografia, EMG), o bloqueio neuromuscular, os fármacos usados e o atraso

de processamento; em particular, estudos controlados documentaram queda do índice após bloqueio em voluntários acordados, resposta paradoxal à cetamina e atrasos distintos entre monitores processados [U.S. Food and Drug Administration and Covidien 2024, Connor 2022, Schuller et al. 2015, Hans et al. 2005, Pilge et al. 2006]. Ensaios com protocolos guiados pelo índice também produziram resultados que dependem do grupo de comparação e da população, o que impede extrapolar um único número para benefício clínico universal [Myles et al. 2004, Avidan et al. 2008, Avidan et al. 2011].

Modelos de sinais podem aproximar índices derivados de EEG, e redes profundas já foram estudadas com alvos, canais, populações e equipamentos distintos [Park et al. 2020, Shi et al. 2023]. Entretanto, trechos vizinhos da mesma cirurgia são parecidos entre si: espalhá-los aleatoriamente entre treino e teste cria uma tarefa mais fácil do que aplicar o modelo em um caso novo, nunca visto. Por isso, este trabalho separa os dados por caso ou pessoa. Resultados recentes nesse corpus e evidência metodológica mais ampla mostram que essa unidade de separação altera materialmente a estimativa de desempenho [Sukriti et al. 2026, Saeb et al. 2017].

A pergunta de pesquisa é: quanto uma rede neural convolucional unidimensional compacta (1-D CNN) aproxima o rótulo BIS em casos não usados no ajuste, comparada a um controle mais simples baseado em medidas espectrais (baseline espectral), e como esse desempenho muda entre fontes de dados? Este trabalho apresenta e avalia o BrainSniffer como protótipo reproduzível para arquivos e repetição retrospectiva de gravações (replay). A contribuição é uma cadeia auditável, com partições por grupo, controle espectral, comparação entre fontes e análise de incerteza por caso. O escopo deste TCC é avaliar essa cadeia, não desenvolver um dispositivo médico [Guimarães sd].

Para reduzir a ambiguidade dos nomes usados no restante do artigo, a Tabela 1 resume as fontes vistas no treinamento e os conjuntos de avaliação de cada checkpoint. “Ativo” e “misto” são abreviações desses dois modelos.

Tabela 1. Definição conceitual dos dois checkpoints. O holdout VitalDB do modelo misto é histórico e da mesma fonte já presente no desenvolvimento; portanto, não é validação externa confirmatória.		
Modelo	Treinado com	Avaliado em
Modelo A – Figshare (ativo)	Figshare	Figshare (holdout por caso) e VitalDB (avaliação cruzada de dataset)
Modelo B – misto	Figshare + parte do VitalDB	Figshare (benchmark histórico) e VitalDB (holdout histórico por participante)

2. Fundamentação e trabalhos relacionados

O conjunto “EEG and BIS raw data” reúne 24 casos anônimos com EEG frontal e valores BIS, publicado no repositório Figshare sob licença CC BY 4.0 [Ma 2017]. No mesmo corpus, um estudo anterior usou características multiescala com análise discriminante linear (Linear Discriminant Analysis, LDA); esse trabalho sustenta a descrição do corpus e das faixas, mas não é evidência de rede convolucional [Nsugbe and Connelly 2022]. Em outras configurações, uma rede estimou a concentração anestésica derivada de EEG




Figura 1. Fluxo retrospectivo auditável do BrainSniffer, a partir de arquivos existentes. A separação por grupo impede que janelas do mesmo grupo atravessem partições; no Figshare, o grupo é o caso. O pool elegível de 33 casos não é o corpus fixo de 28 grupos, que exclui os cinco casos históricos e se divide em 16/6/6. As setas finais indicam avaliação, nunca treino. Fontes internas [Guimarães sd]; o benchmark VitalDB do misto não é confirmatório.

com cadeia de aquisição dedicada, enquanto outro estudo estimou o índice de estado do paciente (Patient State Index, PSI) com quatro canais em 18 participantes idosos sedados. Esses estudos demonstram viabilidade técnica em configurações específicas, não comparabilidade direta com o rótulo, o canal ou a população do BrainSniffer [Park et al. 2020, Shi et al. 2023].

O VitalDB é um banco de sinais perioperatórios de milhares de cirurgias e inclui os canais de EEG e de BIS usados aqui (BIS/EEG1_WAV e BIS/BIS) [Lee et al. 2022, VitalDB 2026, Lee and Jung 2022]. O conjunto aberto (vitaldb.net) exige licença CC BY-NC-SA 4.0 e acordo de uso de dados, sem redistribuição. Escala, equipamento, montagem e população diferem do Figshare; por isso, o VitalDB informa a sensibilidade à troca de fonte de dados, sem isolar a causa. O conjunto DOSE-I (Zenodo, CC BY 4.0) não foi incorporado à regressão porque usa uma escala clínica de sedação por observação (Modified Observer’s Assessment of Alertness/Sedation, MOAA/S) e estado de consciência, não conversíveis em BIS [Garbe et al. 2026].

Uma reimplementação aberta do algoritmo do índice ajuda a discutir a transparência do cálculo, mas não torna um regressor treinado contra o BIS equivalente a um monitor nem certificado como tal [Connor 2022]. A independência entre desenvolvimento e avaliação, a descrição de grupos e a análise de calibração e acordo são componentes centrais de relato e avaliação de modelos; para desfecho contínuo, o tamanho da validação deve ser planejado pela precisão desejada, não pelo número de réplicas bootstrap [Collins et al. 2024, Archer et al. 2021].

3. Materiais e métodos

3.1. Fontes, unidades de agrupamento e partições

O manifesto versionado `reports/corpus_manifest.json` registra 59 arquivos: 44 casos no pool de desenvolvimento e 15 casos VitalDB congelados. Após os gates de qualidade, 23 casos Figshare e dez VitalDB ficaram elegíveis, totalizando 33 casos e 55.471 janelas. No Figshare, `subject_id` não está disponível; assim, `case_id` evita compartilhar janelas da mesma cirurgia, mas não permite provar independência entre cirurgias de uma mesma pessoa. No VitalDB, o agrupamento usa `subjectid` e, portanto, reúne reoperações conhecidas [Guimarães sd, Ma 2017, Lee et al. 2022, Lee and Jung 2022].

O checkpoint ativo foi desenvolvido apenas com os 23 casos Figshare elegíveis, divididos com seed 42 em 13 casos de treino, cinco de validação e cinco de teste. O candidato misto fixo excluiu desse desenvolvimento os cinco casos do holdout Figshare histórico e usou 18 grupos Figshare mais dez grupos VitalDB: 28 grupos e 49.948 janelas, com partição registrada de 16/6/6 grupos para treino, validação e teste. O ajuste usa somente 12 casos Figshare e quatro participantes VitalDB (34.792 janelas); a validação usa dois Figshare e quatro VitalDB (7.235 janelas), e o teste interno, quatro Figshare e dois VitalDB (7.921 janelas). Essas contagens, a origem e os hashes estão em `models/brainsniffer_corpus_fixed.json`; dizer “corpus de 28 grupos” não significa que os 28 foram usados no ajuste [Guimarães sd].

Os mesmos cinco casos Figshare foram usados como benchmark histórico dos dois checkpoints. Para o ativo Figshare-only, os 15 casos VitalDB constituem uma avaliação cruzada de dataset. Para o misto, esses 15 participantes não entraram no ajuste, mas vêm da mesma fonte já presente no desenvolvimento; além disso, o benchmark havia sido inspecionado antes da criação do candidato. Consequentemente, ele é descrito como holdout VitalDB histórico, por participante e após exposição ao domínio, não como validação externa confirmatória. Manter o candidato fora do dashboard é uma decisão operacional: não restaura a independência de benchmarks já inspecionados, inclusive o Figshare reutilizado [Guimarães sd, Collins et al. 2024, International Medical Device Regulators Forum 2025].

3.2. Tarefa, pré-processamento e qualidade

Cada exemplo é um trecho curto de EEG: 640 amostras, isto é, uma janela de 5 segundos amostrada a 128 Hz, com passo de 5 s na construção offline. Para início t , o alvo corresponde a $t + \text{offset}$, arredondado ao intervalo do BIS do caso (5 s no Figshare e 1 s nos arquivos VitalDB normalizados). A emissão só pode ocorrer após completar a janela, aproximadamente em $t + 5$ s, além do processamento; com offset zero, não se trata de previsão de um BIS futuro nem de leitura contemporânea ao fim da janela. O pipeline mantém a banda de 0,5–45 Hz, remove a interferência da rede elétrica (notch de 50 Hz) com filtro de quarta ordem e aplica a escala de amplitude registrada, com o rótulo BIS associado ao início da janela (offset padrão 0 s). O filtro usa apenas amostras passadas e presentes (estado causal), preservado por caso e entre blocos; uma rota de fase zero existe somente para análise offline explícita. Essas escolhas estão em `reports/corpus_manifest.json`, `models/brainsniffer_cnn.json` e `models/brainsniffer_corpus_fixed.json`; as fontes externas descrevem

os corpora e o problema, mas não definem esta configuração [Guimarães sd, Ma 2017, Nsugbe and Connelly 2022].

O controle de qualidade do corpus exige, entre outros critérios internos, pelo menos 90% de EEG com valores numéricos válidos (finitos), lacuna inválida máxima de 2 s, qualidade global mínima 0,35, pelo menos 80% de BIS válido e qualidade mínima 0,20 por janela. O caso Figshare 24 permanece em quarentena por escala incompatível. Esses limiares são heurísticas de engenharia ainda não calibradas para risco clínico; no replay, trechos inválidos são rejeitados antes do filtro e trechos de baixa qualidade levam o modelo a se abster. A proveniência dos limiares é exclusivamente `reports/corpus_manifest.json` [Guimarães sd].

Esse controle do corpus de desenvolvimento não se aplica aos 15 casos do benchmark VitalDB histórico. Na construção offline, `make_windows` passa o EEG completo do caso ao pré-processador: valores inválidos (não finitos) são preenchidos por interpolação linear entre vizinhos válidos, repetindo o extremo nas bordas (vetor todo inválido vira zeros), sem limite de duração da lacuna e podendo usar amostras futuras, mesmo quando o filtro seguinte é causal. A qualidade é calculada sobre a janela bruta. O BIS inválido ou fora de $[0, 100]$ é descartado, sem interpolação nessa etapa; antes, a normalização em `src/brainsniffer/data/vitaldb.py` (função `_align_numeric_to_eeg`) ordena, remove tempos duplicados e interpola os pontos BIS válidos para uma grade de 1 s apenas entre o primeiro e o último ponto válido (fora, NaN), sem limite de lacuna nem máscara persistida; aqui, válido significa finito. Como os 15 arquivos históricos contêm EEG inválido, sua avaliação offline difere da política de rejeição do replay. Esse preenchimento pode suavizar lacunas longas e limita a interpretação; política e métricas históricas foram mantidas. Descrição baseada no código e nos relatórios locais, não em recomendação dos datasets [Guimarães sd].

3.3. Modelos e treinamento

A rede histórica é a `Conv1DDepthEstimator`: recebe a janela de 640 amostras em um canal, é treinada com perda Smooth L1 e tem saída sigmoideal escalada para $[0, 100]$. A Tabela 2 explicita a arquitetura compatível em `src/brainsniffer/models/cnn.py` e os parâmetros registrados nos JSON, sem carregar pesos. Recursos posteriores do treinador e arquiteturas opcionais não são atribuídos retroativamente a esses pesos [Guimarães sd].

Tabela 2. Configuração histórica: JSON dos checkpoints ativo e misto fixo; arquitetura compatível no código [Guimarães sd].

Item	Configuração registrada/compatível
Convolucionais (Conv1d)	<i>Channels</i> 1–32–64–128–128; <i>kernel</i> 7, 7, 5, 5; <i>padding</i> 3, 3, 2, 2; <i>stride</i> 1; BatchNorm1d + GELU
<i>Pooling</i> e cabeça	MaxPool1d(2) nos 3 primeiros blocos; AdaptiveAvgPool1d(1); Linear 128–64–1, GELU, dropout 0,20
Treino (ambos)	10 <i>epochs</i> , <i>batch</i> 128, <i>lr</i> 10^{-3} , <i>wd</i> 10^{-4} , <i>seed</i> 42; val/teste 0,20/0,20
Amostragem	Misto: <i>balanced sampling</i> por grupo/fonte; ativo: não registrado
Amplitude e notch	<i>Clip</i> $\pm 100 \mu V$, escala $50 \mu V$, saída em $[-5, 5]$; <i>notch</i> 50 Hz, Q=30
Random Forest	<i>n_estimators</i> =100, <i>max_depth</i> =12, <i>min_samples_leaf</i> =2, <i>random_state</i> =42

A arquitetura compacta permite replay em CPU, mas não implica superioridade sobre redes temporais, atenção ou representações tempo-frequência [Guimarães sd, Park et al. 2020, Shi et al. 2023].

Como controle, o baseline extrai medidas espectrais clássicas (potência por banda, frequência de borda espectral SEF90, entropia espectral, valor eficaz RMS e *line length*) e ajusta uma floresta aleatória (*Random Forest*) nas mesmas janelas e partição do ativo. Detalhes em `reports/spectral_baseline_holdout.json` [Guimarães sd].

3.4. Métricas, incerteza e análises exploratórias

Foram calculados o erro absoluto médio (Mean Absolute Error, MAE), a raiz do erro quadrático médio (Root Mean Squared Error, RMSE), o viés e a correlação de Pearson para o rótulo contínuo, além de acurácia e macro-F1 para quatro faixas de BIS. Em leitura simples: MAE é o erro médio em pontos BIS; RMSE penaliza mais os erros grandes; viés é a diferença média predito menos referência; Pearson mede se as curvas variam juntas (associação, não acordo); macro-F1 é o acerto médio entre faixas. As métricas implementadas em `src/brainsniffer/pipeline/metrics.py` [Guimarães sd] incluem MAE e RMSE, definidos por

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (1)$$

O resultado principal agrega todas as janelas aceitas (casos longos pesam mais), em vez de tirar a média por pessoa. O viés é a média de predito menos referência. As faixas são $[0, 40)$, $[40, 60)$, $[60, 80)$ e $[80, 100]$, aqui lidas com rótulos curtos apenas para comunicação — profunda, geral adequada, leve/transicional e acordado — sem validar limiar clínico. Pearson quantifica associação linear e não acordo; não foram estimados, nesta execução, limites de concordância, coeficiente de concordância ou calibração clínica. As quatro faixas são apenas uma apresentação interna e não constituem classes clínicas independentes [Guimarães sd, Collins et al. 2024].

A análise por zona estratifica essas mesmas faixas pelo BIS verdadeiro: por zona, n , MAE, RMSE, viés e recall (fração com faixa predita correta), além da matriz de confusão 4×4 em ordem profunda–geral–leve–acordado. Um recorte exploratório $\text{BIS} < 20$, subset da profunda, sinaliza risco de padrão isoelétrico/supressão de surtos, sem ser quinta classe ou detector validado. O comando `evaluate-zones` reaproveita janelas e predições dos mesmos benchmarks, sem retreino, nos quatro relatórios `zone_*.json` em `reports/` [Guimarães sd].

O bootstrap estima a incerteza sorteando casos inteiros com reposição, juntando todas as janelas sorteadas e recalculando a métrica. Assim, respeita melhor a dependência dentro de cada caso do que sortear janelas, mas o resultado continua ponderado pela duração. Foram usadas $B = 1.000$ réplicas, seed 42 e percentis 2,5/97,5 para o intervalo de 95%. Com apenas cinco casos Figshare, o intervalo é exploratório; 1.000 réplicas não equivalem a 1.000 casos [Guimarães sd, Field and Welsh 2007, Archer et al. 2021].

A comparação VitalDB também foi calculada por caso, pareando `case_id` e número de janelas em `reports/vitaldb_external_validation.json` e `reports/mixed_vitaldb_external.json`. A sensibilidade registrada em

`reports/offset_sensitivity.json` reaplicou o checkpoint ativo aos mesmos cinco casos Figshare, sem retreino, em uma grade de -20 a $+20$ s. Como a grade foi examinada após o treinamento, ela formula hipótese sobre alinhamento e não escolhe o atraso do rótulo [Guimarães sd, Pilge et al. 2006].

3.5. Replay retrospectivo e trajetória ilustrativa

Replay significa percorrer uma gravação existente, não adquirir EEG: preenche-se um buffer de 5 s e depois emite-se atualização a cada 1 s, separando valor bruto, média móvel exponencial (Exponentially Weighted Moving Average, EWMA), qualidade, instante e origem. O escopo deste TCC é exclusivamente retrospectivo, sem conexão a EEG físico. A implementação em `src/brainsniffer/pipeline/realtime.py` distingue o instante de emissão do alvo histórico no início da janela [Guimarães sd].

Para visualizar o comportamento temporal, fixou-se antes da inferência o `case19` do holdout Figshare (escolha anterior à inferência, por consistência da demonstração, não pelo desempenho), usando toda a gravação (4.355 s). O script `docs/generate_figures.py` (opção `-infer-trajectory`) reutiliza `make_windows`, a configuração do checkpoint ativo e loader restrito, em CPU, sem treino. A curva bruta (sem EWMA) é posicionada no instante do alvo offline (início mais offset 0 s), em passos de 5 s; não representa disponibilidade sem atraso. Arrays, CSV, hashes e métricas ficam em `tmp/pdfs/trajectory-audit/`; a execução padrão não faz inferência nem download [Guimarães sd].

4. Resultados

4.1. Checkpoint ativo e baseline no Figshare

No holdout Figshare do checkpoint ativo, cinco casos e 5.523 janelas produziram MAE 7,03, RMSE 11,08, viés 0,79 e Pearson 0,784. A acurácia por faixa foi 0,585 e o macro-F1 0,548. O baseline espectral, na mesma partição, obteve MAE 8,86, RMSE 13,23, Pearson 0,667, acurácia 0,540 e macro-F1 0,480. A diferença sustenta apenas vantagem da CNN nessa partição e execução, não superioridade geral. Fontes internas: `reports/figshare_holdout_evaluation.json` e `reports/spectral_baseline_holdout.json` [Guimarães sd].

Tabela 3. Holdout Figshare comum: cinco casos, 5.523 janelas, seed 42; métricas agregadas por janela. Fonte interna [Guimarães sd].

Modelo	MAE	RMSE	Pearson	Acurácia	Macro-F1
CNN ativa	7,03	11,08	0,784	0,585	0,548
Baseline espectral	8,86	13,23	0,667	0,540	0,480

A Figura 2 mostra queda inicial e elevação final em ambas as curvas, mas a CNN superestima o patamar intermediário e não reproduz várias oscilações da referência. Nas 850 janelas aceitas, MAE foi 8,72, RMSE 10,21, viés $+4,79$ pontos BIS e Pearson 0,910: associação alta não elimina erro sistemático. É um exemplo ilustrativo, não evidência de generalização. A série BIS tem 906 pontos e se estende além do EEG; das 871 janelas completas, 21 foram rejeitadas, e 35 pontos finais não têm janela correspondente. As 56 posições sem previsão permanecem NaN; não havia EEG inválido neste caso. Fonte: auditoria em `tmp/pdfs/trajectory-audit/case19.json` [Guimarães sd].




Figura 2. Trajetória offline do Figshare *case19*, fixado antes da inferência por consistência da demonstração, não por desempenho. BIS original e CNN ativa bruta (sem EWMA), com erro no painel inferior. Alvo no início da janela (offset 0 s), não no instante de emissão. Lacunas preservadas; a cauda BIS excede o suporte EEG. Fontes: `data/raw/case19.mat` e auditoria `tmp/pdfs/trajectory-audit/case19.json`. Exemplo individual [Guimarães sd].

4.2. Comparação dos checkpoints nos benchmarks históricos

O candidato misto apresentou MAE 6,69, RMSE 10,67, viés 2,12, Pearson 0,818 e macro-F1 0,574 no holdout Figshare. Nos 15 participantes e 38.730 janelas do holdout VitalDB histórico, obteve 8,60, 11,74, -1,01, 0,688 e 0,486. O ativo obteve, respectivamente, 7,03/11,08/0,79/0,784/0,548 no Figshare e 12,43/18,80/1,40/0,024/0,398 no VitalDB. Os valores vêm de `reports/figshare_holdout_evaluation.json`, `reports/mixed_fixed_figshare_holdout.json`, `reports/vitaldb_external_validation.json` e `reports/mixed_vitaldb_external.json` [Guimarães sd].

Tabela 4. Comparação retrospectiva nos mesmos benchmarks históricos. “Visto” indica fonte vista no desenvolvimento. Fonte interna [Guimarães sd].

Benchmark	Modelo (fontes vistas)	Casos	MAE	RMSE	Pearson
Figshare	ativo (Figshare)	5	7,03	11,08	0,784
Figshare	misto (Figshare+VitalDB)	5	6,69	10,67	0,818
VitalDB	ativo (Figshare)	15	12,43	18,80	0,024
VitalDB	misto (Figshare+VitalDB)	15	8,60	11,74	0,688

No VitalDB, o MAE do candidato caiu em 14 dos 15 casos pareados; no `vitaldb_case16`, subiu cerca de 0,67 ponto BIS. A Figura 3 mostra que o ganho agregado convive com heterogeneidade e que casos longos pesam mais. Essa comparação descreve adaptação após exposição ao VitalDB, não transporte para nova fonte

[Guimarães sd].

4.3. Precisão por zona BIS verdadeira

O erro se distribui de forma desigual entre zonas. A Tabela 5 e a Figura 4 estratificam pelo BIS verdadeiro nos mesmos benchmarks; BIS < 20 é subset exploratório da profunda. Fontes: os quatro relatórios `zone_*.json` em `reports/` [Guimarães sd].

Tabela 5. MAE, viés e recall por zona BIS verdadeira (recall = fração com faixa correta). BIS < 20 é subset da profunda. Mesmos 5 Figshare e 15 VitalDB anteriores.

Conjunto	Zona (BIS)	n	MAE	Viés	Recall
Figshare ativo	profunda 0–40	1.773	5,64	+4,91	0,587
Figshare ativo	geral 40–60	2.584	5,53	+1,02	0,638
Figshare ativo	leve 60–80	592	11,20	+0,26	0,414
Figshare ativo	acordado 80–100	574	13,73	−12,45	0,517
Figshare misto	profunda 0–40	1.773	6,24	+5,82	0,563
Figshare misto	geral 40–60	2.584	5,31	+1,35	0,631
Figshare misto	leve 60–80	592	11,42	+1,92	0,370
Figshare misto	acordado 80–100	574	9,37	−5,60	0,714
VitalDB ativo	profunda 0–40	14.111	17,95	+17,34	0,452
VitalDB ativo	geral 40–60	21.580	8,42	−6,78	0,421
VitalDB ativo	leve 60–80	2.214	15,94	−15,22	0,190
VitalDB ativo	acordado 80–100	825	13,71	−12,61	0,448
VitalDB misto	profunda 0–40	14.111	10,03	+8,06	0,534
VitalDB misto	geral 40–60	21.580	6,75	−5,06	0,645
VitalDB misto	leve 60–80	2.214	15,54	−14,91	0,178
VitalDB misto	acordado 80–100	825	14,05	−13,11	0,425

No Figshare, sem BIS < 20 ($n = 0$), a zona leve é a mais difícil (MAE ≈ 11 , recall 0,37–0,41); o ganho do misto concentra-se no acordado (MAE 13,73 para 9,37; recall 0,517 para 0,714). No VitalDB, o ativo colapsa nas extremidades: profunda com MAE 17,95 (viés +17,34) e 12.214 das 21.580 janelas gerais preditas como profundas. No subset BIS < 20 ($n = 2.301$), MAE 60,73 no ativo contra 12,15 no misto; profunda vai a 10,03 e geral a 6,75 (recall 0,645), mas leve (15,54) e acordado (14,05) não melhoram. Pearson intrafaixa não conduz a leitura [Guimarães sd].

4.4. Bootstrap agrupado e sensibilidade ao offset

No Figshare, o ativo apresentou MAE observado 7,03 (IC percentil 95%: 6,38–8,24) e Pearson 0,784 (0,703–0,881); para o misto, os valores foram 6,69 (5,65–8,53) e 0,818 (0,751–0,890). No VitalDB, o ativo apresentou 12,43 (11,05–14,45) e 0,024 (−0,126–0,193), enquanto o misto apresentou 8,60 (7,57–9,95) e 0,688 (0,606–0,752). Os marcadores da Figura 5 são essas métricas observadas; somente as barras representam os intervalos das réplicas. As médias das réplicas bootstrap não substituem esses pontos observados. Os mesmos quatro relatórios registram B , seed, unidade e intervalos [Guimarães sd].

Na grade de offset, o ativo variou de MAE 7,22/Pearson 0,766 em -20 s para 7,03/0,784 em 0 s e 6,76/0,799 em $+20$ s. Um offset positivo associa a janela EEG a um BIS posterior. A tendência foi observada pós-hoc, sem retreino, e não identifica causalmente atraso do monitor nem autoriza mudar o offset padrão. Fonte interna: `reports/offset_sensitivity.json` [Guimarães sd]; contexto sobre atraso de índices processados em [Pilge et al. 2006].




Figura 3. Agregados por janela no Figshare (5 casos/5.523 janelas) e VitalDB (15/38.730) e MAE pareado por caso, ordenado pela diferença misto menos ativo. O ativo viu só o Figshare; o misto já viu outros participantes VitalDB. Pontos e linhas vêm dos quatro relatórios citados no texto; 14/15 casos melhoram, mas o caso 16 piora cerca de 0,67 [Guimarães sd].




Figura 4. MAE por zona BIS verdadeira (Figshare 5/5.523; VitalDB 15/38.730), ativo vs misto. Rótulos n por zona. No VitalDB, o subset BIS < 20 ($n = 2.301$) tem MAE 60,7 no ativo vs 12,2 no misto [Guimarães sd].




Figura 5. Métricas observadas (marcadores) e intervalos percentis de 95% (barras) do bootstrap por caso ($B = 1.000$, seed 42). Cada caso sorteado contribui com todas as janelas. O $n = 5$ do Figshare limita a leitura [Guimarães sd].




Figura 6. Sensibilidade pós-hoc ao alinhamento do rótulo em cinco casos Figshare. O número de janelas varia de 5.503 a 5.525, sem restrição a suporte comum. A linha vertical indica o padrão 0 s. A análise sem retreino gera hipótese e não seleciona atraso. Fonte: reports/offset_sensitivity.json [Guimarães sd].

5. Discussão e limitações

A degradação do ativo treinado só no Figshare, quando aplicado ao VitalDB, é evidência interna de sensibilidade à troca de fonte de dados, não prova de qual diferença (equipamento, centro, ganho, montagem, população ou distribuição do BIS) a causou. A redução de erro do candidato misto é compatível com adaptação após incorporar participantes VitalDB ao desenvolvimento; como esse benchmark é da mesma fonte e já havia sido observado, ele deve gerar uma hipótese para uma nova coorte travada, não uma alegação de generalização externa [Guimarães sd, Lee et al. 2022, Collins et al. 2024, International Medical Device Regulators Forum 2025].

A melhora em 14/15 casos coexiste com piora no caso 16, e os agregados por janela privilegiam cirurgias longas. Além disso, Pearson pode aumentar mesmo com vies ou discordância relevantes. Métricas por participante e análises de acordo/calibração são extensões possíveis, não resultados já demonstrados [Guimarães sd, Collins et al. 2024, Archer et al. 2021].

O bootstrap representa somente a variabilidade de reamostrar os casos disponíveis sob o algoritmo escolhido. Ele não cobre incerteza de treinamento, seleção de checkpoint, hiperparâmetros, mudança de centro ou erro do próprio rótulo BIS. O pequeno n Figshare e o reaproveitamento do benchmark VitalDB impedem leitura confirmatória [Guimarães sd, Field and Welsh 2007, Archer et al. 2021].

O alvo é a saída BIS, que pode responder a EMG, bloqueio neuromuscular, cetamina e atrasos; portanto, baixo erro contra o monitor não equivale a medir consciência ou efeito farmacológico verdadeiro [Schuller et al. 2015, Hans et al. 2005, Pilge et al. 2006]. De modo semelhante, as faixas e os limiares de qualidade do protótipo são heurísticas internas [Guimarães sd]. DOSE-I deve permanecer uma tarefa separada para MOAA/S e estado de consciência, sem conversão artificial para BIS [Garbe et al. 2026].

A leitura por zona mostra onde o agregado engana: o MAE global 12,43 do ativo no VitalDB combina zona geral razoável (8,42) com colapso na profunda (17,95) e no subset isoeletrico (60,73). A melhora do misto é desigual — profunda e geral melhoram, leve e acordado não — e, como o benchmark é histórico e reutilizado, gera hipótese para coorte travada, não evidência confirmatória [Guimarães sd, Collins et al. 2024].

Em engenharia, a cadeia registra hashes, partições, pré-processamento, relatórios e replay de arquivos. A trajetória individual torna visíveis erros que os agregados ocultam, mas não substitui a análise entre casos. Investigar o efeito das lacunas e a concordância em dados secundários são extensões metodológicas possíveis, não requisitos adicionais para concluir este TCC retrospectivo [Guimarães sd, Collins et al. 2024].

6. Conclusão

O BrainSniffer entrega um protótipo aberto e reproduzível para estimar uma referência BIS a partir de EEG frontal em arquivos e replay retrospectivo. Como sintetizado na Seção 4, o checkpoint ativo mostrou desempenho interno melhor que o baseline espectral, mas perdeu associação no VitalDB; o candidato misto reduziu o erro após exposição a esse domínio, com heterogeneidade por caso e sem independência confirmatória. Os resultados são retrospectivos, exploratórios e limitados pelo rótulo, pelo número de casos,

pelo reuso dos benchmarks e pelas políticas de imputação offline [Guimarães sd].

A contribuição defensável é uma base auditável para formular e testar hipóteses, não um sistema clínico. O software não mede consciência, não prescreve dose, não controla bomba e não deve acionar alarme ou conduta. O TCC se encerra com a implementação documentada, a comparação existente e a explicitação dos limites; uma futura alegação de generalização exigiria avaliação independente [Guimarães sd, Collins et al. 2024].

Ética, governança e conformidade

Esta etapa usa os corpora secundários Figshare e VitalDB, cujas publicações e páginas oficiais identificam a origem dos dados, não a aprovação institucional deste projeto [Ma 2017, Lee et al. 2022, Lee and Jung 2022]. Não se relata coleta prospectiva nem intervenção. Não foi apresentado aqui número de parecer, aprovação ou dispensa institucional, e nenhum é presumido a partir da disponibilidade dos dados. Os termos de uso e o enquadramento ético devem ser confirmados pelo autor e pela instituição, conforme os procedimentos institucionais aplicáveis, antes de qualquer estudo futuro. A nova inferência ilustrativa em um caso não reexecuta o treinamento nem os benchmarks completos; a compilação não valida alterações simultâneas do sistema.

Referências

- Archer, L., Snell, K. I. E., Ensor, J., Hudda, M. T., Collins, G. S., and Riley, R. D. (2021). Minimum sample size for external validation of a clinical prediction model with a continuous outcome. *Statistics in Medicine*, 40(1):133–146. DOI: <https://doi.org/10.1002/sim.8766>.
- Avidan, M. S., Jacobsohn, E., Glick, D., et al. (2011). Prevention of intraoperative awareness in a high-risk surgical population. *New England Journal of Medicine*, 365:591–600. DOI: <https://doi.org/10.1056/NEJMoa1100403>.
- Avidan, M. S., Zhang, L., Burnside, B. A., et al. (2008). Anesthesia awareness and the bispectral index. *New England Journal of Medicine*, 358:1097–1108. DOI: <https://doi.org/10.1056/NEJMoa0707361>.
- Collins, G. S., Moons, K. G. M., Dhiman, P., et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378. DOI: <https://doi.org/10.1136/bmj-2023-078378>.
- Connor, C. W. (2022). Open reimplementations of the BIS algorithms for depth of anesthesia. *Anesthesia & Analgesia*, 135(4):855–864. DOI: <https://doi.org/10.1213/ANE.00000000000006119>.
- Field, C. A. and Welsh, A. H. (2007). Bootstrapping clustered data. *Journal of the Royal Statistical Society: Series B*, 69(3):369–390. DOI: <https://doi.org/10.1111/j.1467-9868.2007.00593.x>.
- Garbe, J., Nguyen, Q. V., Kantelhardt, J. W., Dünninghaus, F., Erffmeier, K., Seeliger, K., and Schmid, T. (2026). DOSE-I: A multimodal biosignal dataset of procedural sedation for endoscopy. Dataset, v1, 171 gravações. Licença CC BY 4.0 com Data_Use_Agreement.txt. Não utilizado no treino deste trabalho; citado apenas como contexto MOAA/S. DOI: <https://doi.org/10.5281/zenodo.18483292>.

Guimarães, B. R. (s.d.). BrainSniffer: código, configurações e relatórios locais de pesquisa. Artefatos internos não publicados. Caminhos relativos à raiz do projeto: `src/brainsniffer/`, `models/brainsniffer_cnn.json`, `models/brainsniffer_corpus_fixed.json` e `reports/`. O corpus de relatórios inclui manifesto, holdouts Figshare e VitalDB dos dois checkpoints, baseline espectral, sensibilidade ao offset e sessões LSL sintéticas; arquivos específicos identificados no texto. Sem data única atribuída ao conjunto, DOI ou publicação validada; não constitui validação independente.

Hans, P., Dewandre, P.-Y., Brichant, J. F., and Bonhomme, V. (2005). Comparative effects of ketamine on bispectral index and spectral entropy of the electroencephalogram under sevoflurane anaesthesia. *British Journal of Anaesthesia*, 94(3):336–340. DOI: <https://doi.org/10.1093/bja/aei047>.

International Medical Device Regulators Forum (2025). Good machine learning practice for medical device development: Guiding principles. IMDRF/AIML WG/N88 FINAL:2025. Documento final de 29 jan. 2025. Portal oficial: <https://www.imdrf.org>.

Lee, H.-C. and Jung, C.-W. (2022). VitalDB, a high-fidelity multi-parameter vital signs database in surgical patients. Version 1.0.0. Espelho PhysioNet com LICENSE.txt CC BY 4.0; tracks usados via API oficial vitaldb.net sob regime CC BY-NC-SA 4.0. Mapa caseid-subjectid em `clinical_data.csv`. DOI: <https://doi.org/10.13026/czw8-9p62>.

Lee, H.-C., Park, Y., Yoon, S. B., Yang, S. M., Park, D., and Jung, C.-W. (2022). VitalDB, a high-fidelity multi-parameter vital signs database in surgical patients. *Scientific Data*, 9:279. DOI: <https://doi.org/10.1038/s41597-022-01411-5>.

Ma, L. (2017). EEG and BIS raw data. Dataset, versão v1, 24 arquivos. Licença CC BY 4.0. DOI: <https://doi.org/10.6084/m9.figshare.5589841.v1>. Conferido via API pública em 14 set. 2026. Citação oficial: Ma, Li (2017). EEG and BIS raw data. figshare. Dataset.

Myles, P. S., Leslie, K., McNeil, J., Forbes, A., and Chan, M. T. V. (2004). Bispectral index monitoring to prevent awareness during anaesthesia: the B-Aware randomised controlled trial. *The Lancet*, 363:1757–1763. DOI: [https://doi.org/10.1016/S0140-6736\(04\)16300-9](https://doi.org/10.1016/S0140-6736(04)16300-9).

Nsugbe, E. and Connelly, S. (2022). Multiscale depth of anaesthesia prediction for surgery using frontal cortex electroencephalography. *Healthcare Technology Letters*, 9:43–53. DOI: <https://doi.org/10.1049/htl2.12025>.

Park, Y., Han, S.-H., Byun, W., Kim, J.-H., Lee, H.-C., and Kim, S.-J. (2020). A real-time depth of anesthesia monitoring system based on deep neural network with large EDO tolerant EEG analog front-end. *IEEE Transactions on Biomedical Circuits and Systems*, 14:825–837. DOI: <https://doi.org/10.1109/TBCAS.2020.2998172>.

Pilge, S., Zanner, R., Schneider, G., Blum, J., Kreuzer, M., and Kochs, E. F. (2006). Time delay of index calculation: analysis of cerebral state, bispectral, and Narcotrend

- indices. *Anesthesiology*, 104(3):488–494. DOI: <https://doi.org/10.1097/00000542-200603000-00016>.
- Saeb, S., Lonini, L., Jayaraman, A., Mohr, D. C., and Kording, K. P. (2017). The need to approximate the use-case in clinical machine learning. *GigaScience*, 6. DOI: <https://doi.org/10.1093/gigascience/gix019>.
- Schuller, P. J., Newell, S., Strickland, P. A., and Barry, J. J. (2015). Response of bispectral index to neuromuscular block in awake volunteers. *British Journal of Anaesthesia*, 115(Suppl 1):i95–i103. DOI: <https://doi.org/10.1093/bja/aev072>.
- Shi, M., Huang, Z., Xiao, G., Xu, B., Ren, Q., and Zhao, H. (2023). Estimating the depth of anesthesia from EEG signals based on a deep residual shrinkage network. *Sensors*, 23(2):1008. DOI: <https://doi.org/10.3390/s23021008>.
- Sukriti, Kriplani, C., Kumar, S., and Singh, A. (2026). Predicting depth of anesthesia from single-channel EEG using a deep TCN-BiLSTM-attention model with EWMA. *Scientific Reports*, 16:25470. DOI: <https://doi.org/10.1038/s41598-026-54608-8>.
- U.S. Food and Drug Administration and Covidien (2024). BIS Advance Monitoring System: K230693, Indications for Use. 510(k) premarket notification. Disponível em: https://www.accessdata.fda.gov/cdrh_docs/pdf23/K230693.pdf.
- VitalDB (2026). Open dataset: overview and track list. Documentação oficial. Licença CC BY-NC-SA 4.0 com Data Use Agreement e exigência de citação a Lee et al. 2022. Disponível em: <https://vitaldb.net/dataset/>; acesso em 14 set. 2026.