

BrainSniffer: protótipo reproduzível para estimar uma referência BIS a partir de EEG frontal

Bruno Rocha Guimarães¹

¹Ciência da Computação – Centro Universitário Jorge Amado
Salvador, Bahia – Brasil

Abstract. *This paper describes BrainSniffer, a reproducible engineering prototype that estimates a Bispectral Index (BIS) reference label from frontal electroencephalography (EEG). The pipeline uses five-second windows at 128 Hz, a compact one-dimensional convolutional neural network, and partitions grouped by case or subject. The active Figshare-only checkpoint reached mean absolute error (MAE) 7.03 and Pearson correlation 0.784 in a five-case Figshare holdout, but 12.43 and 0.024 in a 15-case VitalDB cross-dataset assessment. A mixed candidate trained with Figshare and part of VitalDB reached 6.69/0.818 on the Figshare benchmark and 8.60/0.688 on the historical VitalDB participant holdout. These results are retrospective and exploratory; Pearson is interpreted as association, not agreement. BrainSniffer neither measures consciousness nor supports clinical decisions, alarms, or drug dosing.*

Resumo. *Este artigo descreve o BrainSniffer, protótipo de engenharia reproduzível que estima, a partir de eletroencefalografia (EEG) frontal, um rótulo de referência do Índice Bispectral (BIS). O pipeline usa janelas de cinco segundos a 128 Hz, uma rede neural convolucional unidimensional compacta (1-D CNN, Conv1DDepthEstimator) e partições agrupadas por caso ou pessoa. O checkpoint ativo, treinado apenas no Figshare, obteve erro absoluto médio (MAE) 7,03 e correlação de Pearson 0,784 em cinco casos Figshare, mas 12,43 e 0,024 em uma avaliação cruzada com 15 casos VitalDB. Um candidato misto, treinado com Figshare e parte do VitalDB, obteve 6,69/0,818 no benchmark Figshare e 8,60/0,688 no holdout histórico VitalDB por participante. Os resultados são retrospectivos e exploratórios; Pearson é tratado como associação, não acordo. O BrainSniffer não mede consciência nem apoia decisão clínica, alarme ou dose.*

Palavras-chave: EEG frontal; rótulo BIS; CNN unidimensional; validação agrupada; mudança de domínio; reprodutibilidade.

1. Introdução

Na anestesia geral, é preciso saber se o paciente está suficientemente hipnotizado sem exagerar na dose, e para isso usam-se referências objetivas de profundidade. O Índice Bispectral (Bispectral Index, BIS), calculado a partir da eletroencefalografia (EEG) frontal, é a referência mais usada à beira do leito, mas é uma saída proprietária: sua regra de combinação não é publicada e não pode ser reproduzida exatamente a partir do sinal. Modelos que tentam aproximar esse rótulo enfrentam ainda um risco metodológico silencioso: janelas vizinhas da mesma cirurgia são quase idênticas, então uma partição

aleatória entre treino e teste mede o reconhecimento de casos já vistos, não a generalização. Falta um protótipo reproduzível que estime o rótulo BIS com partições por caso ou pessoa, um controle simples baseado em medidas espectrais e avaliação entre fontes distintas de dados. Este trabalho apresenta e avalia o BrainSniffer, um protótipo para arquivos e repetição retrospectiva de gravações (replay), com esse desenho.

A pesquisa responde a duas perguntas. (i) Quanto uma rede neural convolucional unidimensional compacta (1-D CNN) aproxima o rótulo BIS em casos não usados no ajuste, comparada a um controle mais simples baseado em medidas espectrais (baseline espectral)? (ii) Esse desempenho se mantém ao trocar a fonte dos dados, do Figshare para o VitalDB, com outro equipamento, montagem e população? O objetivo geral é avaliar essa aproximação de forma reproduzível. Os objetivos específicos são: comparar a CNN ao baseline espectral no holdout Figshare; quantificar a degradação do modelo ao aplicá-lo ao VitalDB; testar se incorporar parte do VitalDB ao treino (candidato misto) reduz o erro; e caracterizar a ordenação das estimativas (probabilidade de predição P_K) e a incerteza por caso (bootstrap agrupado).

Vale fixar o vocabulário: o modelo estima um rótulo de referência derivado do BIS, e não o BIS como grandeza independente, porque o próprio BIS é a saída de um monitor sobre o mesmo sinal. A contribuição é uma cadeia com partições por grupo, controle espectral, comparação entre fontes e análise de incerteza por caso. O escopo deste TCC é avaliar essa cadeia, não desenvolver um dispositivo médico. A Seção 2 fundamenta o índice BIS e o problema do vazamento entre janelas; a Seção 3 descreve materiais e métodos; a Seção 4 apresenta os resultados; a Seção 5 discute limitações; e a Seção 6 conclui.

2. Fundamentação e trabalhos relacionados

2.1. O índice BIS e seus limites

O Índice Bispectral (Bispectral Index, BIS) é uma saída proprietária calculada a partir da eletroencefalografia (EEG), o registro da atividade elétrica cerebral captada no couro cabeludo. Sua escala vai de 0, próximo de silêncio elétrico, a 100, tipicamente associado à vigília; a faixa intermediária costuma ser usada como referência de hipnose em anestesia geral, sem que isso defina um limiar clínico único ou uma fronteira nítida entre estados. O cálculo combina características no domínio do tempo e da frequência (incluindo componentes bispectrais e de supressão de surto) por uma regra de combinação não publicada; por ser fechado, o índice não pode ser reproduzido exatamente a partir do EEG, e qualquer modelo treinado contra ele herda esse limite. O BIS é indicado apenas como auxílio, em contexto e sob supervisão definidos, não como medida direta de consciência, de adequação anestésica ou de dose. Sua leitura varia com a atividade elétrica muscular (eletromiografia, EMG), o bloqueio neuromuscular, os fármacos usados e o atraso de processamento: estudos controlados documentaram queda do índice após bloqueio em voluntários acordados, resposta paradoxal à cetamina e atrasos distintos entre monitores processados [U.S. Food and Drug Administration and Covidien 2024, Connor 2022, Schuller et al. 2015, Hans et al. 2005, Pilge et al. 2006]. Ensaios com protocolos guiados pelo índice também produziram resultados que dependem do grupo de comparação e da população, o que impede extrapolar um único número para benefício clínico universal [Myles et al. 2004, Avidan et al. 2008, Avidan et al. 2011].

2.2. Vazamento entre janelas e partição por grupo

Redes profundas já foram estudadas com alvos, canais, populações e equipamentos distintos para aproximar índices derivados de EEG [Park et al. 2020, Shi et al. 2023]. O problema é que janelas vizinhas da mesma cirurgia são parecidas entre si em amplitude, espectro e nível de BIS, porque refletem o mesmo paciente no mesmo plano anestésico. Se essas janelas forem espalhadas aleatoriamente entre treino e teste, o teste contém trechos quase idênticos aos de treino, e a métrica mede a capacidade de reconhecer um caso já visto, não de generalizar: é o vazamento (*leakage*), que infla o desempenho de forma silenciosa. Para evitar isso, este trabalho separa os dados por caso ou por pessoa (o grupo), de modo que nenhum grupo contribua simultaneamente para treino e para teste; o custo é uma estimativa mais pessimista e mais realista do uso em um caso novo. Resultados recentes nesse corpus e evidência metodológica mais ampla mostram que essa unidade de separação altera materialmente a estimativa de desempenho [Sukriti et al. 2026, Saeb et al. 2017].

2.3. Corpora, transparência e relato de modelos

O conjunto “EEG and BIS raw data” reúne 24 casos anônimos com EEG frontal e valores BIS, publicado no repositório Figshare sob licença CC BY 4.0 [Ma 2017]. No mesmo corpus, um estudo anterior usou características multiescala com análise discriminante linear (Linear Discriminant Analysis, LDA); esse trabalho sustenta a descrição do corpus e das faixas, mas não é evidência de rede convolucional [Nsugbe and Connelly 2022]. Em outras configurações, uma rede estimou a concentração anestésica derivada de EEG com cadeia de aquisição dedicada, enquanto outro estudo estimou o índice de estado do paciente (Patient State Index, PSI) com quatro canais em 18 participantes idosos sedados. Esses estudos demonstram viabilidade técnica em configurações específicas, não comparabilidade direta com o rótulo, o canal ou a população do BrainSniffer [Park et al. 2020, Shi et al. 2023].

O VitalDB é um banco de sinais perioperatórios de milhares de cirurgias e inclui os canais de EEG e de BIS usados aqui (BIS/EEG1_WAV e BIS/BIS) [Lee et al. 2022, VitalDB 2026, Lee and Jung 2022]. O conjunto aberto (vitaldb.net) exige licença CC BY-NC-SA 4.0 e acordo de uso de dados, sem redistribuição. Escala, equipamento, montagem e população diferem do Figshare; por isso, o VitalDB informa a sensibilidade à troca de fonte de dados, sem isolar a causa. O conjunto DOSE-I (Zenodo, CC BY 4.0) não foi incorporado à regressão porque usa uma escala clínica de sedação por observação (Modified Observer’s Assessment of Alertness/Sedation, MOAA/S) e estado de consciência, não conversíveis em BIS [Garbe et al. 2026].

Uma reimplementação aberta do algoritmo do índice ajuda a discutir a transparência do cálculo, mas não torna um regressor treinado contra o BIS equivalente a um monitor nem certificado como tal [Connor 2022]. A independência entre desenvolvimento e avaliação, a descrição de grupos e a análise de calibração e acordo são componentes centrais de relato e avaliação de modelos; para desfecho contínuo, o tamanho da validação deve ser planejado pela precisão desejada, não pelo número de réplicas bootstrap [Collins et al. 2024, Archer et al. 2021].

3. Materiais e métodos

Para reduzir a ambiguidade dos nomes usados neste artigo, a Tabela 1 resume as fontes vistas no treinamento e os conjuntos de avaliação de cada checkpoint. Os dois checkpoints respondem a perguntas diferentes. O “ativo” foi ajustado apenas no Figshare e testa o limite do modelo dentro da própria fonte e a sua queda ao mudar de corpus; o “misto” foi ajustado também com parte do VitalDB e testa se incorporar a fonte de destino reduz o erro. Como o misto viu o domínio VitalDB, o desempenho dele nessa fonte não mede transporte para uma fonte nova. “Ativo” e “misto” são apenas abreviações desses dois modelos.

Tabela 1. Definição conceitual dos dois checkpoints.

Modelo	Treinado com	Avaliado em
Modelo A – Figshare (ativo)	Figshare	Figshare (holdout por caso) e VitalDB (avaliação cruzada de dataset)
Modelo B – misto	Figshare + parte do VitalDB	Figshare (benchmark histórico) e VitalDB (holdout histórico por participante)

A Figura 1 resume esse fluxo retrospectivo, da composição do pool à avaliação sem reajuste.




Figura 1. Fluxo retrospectivo auditável do BrainSniffer.

3.1. Fontes, unidades de agrupamento e partições

Cada arquivo é uma gravação inteira, tratada como um caso; de cada caso saem janelas de 5 s, unidades de treino e de métrica. O grupo é a unidade que nunca cruza partições. O

corpus tem 59 arquivos: 44 no pool de desenvolvimento e 15 casos VitalDB congelados. Os gates de qualidade são filtros prévios ao ajuste que descartam casos ou janelas com escala problemática, valores inválidos ou sinal insuficiente; depois deles, 23 casos Figshare e dez VitalDB ficaram elegíveis: 33 casos e 55.471 janelas. Janelas medem volume disponível, não desempenho, e casos longos pesam mais. No Figshare não há `subject_id`; `case_id` evita compartilhar janelas da mesma cirurgia, mas não prova independência entre cirurgias da mesma pessoa. No VitalDB o agrupamento usa `subjectid` e reúne reoperações conhecidas [Ma 2017, Lee et al. 2022, Lee and Jung 2022].

O checkpoint ativo foi desenvolvido só com os 23 casos Figshare elegíveis, divididos com seed 42 em 13 de treino, cinco de validação e cinco de teste. O candidato misto fixo excluiu os cinco casos do holdout Figshare histórico e usou 18 grupos Figshare mais dez VitalDB: 28 grupos e 49.948 janelas, com partição registrada de 16/6/6 grupos. O ajuste usa 12 casos Figshare e quatro participantes VitalDB (34.792 janelas); a validação, dois Figshare e quatro VitalDB (7.235); o teste interno, quatro Figshare e dois VitalDB (7.921). O treino atualiza os pesos, a validação apoia a parada e só o teste interno é lido como resultado; por isso as janelas de validação não aparecem nas tabelas. As contagens seguem o protocolo de partição; dizer “corpus de 28 grupos” não significa que os 28 entraram no ajuste.

Os mesmos cinco casos Figshare são o benchmark histórico dos dois checkpoints. Para o ativo, os 15 casos VitalDB são avaliação cruzada de dataset. Para o misto, esses 15 participantes não entraram no ajuste, mas vêm da mesma fonte do desenvolvimento e o benchmark já havia sido inspecionado antes da criação do candidato; por isso ele é descrito como holdout VitalDB histórico, por participante e após exposição ao domínio, não como validação externa confirmatória. Manter o candidato fora do dashboard é decisão operacional: não restaura a independência de benchmarks já inspecionados, inclusive o Figshare reutilizado [Collins et al. 2024, International Medical Device Regulators Forum 2025].

3.2. Tarefa, pré-processamento e qualidade

Cada exemplo é um trecho curto de EEG: 640 amostras, isto é, uma janela de 5 segundos amostrada a 128 Hz, com passo de 5 s na construção offline. Para cada início t , o alvo corresponde a $t + \text{offset}$, arredondado ao intervalo do BIS do caso (5 s no Figshare e 1 s nos arquivos VitalDB normalizados). Como a emissão só pode ocorrer depois de completar a janela (aproximadamente em $t + 5$ s) e somar o tempo de processamento, com offset zero o sistema não faz previsão de um BIS futuro nem leitura contemporânea ao fim da janela. O pipeline mantém a banda de 0,5–45 Hz, remove a interferência da rede elétrica (notch de 50 Hz, filtro de quarta ordem) e aplica a escala de amplitude registrada, com o rótulo BIS associado ao início da janela (offset padrão 0 s). O filtro usa apenas amostras passadas e presentes (estado causal), preservado por caso e entre blocos; uma rota de fase zero existe somente para análise offline explícita. Essas escolhas seguem o protocolo do estudo; as fontes externas descrevem os corpora e o problema, mas não definem esta configuração [Ma 2017, Nsugbe and Connelly 2022].

O controle de qualidade do corpus exige, entre outros critérios internos, pelo menos 90% de EEG com valores finitos, lacuna inválida máxima de 2 s, qualidade global mínima 0,35, pelo menos 80% de BIS válido e qualidade mínima 0,20 por janela; o caso

Figshare 24 está em quarentena por escala incompatível. Esses limiares são heurísticas de engenharia não calibradas para risco clínico; no replay, trechos inválidos são rejeitados antes do filtro e trechos de baixa qualidade levam o modelo a se abster.

Esse controle do corpus de desenvolvimento não se aplica aos 15 casos do benchmark VitalDB histórico. Na construção offline, `make_windows` processa o EEG completo do caso: valores inválidos (não finitos) são preenchidos por interpolação linear entre vizinhos válidos, repetindo o extremo nas bordas, sem limite de duração da lacuna e podendo usar amostras futuras, mesmo quando o filtro seguinte é causal; um vetor todo inválido vira zeros. A qualidade é calculada sobre a janela bruta. O BIS inválido ou fora de $[0, 100]$ é descartado, sem interpolação nessa etapa. Antes disso, a normalização (função `_align_numeric_to_eeg`) ordena os dados, remove tempos duplicados e interpola os pontos BIS válidos para uma grade de 1 s, apenas entre o primeiro e o último ponto válido (fora disso, NaN), sem limite de lacuna e sem máscara persistida; aqui, válido significa finito. Como os 15 arquivos históricos contêm EEG inválido, sua avaliação offline difere da política de rejeição do replay. Esse preenchimento pode suavizar lacunas longas e limita a interpretação; política e métricas históricas foram mantidas. É um procedimento adotado neste estudo, não uma recomendação dos datasets.

3.3. Modelos e treinamento

A CNN histórica (`Conv1DDepthEstimator`) recebe a janela de 640 amostras em um canal, é treinada com perda Smooth L1 e tem saída sigmoideal escalada para $[0, 100]$. A Tabela 2 explicita a arquitetura e os parâmetros registrados no protocolo, sem carregar pesos. Recursos posteriores do treinador e arquiteturas opcionais não são atribuídos retroativamente a esses pesos.

Tabela 2. Configuração histórica dos checkpoints.

Item	Configuração registrada/compatível
Convolucionais (<code>Conv1d</code>)	<i>Channels</i> 1–32–64–128–128; <i>kernel</i> 7, 7, 5, 5; <i>padding</i> 3, 3, 2, 2; <i>stride</i> 1; <code>BatchNorm1d</code> + GELU
<i>Pooling</i> e cabeça	<code>MaxPool1d</code> (2) nos 3 primeiros blocos; <code>AdaptiveAvgPool1d</code> (1); <code>Linear</code> 128–64–1, GELU, <i>dropout</i> 0,20
Treino (ambos)	10 <i>epochs</i> , <i>batch</i> 128, <i>lr</i> 10^{-3} , <i>wd</i> 10^{-4} , <i>seed</i> 42; val/teste 0,20/0,20
Amostragem	Misto: <i>balanced sampling</i> por grupo/fonte; ativo: não registrado
Amplitude e <i>notch</i>	<i>Clip</i> $\pm 100 \mu V$, escala $50 \mu V$, saída em $[-5, 5]$; <i>notch</i> 50 Hz, Q=30
<i>Random Forest</i>	<i>n_estimators</i> =100, <i>max_depth</i> =12, <i>min_samples_leaf</i> =2, <i>random_state</i> =42

A arquitetura compacta permite replay em CPU, mas não implica superioridade sobre redes temporais, atenção ou representações tempo-frequência [Park et al. 2020, Shi et al. 2023].

Como controle simples, o baseline espectral resume cada janela de 5 s em 14 atributos clássicos: potências absoluta e relativa das bandas delta (0,5–4 Hz), teta (4–8 Hz), alfa (8–13 Hz), beta (13–30 Hz) e gama (30–45 Hz), frequência de borda espectral em 90% (SEF90), entropia espectral, valor eficaz (RMS) e *line length*. Uma floresta aleatória (*Random Forest*, configuração na Tabela 2) é ajustada nas mesmas 15.894 janelas de

treino e avaliada nas mesmas 5.523 janelas de teste do holdout Figshare, sem acesso a informação adicional e herdando a mesma proteção contra vazamento da partição agrupada por caso. O controle responde a uma pergunta prática: se poucas medidas de espectro já alcançam erro parecido, a complexidade da CNN precisa ser justificada; se a CNN supera o controle, há indício de que a representação aprendida captura estrutura além do espectro clássico.

3.4. Métricas, incerteza e análises exploratórias

Foram calculados o erro absoluto médio (Mean Absolute Error, MAE), a raiz do erro quadrático médio (Root Mean Squared Error, RMSE), o viés e a correlação de Pearson para o rótulo contínuo, além de acurácia e macro-F1 para quatro faixas de BIS. Em leitura simples: MAE é o erro médio em pontos BIS; RMSE penaliza mais os erros grandes; viés é a diferença média predito menos referência; Pearson mede se as curvas variam juntas (associação, não acordo); macro-F1 é o acerto médio entre faixas. As métricas incluem MAE e RMSE, definidos por

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (1)$$

O resultado principal agrega todas as janelas aceitas (casos longos pesam mais), em vez de tirar a média por pessoa. O viés é a média de predito menos referência. As faixas são $[0, 40)$, $[40, 60)$, $[60, 80)$ e $[80, 100]$, aqui lidas com rótulos curtos apenas para comunicação — profunda, geral adequada, leve/transicional e acordado — sem validar limiar clínico. Pearson quantifica associação linear e não acordo; não foram estimados, nesta execução, limites de concordância, coeficiente de concordância ou calibração clínica. As quatro faixas são apenas uma apresentação interna e não constituem classes clínicas independentes [Collins et al. 2024].

A associação ordinal entre estimativa e referência é medida pela probabilidade de predição P_K (na literatura de anestesia, Pk), proposta por Smith, Dutton e Smith [Smith et al. 1996] como variante reescalada da medida $d_{y,x}$ de Kim. A pergunta que ela responde é direta: sorteados dois momentos com profundidades de referência distintas, qual é a chance de o indicador ordená-los na mesma ordem da referência? Vale 1 na ordem perfeita e 0,5 no acaso, como cara-ou-coroa.

Na prática, pares com o mesmo BIS de referência são excluídos, porque não informam ordenação, e pares empatados no indicador contam 0,5. Por depender só da ordem, P_K ignora erro sistemático de escala: um modelo que erra sempre por 10 pontos, mas preserva a ordem, pode ter P_K alto com MAE ruim; outro com MAE menor, mas que embaralha níveis próximos, pode ter P_K baixo. Essa invariância a reescala afim crescente é a utilidade do índice aqui: ele separa ganho de ordenação de mero ajuste de escala, o que MAE, RMSE e Pearson sozinhos confundem.

O comando `evaluate-pk` reaproveita as janelas e as predições dos mesmos benchmarks, sem retreino, e grava `pk_*.json`; os intervalos vêm de reamostragem de casos ($B = 1.000$, seed 42), na mesma unidade agrupada do bootstrap [Smith et al. 1996].

O bootstrap estima a incerteza sorteando casos inteiros com reposição, juntando todas as janelas sorteadas e recalculando a métrica. Assim, respeita melhor a dependência

dentro de cada caso do que sortear janelas, mas o resultado continua ponderado pela duração. Foram usadas $B = 1.000$ réplicas, seed 42 e percentis 2,5/97,5 para o intervalo de 95%. Com apenas cinco casos Figshare, o intervalo é exploratório; 1.000 réplicas não equivalem a 1.000 casos [Field and Welsh 2007, Archer et al. 2021].

Como referência externa para dimensionar esses números, adota-se um critério consolidado em estudos de acurácia do próprio monitor BIS: diferenças de até 10 unidades entre duas medições são clinicamente aceitáveis [Dahaba et al. 2010, Shiraishi et al. 2004, Harada et al. 2021]; aqui o valor serve de escala para ler o MAE, não de alvo de desempenho.

A comparação VitalDB também foi calculada por caso, pareando `case_id` e número de janelas por caso. A análise de sensibilidade reaplicou o checkpoint ativo aos mesmos cinco casos Figshare, sem retreino, em uma grade de -20 a $+20$ s. Como a grade foi examinada após o treinamento, ela formula hipótese sobre alinhamento e não escolhe o atraso do rótulo [Pilg et al. 2006].

3.5. Replay retrospectivo e trajetória ilustrativa

Replay significa percorrer uma gravação existente, não adquirir EEG: preenche-se um buffer de 5 s e depois emite-se atualização a cada 1 s, separando valor bruto, média móvel exponencial (Exponentially Weighted Moving Average, EWMA), qualidade, instante e origem. O escopo deste TCC é exclusivamente retrospectivo, sem conexão a EEG físico. A implementação distingue o instante de emissão do alvo histórico no início da janela.

Para visualizar o comportamento temporal, fixou-se antes da inferência o `case19` do holdout Figshare (escolha anterior à inferência, por consistência da demonstração, não pelo desempenho), usando toda a gravação (4.355 s). O procedimento (opção `-infer-trajectory`) reutiliza `make_windows`, a configuração do checkpoint ativo e loader restrito, em CPU, sem treino. A curva bruta (sem EWMA) é posicionada no instante do alvo offline (início mais offset 0 s), em passos de 5 s; não representa disponibilidade sem atraso. Arrays, CSV, hashes e métricas ficam registrados na auditoria da trajetória; a execução padrão não faz inferência nem download.

4. Resultados

4.1. Checkpoint ativo e baseline no Figshare

No holdout Figshare do checkpoint ativo, cinco casos e 5.523 janelas produziram MAE 7,03, RMSE 11,08, viés 0,79 e Pearson 0,784. A acurácia por faixa foi 0,585 e o macro-F1 0,548. O baseline espectral, na mesma partição, obteve MAE 8,86, RMSE 13,23, Pearson 0,667, acurácia 0,540 e macro-F1 0,480. A diferença sustenta apenas vantagem da CNN nessa partição e execução, não superioridade geral. A Tabela 3 resume o agregado.

Tabela 3. Holdout Figshare comum.

Modelo	MAE	RMSE	Pearson	Acurácia	Macro-F1
CNN ativa	7,03	11,08	0,784	0,585	0,548
Baseline espectral	8,86	13,23	0,667	0,540	0,480

A Figura 2 mostra queda inicial e elevação final em ambas as curvas, mas a CNN superestima o patamar intermediário e não reproduz várias oscilações da referência. Nas

850 janelas aceitas, MAE 8,72, RMSE 10,21, viés +4,79 e Pearson 0,910: associação alta não elimina erro sistemático; é exemplo ilustrativo, não evidência de generalização. A série BIS tem 906 pontos e vai além do EEG; das 871 janelas completas, 21 foram rejeitadas, 35 pontos finais ficaram sem janela e as 56 posições sem previsão permanecem NaN (não havia EEG inválido neste caso).




Figura 2. Trajetória offline do Figshare case19.

4.2. Comparação dos checkpoints nos benchmarks históricos

O candidato misto apresentou MAE 6,69, RMSE 10,67, viés 2,12, Pearson 0,818 e macro-F1 0,574 no holdout Figshare. Nos 15 participantes e 38.730 janelas do holdout VitalDB histórico, obteve 8,60, 11,74, -1,01, 0,688 e 0,486. O ativo obteve, respectivamente, 7,03/11,08/0,79/0,784/0,548 no Figshare e 12,43/18,80/1,40/0,024/0,398 no VitalDB. A Tabela 4 organiza esses agregados. Pela referência de Métricas, três dos quatro resultados ficam com MAE abaixo de 10 unidades (6,69; 7,03 e 8,60), inclusive o misto ao trocar de equipamento e população; o ativo no VitalDB (12,43) ultrapassa essa escala, o que combina com a perda de ordenação medida pelo P_K .

Tabela 4. Comparação retrospectiva nos benchmarks históricos.

Benchmark	Modelo (fontes vistas)	Casos	MAE	RMSE	Pearson
Figshare	ativo (Figshare)	5	7,03	11,08	0,784
Figshare	misto (Figshare+VitalDB)	5	6,69	10,67	0,818
VitalDB	ativo (Figshare)	15	12,43	18,80	0,024
VitalDB	misto (Figshare+VitalDB)	15	8,60	11,74	0,688

No VitalDB, o MAE do candidato caiu em 14 dos 15 casos pareados; no `vitaldb_case16`, subiu cerca de 0,67 ponto BIS. Na Figura 3c, cada linha é um caso,

ordenado pela diferença misto menos ativo, e os dois pontos são os MAE de cada modelo no mesmo caso; uma linha apontando para a esquerda indica que o misto errou menos. A leitura é pareada de propósito: comparar médias agregadas de modelos diferentes poderia esconder que eles acertam os mesmos casos ou que um grupo pequeno de casos longos domina a média. O painel (a) e o (b) mostram os agregados, mas é o painel (c) que revela a heterogeneidade: o ganho não é uniforme, e 14 acertos contra 1 piora convivem com casos em que a margem é pequena. Como os agregados são calculados por janela, casos longos pesam mais do que casos curtos, e a média pode não corresponder à de um caso típico. Essa comparação descreve adaptação após exposição ao VitalDB, não transporte para nova fonte.




Figura 3. Agregados por janela e MAE pareado por caso.


4.3. Probabilidade de predição P_K

A associação ordinal é medida nos dois benchmarks pela probabilidade de predição P_K de Smith, Dutton e Smith [Smith et al. 1996], que responde a uma pergunta diferente da de MAE e viés: com que frequência o indicador ordena corretamente duas profundidades observadas distintas? A Tabela 5 e a Figura 4 trazem os valores e os intervalos por caso.

Tabela 5. Probabilidade de predição P_K nos benchmarks históricos.

Benchmark	Modelo	Janelas	P_K	IC 95%	MAE	Pearson
Figshare	ativo	5.523	0,773	0,679–0,828	7,03	0,784
Figshare	misto	5.523	0,774	0,676–0,835	6,69	0,818
VitalDB	ativo	38.730	0,515	0,434–0,581	12,43	0,024
VitalDB	misto	38.730	0,672	0,591–0,737	8,60	0,688

No Figshare (Figura 4), o ativo obtém P_K 0,773 (0,679–0,828) e o misto 0,774 (0,676–0,835). O achado desta seção está na leitura conjunta com a Tabela 4: o misto melhora MAE (7,03 para 6,69) e Pearson (0,784 para 0,818), mas mantém P_K praticamente idêntico, ou seja, o ganho é de escala e não de ordenação. No VitalDB, o ativo tem P_K 0,515 (0,434–0,581), indistinguível do acaso, e o misto 0,672 (0,591–0,737). Como P_K ignora erro sistemático, ele separa duas leituras que o MAE confunde [Smith et al. 1996].

**Figura 4. Probabilidade de predição P_K , ativo vs. misto.**

4.4. Bootstrap agrupado e sensibilidade ao offset

No Figshare, o ativo apresentou MAE observado 7,03 (IC percentil 95%: 6,38–8,24) e Pearson 0,784 (0,703–0,881); para o misto, os valores foram 6,69 (5,65–8,53) e 0,818 (0,751–0,890). No VitalDB, o ativo apresentou 12,43 (11,05–14,45) e 0,024 (–0,126–0,193), enquanto o misto apresentou 8,60 (7,57–9,95) e 0,688 (0,606–0,752). Os marcadores da Figura 5 são essas métricas observadas; somente as barras representam os intervalos das réplicas. As médias das réplicas bootstrap não substituem esses pontos observados.




Figura 5. Bootstrap agrupado por caso.

Na grade de offset, o ativo variou de MAE 7,22/Pearson 0,766 em -20 s para 7,03/0,784 em 0 s e 6,76/0,799 em $+20$ s. Um offset positivo associa a janela EEG a um BIS posterior. A Figura 6 mostra essa grade. A tendência foi observada pós-hoc, sem retreino, e não identifica causalmente atraso do monitor nem autoriza mudar o offset padrão. Contexto sobre atraso de índices processados em [Pilge et al. 2006].




Figura 6. Sensibilidade ao offset do rótulo.

4.5. Painéis de apoio: corpus, qualidade e projeção

As duas figuras seguintes detalham o que as tabelas e os agregados comprimem. A primeira caracteriza o corpus que alimenta o protótipo; a segunda documenta o comporta-

mento do treinamento e uma projeção declarada de planejamento. Os painéis de composição e de qualidade da Figura 7 e o histórico da Figura 8a documentam o corpus e o treinamento; somente a projeção da Figura 8b é cenário ancorado no MAE 7,03 medido, não curva observada.

A Figura 7a separa os casos por fonte em três estados mutuamente exclusivos. “Elegível” é o caso que passou por todos os gates de qualidade e entrou no pool de desenvolvimento; “quarentena” é o caso retido por falha de gate, como o Figshare 24, cuja escala de amplitude é incompatível; “benchmark histórico” é o caso reservado para avaliação, que não ajusta nenhum checkpoint. A leitura correta é de composição, não de desempenho: barras maiores não indicam melhor qualidade. A Figura 7b cruza a fração de amostras de EEG finitas (eixo horizontal) com a fração de janelas aceitas (eixo vertical) e mostra por que os dois gates não são redundantes. Um caso pode ter quase todo o EEG finito e ainda perder janelas por qualidade de sinal insuficiente; outro pode ter lacunas inválidas e ser retido antes da contagem. A linha tracejada marca o gate de 90% de amostras finitas; pontos à sua esquerda foram retidos independentemente do eixo vertical.




Figura 7. Composição e qualidade do corpus.

A Figura 8a acompanha a perda de treino e as métricas de validação por época. As duas curvas medem coisas diferentes: a perda de treino é a função otimizada (Smooth L1, adimensional, na escala normalizada) e tende a cair de forma monotônica, enquanto MAE e RMSE de validação são medidas em pontos BIS e podem oscilar por variação de amostragem entre épocas. Por isso, o critério de leitura é a validação, não a perda de treino; separadamente, a validação também serve para detectar sobreajuste, que apareceria como queda da perda de treino com piora simultânea do MAE de validação. Nesta execução

as três curvas ficam estáveis após poucas épocas, o que é consistente com o teto fixo de dez épocas adotado no protocolo. A Figura 8b projeta o MAE para contagens maiores de casos de treino por uma curva teórica ancorada no único ponto medido (13 casos de treino, MAE 7,03). O eixo horizontal é logarítmico porque o ganho por caso é decrescente; a curva não foi ajustada a dados novos, não substitui o holdout e serve apenas para dimensionar uma coleta futura [Archer et al. 2021].




Figura 8. Treinamento e projeção por casos.

5. Discussão e limitações

A degradação do ativo ao ir do Figshare para o VitalDB é evidência interna de sensibilidade à troca de fonte, não prova de qual diferença (equipamento, centro, ganho, montagem, população ou distribuição do BIS) a causou. A redução de erro do misto é compatível com adaptação após incorporar participantes VitalDB; como o benchmark é da mesma fonte e já havia sido observado, ele gera hipótese para uma nova coorte travada, não alegação de generalização externa [Lee et al. 2022, Collins et al. 2024, International Medical Device Regulators Forum 2025].

A melhora em 14/15 casos convive com piora no caso 16, e os agregados por janela privilegiam cirurgias longas; Pearson pode aumentar mesmo com viés ou discordância relevantes. A referência de 10 unidades usada em Métricas é escala de concordância entre medições do monitor, não limiar estatístico para MAE: dimensiona a ordem de grandeza do erro e não autoriza leitura clínica [Harada et al. 2021]. Métricas por participante e análises de acordo/calibração são extensões possíveis, não resultados demonstrados [Collins et al. 2024, Archer et al. 2021].

O bootstrap representa só a variabilidade de reamostrar os casos disponíveis sob o

algoritmo escolhido; não cobre incerteza de treinamento, seleção de checkpoint, hiperparâmetros, mudança de centro ou erro do rótulo BIS. O pequeno n Figshare e o reaproveitamento do benchmark VitalDB impedem leitura confirmatória [Field and Welsh 2007, Archer et al. 2021].

O alvo é a saída BIS, sensível a EMG, bloqueio neuromuscular, cetamina e atrasos; logo, baixo erro contra o monitor não equivale a medir consciência ou efeito farmacológico verdadeiro [Schuller et al. 2015, Hans et al. 2005, Pilge et al. 2006]. Faixas e limiares de qualidade do protótipo são heurísticas de engenharia, sem validação clínica. DOSE-I permanece tarefa separada para MOAA/S e estado de consciência, sem conversão artificial para BIS [Garbe et al. 2026].

A leitura ordinal separa dois diagnósticos que o MAE confunde: no VitalDB o ativo tem P_K 0,515, quase acaso, enquanto no Figshare alcança 0,773; o modelo não perdeu só calibração, perdeu a ordenação da profundidade. No Figshare o misto eleva Pearson sem mover P_K , distinguindo ajuste de escala de ganho de ordenação. Como a escala aqui é o BIS de referência, não um desfecho de resposta ao estímulo, esses valores não substituem validação clínica [Smith et al. 1996].

Em engenharia, a cadeia registra hashes, partições, pré-processamento, relatórios e replay. A trajetória individual mostra erros que os agregados ocultam, mas não substitui a análise entre casos. Investigar lacunas e concordância em dados secundários são extensões possíveis, não requisitos para concluir este TCC retrospectivo [Collins et al. 2024].

6. Conclusão

O BrainSniffer entrega um protótipo aberto e reproduzível para estimar uma referência BIS a partir de EEG frontal em arquivos e replay retrospectivo. Como sintetizado na Seção 4, o ativo superou o baseline espectral internamente, mas perdeu associação no VitalDB; o misto reduziu o erro após exposição a esse domínio, com heterogeneidade por caso e sem independência confirmatória. Os resultados são retrospectivos, exploratórios e limitados pelo rótulo, pelo número de casos, pelo reuso dos benchmarks e pela imputação offline.

A contribuição defensável é uma base auditável para formular e testar hipóteses, não um sistema clínico. O software não mede consciência, não prescreve dose, não controla bomba e não deve acionar alarme ou conduta. O TCC se encerra com a implementação documentada, a comparação existente e os limites explícitos; uma futura alegação de generalização exigiria avaliação independente [Collins et al. 2024].

Ética, governança e conformidade

Esta etapa usa os corpora secundários Figshare e VitalDB, cujas publicações e páginas oficiais identificam a origem dos dados, não a aprovação institucional deste projeto [Ma 2017, Lee et al. 2022, Lee and Jung 2022]. Não há coleta prospectiva nem intervenção, e nenhum parecer, aprovação ou dispensa institucional é presumido a partir da disponibilidade dos dados. Os termos de uso e o enquadramento ético devem ser confirmados pelo autor e pela instituição, conforme os procedimentos institucionais aplicáveis, antes de qualquer estudo futuro. A inferência ilustrativa em um caso não reexecuta o treinamento nem os benchmarks; a compilação não valida alterações simultâneas do sistema.

Referências

- Archer, L., Snell, K. I. E., Ensor, J., Hudda, M. T., Collins, G. S., and Riley, R. D. (2021). Minimum sample size for external validation of a clinical prediction model with a continuous outcome. *Statistics in Medicine*, 40(1):133–146. DOI: 10.1002/sim.8766.
- Avidan, M. S., Jacobsohn, E., Glick, D., et al. (2011). Prevention of intraoperative awareness in a high-risk surgical population. *New England Journal of Medicine*, 365:591–600. DOI: 10.1056/NEJMoa1100403.
- Avidan, M. S., Zhang, L., Burnside, B. A., et al. (2008). Anesthesia awareness and the bispectral index. *New England Journal of Medicine*, 358:1097–1108. DOI: 10.1056/NEJMoa0707361.
- Collins, G. S., Moons, K. G. M., Dhiman, P., et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378. DOI: 10.1136/bmj-2023-078378.
- Connor, C. W. (2022). Open reimplementa-tion of the BIS algorithms for depth of anesthesia. *Anesthesia & Analgesia*, 135(4):855–864. DOI: 10.1213/ANE.00000000000006119.
- Dahaba, A. A., Xue, J. X., Zhao, G. G., Liu, Q. H., et al. (2010). BIS-vista occipital montage in patients undergoing neurosurgical procedures during propofol-remifentanyl anesthesia. *Anesthesiology*, 112(3):645–651. DOI: 10.1097/ALN.0b013e3181cf4111.
- Field, C. A. and Welsh, A. H. (2007). Bootstrapping clustered data. *Journal of the Royal Statistical Society: Series B*, 69(3):369–390. DOI: 10.1111/j.1467-9868.2007.00593.x.
- Garbe, J., Nguyen, Q. V., Kantelhardt, J. W., Dünninghaus, F., Erffmeier, K., Seeliger, K., and Schmid, T. (2026). DOSE-I: A multimodal biosignal dataset of procedural sedation for endoscopy. Dataset, v1, 171 gravações. Licença CC BY 4.0 com Data_Use_Agreement.txt. Contexto MOAA/S; não usado no treino. DOI: 10.5281/zenodo.18483292.
- Hans, P., Dewandre, P.-Y., Brichant, J. F., and Bonhomme, V. (2005). Comparative effects of ketamine on bispectral index and spectral entropy of the electroencephalogram under sevoflurane anaesthesia. *British Journal of Anaesthesia*, 94(3):336–340. DOI: 10.1093/bja/aei047.
- Harada, H., Muta, S., Kakuma, T., et al. (2021). Accuracy of BIS monitoring using a novel interface device connecting conventional needle-electrodes and BIS sensors during frontal neurosurgical procedures. *PLoS ONE*, 16(10):e0258647. DOI: 10.1371/journal.pone.0258647.
- International Medical Device Regulators Forum (2025). Good machine learning practice for medical device development: Guiding principles. IMDRF/AIML WG/N88 FINAL:2025. Final de 29 jan. 2025. Portal: <https://www.imdrf.org>.
- Lee, H.-C. and Jung, C.-W. (2022). VitalDB, a high-fidelity multi-parameter vital signs database in surgical patients. v1.0.0. Espelho PhysioNet (LICENSE.txt CC BY 4.0); tracks via API oficial vitaldb.net sob CC BY-NC-SA 4.0. Mapa caseid-subjectid em clinical_data.csv. DOI: 10.13026/czw8-9p62.

- Lee, H.-C., Park, Y., Yoon, S. B., Yang, S. M., Park, D., and Jung, C.-W. (2022). VitalDB, a high-fidelity multi-parameter vital signs database in surgical patients. *Scientific Data*, 9:279. DOI: 10.1038/s41597-022-01411-5.
- Ma, L. (2017). EEG and BIS raw data. Dataset, v1, 24 arquivos. Licença CC BY 4.0. DOI: 10.6084/m9.figshare.5589841.v1.
- Myles, P. S., Leslie, K., McNeil, J., Forbes, A., and Chan, M. T. V. (2004). Bispectral index monitoring to prevent awareness during anaesthesia: the B-Aware randomised controlled trial. *The Lancet*, 363:1757–1763. DOI: 10.1016/S0140-6736(04)16300-9.
- Nsugbe, E. and Connelly, S. (2022). Multiscale depth of anaesthesia prediction for surgery using frontal cortex electroencephalography. *Healthcare Technology Letters*, 9:43–53. DOI: 10.1049/htl2.12025.
- Park, Y., Han, S.-H., Byun, W., Kim, J.-H., Lee, H.-C., and Kim, S.-J. (2020). A real-time depth of anesthesia monitoring system based on deep neural network with large EDO tolerant EEG analog front-end. *IEEE Transactions on Biomedical Circuits and Systems*, 14:825–837. DOI: 10.1109/TBCAS.2020.2998172.
- Pilge, S., Zanner, R., Schneider, G., Blum, J., Kreuzer, M., and Kochs, E. F. (2006). Time delay of index calculation: analysis of cerebral state, bispectral, and Narcotrend indices. *Anesthesiology*, 104(3):488–494. DOI: 10.1097/00000542-200603000-00016.
- Saeb, S., Lonini, L., Jayaraman, A., Mohr, D. C., and Kording, K. P. (2017). The need to approximate the use-case in clinical machine learning. *GigaScience*, 6. DOI: 10.1093/gigascience/gix019.
- Schuller, P. J., Newell, S., Strickland, P. A., and Barry, J. J. (2015). Response of bispectral index to neuromuscular block in awake volunteers. *British Journal of Anaesthesia*, 115(Suppl 1):i95–i103. DOI: 10.1093/bja/aev072.
- Shi, M., Huang, Z., Xiao, G., Xu, B., Ren, Q., and Zhao, H. (2023). Estimating the depth of anesthesia from EEG signals based on a deep residual shrinkage network. *Sensors*, 23(2):1008. DOI: 10.3390/s23021008.
- Shiraishi, T., Uchino, H., Sagara, T., and Ishii, N. (2004). A comparison of frontal and occipital bispectral index values obtained during neurosurgical procedures. *Anesthesia & Analgesia*, 98(6):1773–1775. DOI: 10.1213/01.ANE.0000121344.69058.09.
- Smith, W. D., Dutton, R. C., and Smith, N. T. (1996). Measuring the performance of anesthetic depth indicators. *Anesthesiology*, 84(1):38–51. DOI: 10.1097/00000542-199601000-00005.
- Sukriti, Kriplani, C., Kumar, S., and Singh, A. (2026). Predicting depth of anaesthesia from single-channel EEG using a deep TCN-BiLSTM-attention model with EWMA. *Scientific Reports*, 16:25470. DOI: 10.1038/s41598-026-54608-8.
- U.S. Food and Drug Administration and Covidien (2024). BIS Advance Monitoring System: K230693, Indications for Use. 510(k) premarket notification. URL: https://www.accessdata.fda.gov/cdrh_docs/pdf23/K230693.pdf.
- VitalDB (2026). Open dataset: overview and track list. <https://vitaldb.net/dataset/>. Licença CC BY-NC-SA 4.0 + Data Use Agreement; exige citação de Lee et al. 2022.