

BrainSniffer: protótipo reproduzível para estimar uma referência BIS a partir de EEG frontal

Bruno Rocha Guimarães¹

¹Ciência da Computação – Centro Universitário Jorge Amado
Salvador, Bahia – Brasil

Abstract. *This paper describes BrainSniffer, a reproducible engineering prototype that estimates a Bispectral Index (BIS) reference label from frontal electroencephalography (EEG). The pipeline uses five-second windows at 128 Hz, a compact one-dimensional convolutional neural network, and partitions grouped by case or subject. The active Figshare-only checkpoint reached mean absolute error (MAE) 7.03 and Pearson correlation 0.784 in a five-case Figshare holdout, but 12.43 and 0.024 in a 15-case VitalDB cross-dataset assessment, where ordinal prediction probability (P_k) dropped to 0.515, indistinguishable from chance. A mixed candidate trained with Figshare and part of VitalDB reached 6.69/0.818 on the Figshare benchmark and 8.60/0.688 on the historical VitalDB participant holdout, with no sustained difference from the active checkpoint on Figshare (paired Δ MAE 0.34, 95% CI $-0.28-0.81$); a causal per-case exponential smoothing (EWMA, exploratory, no retraining) lowers the mixed candidate to 5.84 (95% CI 4.56–7.62) and 7.89 (95% CI 6.86–9.38) (reference span 10), respectively. These results are retrospective and exploratory; Pearson is interpreted as association, not agreement. BrainSniffer neither measures consciousness nor supports clinical decisions, alarms, or drug dosing.*

Keywords: frontal EEG; BIS reference label; one-dimensional CNN; grouped validation; domain shift; causal smoothing; reproducibility.

Resumo. *Este artigo descreve o BrainSniffer, protótipo de engenharia reproduzível que estima, a partir de eletroencefalografia (EEG) frontal, um rótulo de referência do Índice Bispectral (BIS). O pipeline usa janelas de cinco segundos a 128 Hz, uma rede neural convolucional unidimensional compacta (1-D CNN) e partições agrupadas por caso ou pessoa. O checkpoint ativo, treinado apenas no Figshare, obteve erro absoluto médio (MAE) 7,03 e correlação de Pearson 0,784 em cinco casos Figshare, mas 12,43 e 0,024 na avaliação com 15 casos VitalDB, com P_K 0,515, indistinguível do acaso. Um candidato misto, treinado com Figshare e parte do VitalDB, obteve 6,69/0,818 no benchmark Figshare e 8,60/0,688 no holdout histórico VitalDB por participante, sem diferença sustentada em relação ao ativo no Figshare (Δ MAE pareado 0,34; IC 95% $-0,28-0,81$); uma suavização exponencial causal por caso (EWMA, exploratória, sem retreino) reduz o misto para 5,84 (IC 95% 4,56–7,62) e 7,89 (IC 95% 6,86–9,38) (span de referência 10). Os resultados são retrospectivos e exploratórios; Pearson é tratado como associação, não acordo. O BrainSniffer não mede consciência nem apoia decisão clínica, alarme ou dose.*

Palavras-chave: EEG frontal; rótulo BIS; CNN unidimensional; validação agrupada; mudança de domínio; reprodutibilidade.

1. Introdução

Na anestesia geral, é preciso saber se o paciente está suficientemente hipnotizado sem exagerar na dose, e para isso usam-se referências objetivas de profundidade. O Índice Bispectral (Bispectral Index, BIS), calculado a partir da eletroencefalografia (EEG) frontal, é a referência mais usada à beira do leito, mas é uma saída proprietária: sua regra de combinação não é publicada e não pode ser reproduzida exatamente a partir do sinal. Modelos que tentam aproximar esse rótulo enfrentam ainda um risco metodológico silencioso: janelas vizinhas da mesma cirurgia são quase idênticas, então uma partição aleatória entre treino e teste mede o reconhecimento de casos já vistos, não a generalização. Falta um protótipo reproduzível que estime esse rótulo com partições por caso, um controle espectral e avaliação entre fontes; este trabalho apresenta o BrainSniffer, com esse desenho.

A pesquisa responde a duas perguntas. (i) Quanto uma rede neural convolucional unidimensional compacta (1-D CNN) aproxima o rótulo BIS em casos não usados no ajuste, comparada a um controle mais simples baseado em medidas espectrais (baseline espectral)? (ii) Esse desempenho se mantém ao trocar a fonte dos dados, do Figshare para o VitalDB, com outro equipamento, montagem e população? O objetivo geral é avaliar essa aproximação de forma reproduzível. Os objetivos específicos são: comparar a CNN ao baseline espectral no holdout Figshare; quantificar a degradação do modelo ao aplicá-lo ao VitalDB; testar se incorporar parte do VitalDB ao treino (candidato misto) reduz o erro; e caracterizar a ordenação das estimativas (probabilidade de predição P_K) e a incerteza da avaliação (bootstrap agrupado de casos); além disso, testar o efeito de uma suavização causal (EWMA) sobre as predições congeladas.

Vale fixar o vocabulário: o modelo estima um rótulo de referência derivado do BIS, não o BIS como grandeza independente, porque o próprio BIS é a saída de um monitor sobre o mesmo sinal. A contribuição é uma cadeia com partições por grupo, controle espectral, comparação entre fontes, análise de incerteza e suavização causal exploratória. O escopo deste trabalho é avaliar essa cadeia, não desenvolver um dispositivo médico. A Seção 2 fundamenta o índice BIS e o problema do vazamento entre janelas; a Seção 3 descreve materiais e métodos; a Seção 4 apresenta os resultados; a Seção 5 discute limitações; e a Seção 6 conclui.

2. Fundamentação e trabalhos relacionados

2.1. O índice BIS e seus limites

O Índice Bispectral (Bispectral Index, BIS) é uma saída proprietária calculada a partir da eletroencefalografia (EEG), o registro da atividade elétrica cerebral captada no couro cabeludo; a formulação deriva da análise bispectral do EEG e de suas primeiras aplicações clínicas [Johansen and Sebel 2000]. Sua escala vai de 0, próximo de silêncio elétrico, a 100, tipicamente associado à vigília; a faixa intermediária costuma ser usada como referência de hipnose em anestesia geral, sem que isso defina um limiar clínico único ou uma fronteira nítida entre estados. O cálculo combina características no domínio do tempo e da frequência (incluindo componentes bispectrais e de supressão de surto) por uma regra de combinação não publicada; por ser fechado, o índice não pode ser reproduzido exatamente a partir do EEG, e qualquer modelo treinado contra ele herda esse limite. O BIS é indicado apenas como auxílio, em contexto e sob supervisão definidos, não como medida

direta de consciência, de adequação anestésica ou de dose. Sua leitura varia com a atividade elétrica muscular (eletromiografia, EMG), o bloqueio neuromuscular, os fármacos usados e o atraso de processamento: estudos controlados documentaram queda do índice após bloqueio em voluntários acordados, resposta paradoxal à cetamina e atrasos distintos entre monitores processados [U.S. Food and Drug Administration and Covidien 2024, Connor 2022, Schuller et al. 2015, Hans et al. 2005, Pilge et al. 2006]. Ensaios com protocolos guiados pelo índice também produziram resultados que dependem do grupo de comparação e da população, o que impede extrapolar um único número para benefício clínico universal [Myles et al. 2004, Avidan et al. 2008, Avidan et al. 2011]. Além disso, o BIS chega suavizado e com atraso [Pilge et al. 2006]: comparar predições brutas de janela única a esse alvo superestima a oscilação do modelo, e a suavização causal é prática comum em trabalhos recentes no mesmo corpus [Sukriti et al. 2026].

2.2. Vazamento entre janelas e partição por grupo

Redes profundas já foram estudadas com alvos, canais, populações e equipamentos distintos para aproximar índices derivados de EEG [Park et al. 2020, Shi et al. 2023]. O problema é que janelas vizinhas da mesma cirurgia são parecidas entre si em amplitude, espectro e nível de BIS, porque refletem o mesmo paciente no mesmo plano anestésico. Se essas janelas forem espalhadas aleatoriamente entre treino e teste, o teste contém trechos quase idênticos aos de treino, e a métrica mede a capacidade de reconhecer um caso já visto, não de generalizar: é o vazamento (*leakage*), que infla o desempenho de forma silenciosa. Para evitar isso, este trabalho separa os dados por caso ou por pessoa (o grupo), de modo que nenhum grupo contribua simultaneamente para treino e para teste; o custo é uma estimativa mais pessimista e mais realista do uso em um caso novo. Essa unidade de separação altera a estimativa de desempenho [Sukriti et al. 2026, Saeb et al. 2017].

2.3. Corpora, transparência e relato de modelos

O conjunto “EEG and BIS raw data” reúne 24 casos anônimos com EEG frontal e valores BIS, publicado no repositório Figshare sob licença CC BY 4.0 [Ma 2017]. Um estudo anterior no mesmo corpus usou características multiescala com análise discriminante linear (LDA) e sustenta a descrição do corpus, mas não é evidência de rede convolucional [Nsugbe and Connelly 2022]. Outros estudos estimaram a concentração anestésica derivada de EEG com cadeia dedicada e o índice de estado do paciente (Patient State Index, PSI) com quatro canais em 18 idosos sedados; ambos demonstram viabilidade em configurações específicas, sem comparabilidade direta com o rótulo, o canal ou a população deste trabalho [Park et al. 2020, Shi et al. 2023].

O VitalDB é um banco de sinais perioperatórios de milhares de cirurgias e inclui os canais de EEG frontal e de BIS usados aqui [Lee et al. 2022, VitalDB 2026]. O conjunto aberto exige licença CC BY-NC-SA 4.0 e acordo de uso de dados, sem redistribuição. Escala, equipamento, montagem e população diferem do Figshare; por isso, o VitalDB informa a sensibilidade à troca de fonte de dados, sem isolar a causa. As fontes também diferem no instrumento do rótulo: o corpus Figshare registra BIS a cada 5 s por sensor BIS Quatro (Aspect Medical Systems) [Ma 2017, Sukriti et al. 2026], enquanto o VitalDB registra BIS numérico de 1 s de monitores BIS Vista (Covidien/Medtronic) [VitalDB 2026, Lee et al. 2022]; versões de algoritmo e suavização não são públicas, então o rótulo não é o mesmo instrumento entre as fontes. O conjunto DOSE-I (Zenodo,

CC BY 4.0) não foi incorporado à regressão porque usa uma escala clínica de sedação por observação (Modified Observer’s Assessment of Alertness/Sedation, MOAA/S) e estado de consciência, não conversíveis em BIS [Garbe et al. 2026].

Uma reimplementação aberta do algoritmo do índice não torna um regressor treinado contra o BIS equivalente a um monitor [Connor 2022]. Independência entre desenvolvimento e avaliação, descrição de grupos e análise de acordo e calibração são centrais no relato de modelos [Collins et al. 2024, Archer et al. 2021].

3. Materiais e métodos

Para reduzir a ambiguidade dos nomes usados neste artigo, a Tabela 1 resume as fontes vistas no treinamento e os conjuntos de avaliação de cada checkpoint. Os dois checkpoints respondem a perguntas diferentes. O “ativo” foi ajustado apenas no Figshare e testa o limite do modelo dentro da própria fonte e a sua queda ao mudar de corpus; o “misto” foi ajustado também com parte do VitalDB e testa se incorporar a fonte de destino reduz o erro. Como o misto viu o domínio VitalDB, o desempenho dele nessa fonte não mede transporte para uma fonte nova. “Ativo” e “misto” são apenas abreviações desses dois modelos.

Tabela 1. Definição conceitual dos dois checkpoints.

Modelo	Treinado com	Avaliado em
Modelo A – Figshare (ativo)	Figshare	Figshare (holdout por caso) e VitalDB (avaliação cruzada de dataset)
Modelo B – misto	Figshare + parte do VitalDB	Figshare (benchmark histórico) e VitalDB (holdout histórico por participante)

A Figura 1 resume esse fluxo retrospectivo, da composição do pool à avaliação sem reajuste.

3.1. Fontes, unidades de agrupamento e partições

Cada arquivo é uma gravação inteira, tratada como um caso; de cada caso saem janelas de 5 s, unidades de treino e de métrica. O grupo é a unidade que nunca cruza partições. O corpus tem 59 arquivos: 44 no pool de desenvolvimento e 15 casos VitalDB congelados. Os gates de qualidade são filtros prévios ao ajuste que descartam casos ou janelas com escala problemática, valores inválidos ou sinal insuficiente; depois deles, 23 casos Figshare e dez VitalDB ficaram elegíveis: 33 casos e 55.471 janelas. Janelas medem volume disponível, não desempenho, e casos longos pesam mais. No Figshare não há identificador de participante; agrupar por cirurgia evita compartilhar janelas da mesma gravação, mas não prova independência entre cirurgias da mesma pessoa. No VitalDB o agrupamento usa o identificador de participante e reúne reoperações conhecidas [Ma 2017, Lee et al. 2022].

O checkpoint ativo foi desenvolvido só com os 23 casos Figshare elegíveis, divididos com seed 42 em 13 de treino, cinco de validação e cinco de teste. O candidato misto fixo excluiu os cinco casos do holdout Figshare histórico e usou 18 grupos Figshare mais dez VitalDB: 28 grupos e 49.948 janelas, com partição registrada de 16/6/6 grupos. O ajuste usa 12 casos Figshare e quatro participantes VitalDB (34.792 janelas); a validação,




Figura 1. Fluxo retrospectivo auditável do BrainSniffer.

dois Figshare e quatro VitalDB (7.235); o teste interno, quatro Figshare e dois VitalDB (7.921). O treino atualiza os pesos, a validação apoia a parada e só o teste interno é lido como resultado; por isso as janelas de validação não aparecem nas tabelas. As contagens seguem o protocolo de partição; dizer “corpus de 28 grupos” não significa que os 28 entraram no ajuste.

Os mesmos cinco casos Figshare são o benchmark histórico dos dois checkpoints. Para o ativo, os 15 casos VitalDB são avaliação cruzada de dataset. Para o misto, esses 15 participantes não entraram no ajuste, mas vêm da mesma fonte do desenvolvimento e o benchmark já havia sido inspecionado antes da criação do candidato; por isso ele é descrito como holdout VitalDB histórico, por participante e após exposição ao domínio, não como validação externa confirmatória. Manter o candidato fora do painel de demonstração não restaura a independência de benchmarks já inspecionados [Collins et al. 2024, International Medical Device Regulators Forum 2025]. Os IDs ficam registrados: o holdout Figshare usa os casos 3, 4, 5, 9 e 19; os 15 congelados do VitalDB são os arquivos numerados de 1 a 17, excluídos o 11 (sem os dois tracks necessários) e o 15 (sem os tracks de EEG frontal e BIS requeridos pelo protocolo).

3.2. Tarefa, pré-processamento e qualidade

Cada exemplo é um trecho curto de EEG: 640 amostras, isto é, uma janela de 5 segundos amostrada a 128 Hz, com passo de 5 s na construção offline. Para cada início t , o alvo corresponde a $t + \text{offset}$, arredondado ao intervalo do BIS do caso (5 s no Figshare e 1 s nos arquivos VitalDB normalizados). Como a emissão só pode ocorrer depois de completar a janela (aproximadamente em $t + 5$ s) e somar o tempo de processamento, com offset zero o sistema não faz previsão de um BIS futuro nem leitura contemporânea ao fim da janela. O pipeline mantém a banda de 0,5–45 Hz, remove a interferência da rede elétrica (notch de 50 Hz, filtro de quarta ordem) e aplica a escala de amplitude registrada, com o rótulo BIS associado ao início da janela (offset padrão 0 s). O filtro usa apenas amostras passadas e presentes (estado causal), preservado por caso e entre blocos; uma rota de fase

zero existe somente para análise offline explícita. Essas escolhas seguem o protocolo do estudo, não uma definição das fontes externas [Ma 2017, Nsugbe and Connolly 2022].

O controle de qualidade do corpus exige, entre outros critérios internos, pelo menos 90% de EEG com valores finitos, lacuna inválida máxima de 2 s, qualidade global mínima 0,35, pelo menos 80% de BIS válido e qualidade mínima 0,20 por janela; o caso Figshare 24 está em quarentena por escala incompatível. Esses limiares são heurísticas não calibradas para risco clínico; no replay, trechos inválidos são rejeitados antes do filtro e trechos de baixa qualidade levam à abstenção.

Esse controle não se aplica aos 15 casos do benchmark VitalDB histórico. Na construção offline, valores não finitos são preenchidos por interpolação linear entre vizinhos válidos, repetindo o extremo nas bordas, sem limite de lacuna e podendo usar amostras futuras, mesmo com filtro causal; vetor todo inválido vira zeros. A qualidade é calculada sobre a janela bruta, e BIS inválido ou fora de $[0, 100]$ é descartado. Antes disso, a normalização ordena os dados e interpola o BIS válido para uma grade de 1 s entre o primeiro e o último ponto, sem limite de lacuna e sem máscara persistida (válido significa finito). Como os 15 arquivos contêm EEG inválido, sua avaliação offline difere da política de rejeição do replay; o preenchimento pode suavizar lacunas longas e limita a interpretação, mas política e métricas históricas foram mantidas.

3.3. Modelos e treinamento

A CNN histórica recebe a janela de 640 amostras em um canal, é treinada com perda Smooth L1 (os braços novos do experimento fatorial usam Huber com $\delta = 5$) e tem saída sigmoidal escalada para $[0, 100]$. A Tabela 2 explicita a arquitetura e os parâmetros registrados no protocolo, sem carregar pesos. Recursos posteriores do treinador e arquiteturas opcionais não são atribuídos retroativamente a esses pesos.

Tabela 2. Configuração histórica dos checkpoints.

Item	Configuração registrada
Convolucionais	Canais 1→32→64→128→128; <i>kernel</i> 7, 7, 5, 5; <i>padding</i> 3, 3, 2, 2; <i>stride</i> 1; normalização em lote + GELU
<i>Pooling</i> e cabeça	max-pooling de fator 2 nos 3 primeiros blocos; pooling médio global; camada densa 128–64–1, GELU, <i>dropout</i> 0,20
Treino (ambos)	10 <i>epochs</i> , <i>batch</i> 128, <i>lr</i> 10^{-3} , <i>wd</i> 10^{-4} , <i>seed</i> 42; validação/teste: 20% dos grupos em cada partição
Amostragem	Misto: balanceada por grupo/fonte; ativo: não registrada
Amplitude e <i>notch</i>	<i>Clip</i> $\pm 100 \mu V$, divisor de escala $50 \mu V$, saída em $[-5, 5]$; <i>notch</i> 50 Hz, <i>Q</i> =30
<i>Random Forest</i>	100 árvores, profundidade máxima 12, mínimo de 2 amostras por folha, semente 42

A arquitetura compacta permite replay em CPU, mas não implica superioridade sobre redes temporais, atenção ou representações tempo-frequência [Park et al. 2020, Shi et al. 2023].

Como controle simples, o baseline espectral resume cada janela de 5 s em 14 atributos clássicos: potências absoluta e relativa das bandas delta (0,5–4 Hz), teta (4–8 Hz), alfa (8–13 Hz), beta (13–30 Hz) e gama (30–45 Hz), frequência de borda espectral em 90% (SEF90), entropia espectral, valor eficaz (RMS) e *line length*. Uma floresta aleatória (*Random Forest*, configuração na Tabela 2) é ajustada nas mesmas 15.894 janelas de

treino e avaliada nas mesmas 5.523 janelas de teste do holdout Figshare, sem acesso a informação adicional e herdando a mesma proteção contra vazamento da partição agrupada por caso. O controle responde a uma pergunta prática: se poucas medidas de espectro já alcançam erro parecido, a complexidade da CNN precisa ser justificada; se a CNN supera o controle, há indício de que a representação aprendida captura estrutura além do espectro clássico.

3.4. Métricas, incerteza e análises exploratórias

Foram calculados o erro absoluto médio (Mean Absolute Error, MAE), a raiz do erro quadrático médio (Root Mean Squared Error, RMSE), o viés, a correlação de Pearson e o coeficiente de concordância de Lin (CCC, que penaliza viés e diferença de escala além da associação) para o rótulo contínuo, além de acurácia e macro-F1 para quatro faixas de BIS. Em leitura simples: RMSE penaliza mais os erros grandes e macro-F1 é o acerto médio entre faixas. As métricas incluem MAE e RMSE, definidos por

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (1)$$

O desfecho primário é o MAE agregado por janela; as demais métricas são secundárias ou exploratórias, sem correção para multiplicidade. O resultado principal agrega todas as janelas aceitas (casos longos pesam mais), em vez de tirar a média por pessoa. O P_K e o Pearson agregados empilham todas as janelas antes de comparar pares, de modo que pares entre casos distintos (com distribuições de BIS distintas) também entram na conta; por isso a Seção 4 apresenta, ao lado do agregado, a mediana e a amplitude por caso. As faixas são $[0, 40)$, $[40, 60)$, $[60, 80)$ e $[80, 100]$, aqui lidas com rótulos curtos apenas para comunicação (profunda, geral adequada, leve/transicional e acordado), sem validar limiar clínico. Pearson quantifica associação linear e não acordo; a concordância é analisada separadamente por inclinação de calibração, limites de concordância, ICC(2,1) e fração de $|\text{erro}| \leq 10$, tudo exploratório. As quatro faixas são apenas uma apresentação interna e não constituem classes clínicas independentes [Collins et al. 2024].

A associação ordinal entre estimativa e referência é medida pela probabilidade de predição P_K (na literatura de anestesia, P_K), proposta por Smith, Dutton e Smith [Smith et al. 1996] como variante reescalada da medida $d_{y,x}$ de Kim. A pergunta que ela responde é direta: sorteados dois momentos com profundidades de referência distintas, qual é a chance de o indicador ordená-los na mesma ordem da referência? Vale 1 na ordem perfeita e 0,5 no acaso, como cara-ou-coroa.

Na prática, pares com o mesmo BIS de referência são excluídos (não informam ordenação) e pares empatados no indicador contam 0,5. Por depender só da ordem, P_K ignora erro sistemático de escala: um modelo que erra sempre por 10 pontos, mas preserva a ordem, pode ter P_K alto com MAE ruim.

Os intervalos de P_K vêm de reamostragem de casos ($B = 1.000$, seed 42), na mesma unidade agrupada do bootstrap [Smith et al. 1996].

O bootstrap estima a incerteza sorteando casos inteiros com reposição, juntando todas as janelas sorteadas e recalculando a métrica. Assim, respeita melhor a dependência dentro de cada caso do que sortear janelas, mas o resultado continua ponderado pela

duração. Foram usadas $B = 1.000$ réplicas, seed 42 e percentis 2,5/97,5 para o intervalo de 95%. Com apenas cinco casos Figshare, o intervalo é exploratório; 1.000 réplicas não equivalem a 1.000 casos [Field and Welsh 2007, Archer et al. 2021].

Como referência externa, estudos de acurácia do próprio BIS tratam diferenças de até 10 unidades entre duas medições do monitor como aceitáveis [Dahaba et al. 2010, Shiraishi et al. 2004, Harada et al. 2021]; como o alvo já varia nessa ordem, um MAE da mesma magnitude fica dentro da variabilidade do rótulo; o valor é escala de leitura, não limiar clínico.

A comparação VitalDB também foi calculada por caso, pareando as janelas de cada caso. A análise de sensibilidade reaplicou o checkpoint ativo aos mesmos cinco casos Figshare, sem retreino, em uma grade de -20 a $+20$ s. Como a grade foi examinada após o treinamento, ela formula hipótese sobre alinhamento e não escolhe o atraso do rótulo [Pilge et al. 2006]. Deslocamentos positivos associam cada janela a um BIS futuro, indisponível no instante de emissão, e por isso não alteram o offset zero do replay.

3.5. Replay retrospectivo e trajetória ilustrativa

Replay significa percorrer uma gravação existente, não adquirir EEG: preenche-se um buffer de 5 s e depois emite-se atualização a cada 1 s, separando valor bruto, média móvel exponencial (Exponentially Weighted Moving Average, EWMA), qualidade, instante e origem. O escopo deste trabalho é exclusivamente retrospectivo, sem conexão a EEG físico. A implementação distingue o instante de emissão do alvo histórico no início da janela.

Para visualizar o comportamento temporal, fixou-se antes da inferência o caso 19 do holdout Figshare (escolha declarada antes da inferência e não guiada pelo desempenho), usando toda a gravação (4.355 s). O procedimento reutiliza o construtor de janelas, a configuração do checkpoint ativo e inferência em CPU, sem treino. A curva bruta (sem EWMA) é posicionada no instante do alvo offline (início mais offset 0 s), em passos de 5 s; não representa disponibilidade sem atraso. Métricas e hashes ficam registrados na auditoria; a execução padrão não faz inferência nem download.

3.6. Suavização causal (EWMA) das predições

Como o alvo é uma saída já suavizada pelo monitor, o pipeline também permite uma média móvel exponencial causal por caso (EWMA), aplicada às predições congeladas, sem retreino: $s_t = \alpha y_t + (1 - \alpha)s_{t-1}$, com $\alpha = 2/(\text{span} + 1)$ e reinício por caso; o *span* é medido em janelas de 5 s e $\text{span} = 1$ reproduz a predição bruta. Usar apenas amostras passadas mantém o caminho compatível com o replay. A varredura de spans é retrospectiva e exploratória (examinada após os resultados; não reescolhe checkpoint, treino ou arquitetura), seguindo a prática de suavização temporal de trabalhos contemporâneos [Sukriti et al. 2026, Pilge et al. 2006].

4. Resultados

4.1. Checkpoint ativo e baseline no Figshare

No holdout Figshare do checkpoint ativo, cinco casos e 5.523 janelas produziram MAE 7,03, RMSE 11,08, viés 0,79 e Pearson 0,784. A acurácia por faixa foi 0,585 e o macro-F1

0,548. O baseline espectral, na mesma partição, obteve MAE 8,86, RMSE 13,23, Pearson 0,667, acurácia 0,540 e macro-F1 0,480. No bootstrap pareado por caso, o ΔMAE favorável à CNN é $-1,84$ (IC 95% $-2,37$ — $-0,66$) e o ΔP_K é $+0,051$ ($0,012$ — $0,081$); os intervalos excluem zero, mas com cinco casos o teste é exploratório. A Tabela 3 resume o agregado.

Tabela 3. Holdout Figshare comum (5 casos, 5.523 janelas; MAE e RMSE em pontos BIS).

Modelo	MAE	RMSE	Pearson	Acurácia	Macro-F1
CNN ativa	7,03	11,08	0,784	0,585	0,548
Baseline espectral	8,86	13,23	0,667	0,540	0,480

A Figura 2 mostra queda inicial e elevação final em ambas as curvas, mas a CNN superestima o patamar intermediário e não reproduz várias oscilações da referência. Nas 850 janelas aceitas, MAE 8,72, RMSE 10,21, viés $+4,79$ e Pearson intra-caso 0,910: associação alta não elimina erro sistemático; é exemplo ilustrativo, não evidência de generalização. Das 871 janelas completas, 21 foram rejeitadas por qualidade e 56 posições ficaram sem previsão (NaN).

4.2. Comparação dos checkpoints nos benchmarks históricos

O candidato misto apresentou MAE 6,69, RMSE 10,67, viés 2,12, Pearson 0,818 e macro-F1 0,574 no holdout Figshare. Nos 15 participantes e 38.730 janelas do holdout VitalDB histórico, obteve 8,60, 11,74, $-1,01$, 0,688 e 0,486. O ativo obteve, respectivamente, 7,03/11,08/0,79/0,784/0,548 no Figshare e 12,43/18,80/1,40/0,024/0,398 no VitalDB. A Tabela 4 organiza esses agregados. Três dos quatro MAE ficam abaixo de 10 unidades BIS (6,69; 7,03 e 8,60), a faixa de variabilidade do próprio monitor [Harada et al. 2021], inclusive o do misto nessa fonte, embora ele tenha visto participantes dela no ajuste; o ativo no VitalDB (12,43) ultrapassa essa escala, compatível com a perda de ordenação medida pelo P_K . No mesmo corpus, a entropia amostral com floresta aleatória reportou MAE 5,22 [Liu et al. 2018] (o baseline deste trabalho, de família semelhante, obtém 8,86 em partição agrupada por caso; o protocolo exato do estudo original não foi verificado para caracterização aqui). Um modelo contemporâneo de maior capacidade no mesmo corpus (TCN-BiLSTM com atenção, cerca de 1,07 milhão de parâmetros, 120 épocas, perda de Huber com $\delta = 5$) reportou MAE 4,499 em divisão por segmentos e $6,03 \pm 0,38$ sob GroupKFold por sujeito com suavização EWMA, com CCC de Lin $0,819 \pm 0,050$ [Sukriti et al. 2026]; o BrainSniffer, com 0,15 milhão de parâmetros, dez épocas e perda Smooth L1, sem suavização, fica em 6,69–7,03 nos números brutos. A comparação é de ordem de grandeza, não direta: diferem a normalização (winsorização em $\pm 200 \mu V$ com z-score por sujeito e estatísticas do próprio split contra clip em $\pm 100 \mu V$ com escala fixa de $50 \mu V$), a seleção da suavização (busca em grade na validação contra varredura pós-hoc no benchmark), a agregação ($\pm$ entre folds contra bootstrap por caso) e a medida de acordo (CCC de Lin contra ICC). O mesmo descompasso entre agregado por janela e média por sujeito aparece lá (6,03 agregado contra 6,31 média por sujeito no melhor kernel), reforçando que a unidade de agregação altera a leitura; e a diferença entre kernels não foi significativa sob o protocolo agrupado (Friedman $p = 0,453$), o que desautoriza ranking entre arquiteturas.




Figura 2. Trajetória offline do caso 19 do Figshare: referência e predição bruta (topo) e erro por janela (base).

Tabela 4. Comparação retrospectiva nos benchmarks históricos; 5 casos no benchmark Figshare e 15 no VitalDB; MAE em pontos BIS; IC 95% por bootstrap agrupado por caso; o RF espectral viu apenas o Figshare.

Benchmark	Modelo (fontes vistas)	MAE (IC 95%)	Pearson (IC 95%)	P_K (IC 95%)
Figshare	ativo (Figshare)	7,03 (6,38–8,24)	0,784 (0,703–0,881)	0,773 (0,679–0,828)
Figshare	misto (Figshare+VitalDB)	6,69 (5,65–8,53)	0,818 (0,751–0,890)	0,774 (0,676–0,835)
VitalDB	ativo (Figshare)	12,43 (11,05–14,45)	0,024 (–0,126–0,193)	0,515 (0,434–0,581)
VitalDB	misto (Figshare+VitalDB)	8,60 (7,57–9,95)	0,688 (0,606–0,752)	0,672 (0,591–0,737)
VitalDB	RF espectral	13,62 (11,98–16,01)	–0,036 (–0,162–0,111)	0,502 (0,447–0,551)

O baseline espectral também foi reavaliado nos 15 casos VitalDB, com o mesmo ajuste e protocolo: MAE 13,62 (11,98–16,01), Pearson $-0,04$ e P_K 0,502, no nível do acaso, e a CNN ativa ainda o supera ($\Delta\text{MAE} -1,19$; IC $-2,13$ – $-0,34$); o colapso no transporte não é específico da CNN. No bootstrap pareado por caso ($\Delta = \text{ativo} - \text{misto}$), o misto melhora o VitalDB ($\Delta\text{MAE} +3,83$, IC $2,95$ – $4,94$; $\Delta P_K -0,157$, IC $-0,216$ – $-0,083$; 14/15 casos, $p < 0,001$), enquanto no Figshare MAE e P_K não sustentam ganho ($\Delta\text{MAE} 0,34$, IC $-0,28$ – $0,81$; ΔP_K IC $-0,013$ – $0,007$).

No VitalDB, o MAE do candidato caiu em 14 dos 15 casos pareados (sinal exato bilateral $p = 0,001$; leitura descritiva, sem valor confirmatório); no caso 16 do VitalDB, subiu cerca de 0,67 ponto BIS. Na Figura 3c, cada linha é um caso, ordenado pela diferença misto menos ativo; linhas à esquerda indicam menor MAE do misto. A leitura é pareada de propósito, para que um grupo de casos longos não domine a comparação, e revela a heterogeneidade: o ganho não é uniforme, e 14 acertos contra 1 piora convivem com margens pequenas. Como os agregados são calculados por janela, a média pode não corresponder à de um caso típico; essa comparação descreve adaptação após exposição ao VitalDB, não transporte para nova fonte.

4.3. Probabilidade de predição P_K

A associação ordinal é medida pela probabilidade de predição P_K de Smith, Dutton e Smith [Smith et al. 1996]: com que frequência o indicador ordena corretamente duas profundidades observadas distintas? A Tabela 4 e a Figura 4 trazem os valores e os intervalos de 95%. No Figshare (Figura 4), o ativo obtém P_K 0,773 (0,679–0,828) e o misto 0,774 (0,676–0,835). O achado desta seção está na leitura conjunta com a Tabela 4: o misto reduz o MAE (7,03 para 6,69) e eleva o Pearson (0,784 para 0,818), mas mantém P_K praticamente idêntico (0,773 para 0,774): não há evidência de mudança na ordenação, e as diferenças são pequenas frente à incerteza dos intervalos. No VitalDB, o ativo tem P_K 0,515 (0,434–0,581), indistinguível do acaso, e o misto 0,672 (0,591–0,737). Como P_K ignora erro sistemático, ele separa duas leituras que o MAE confunde [Smith et al. 1996]. Por caso, o P_K do ativo no VitalDB varia de 0,39 a 0,74 (mediana 0,48) e o do misto, de 0,48 a 0,81 (mediana 0,67); no Figshare, as medianas por caso são 0,80 (ativo) e 0,81 (misto), próximas aos agregados 0,773 e 0,774.

4.4. Bootstrap agrupado e sensibilidade ao offset

A Tabela 4 reúne os intervalos de 95%; na Figura 5, as barras são réplicas e os marcadores, as métricas observadas.

Na grade de offset, o ativo variou de MAE 7,22/Pearson 0,766 em -20 s para 7,03/0,784 em 0 s e 6,76/0,799 em $+20$ s. Um offset positivo associa a janela EEG a um BIS posterior. A Figura 6 mostra essa grade. A tendência foi observada pós-hoc, sem retreino, e não identifica causalmente atraso do monitor nem autoriza mudar o offset padrão. Contexto sobre atraso de índices processados em [Pilge et al. 2006].

4.5. Experimento fatorial inspirado no modelo contemporâneo

Para testar se as escolhas do modelo contemporâneo transferem ganho para esta cadeia, quatro braços foram treinados do zero no Figshare (mesmo split 13/5/5 por caso, seed 42, checkpoints novos sem tocar nos históricos): A (baseline reproduzido: Smooth L1, dez




Figura 3. Agregados por janela e MAE pareado por caso; em (c), cada ponto é um caso e linhas à esquerda indicam menor MAE do misto.




Figura 4. Probabilidade de predição P_K , ativo vs. misto.




Figura 5. Bootstrap agrupado por caso.




Figura 6. Sensibilidade ao offset do rótulo; eixos ampliados (variação total $\leq 0,5$ ponto de MAE e $0,04$ de Pearson).

épocas, batch 128, clip $\pm 100 \mu V$, sem winsor); B (A com winsorização causal $\pm 200 \mu V$ e clip elevado a $\pm 300 \mu V$, para o winsor ter efeito próprio); C (B com perda de Huber $\delta = 5$, até 120 épocas com paciência 18, batch 64 e paciência 6 no agendador); e D (C com z-score por sujeito, com média e desvio estimados somente no split de treino, congelados no checkpoint e fallback global para sujeito novo). Cada braço foi avaliado nos mesmos benchmarks (cinco Figshare e 15 VitalDB congelados), com CCC de Lin e média por caso ao lado do agregado por janela. A Tabela 5 resume os números brutos, sem EWMA.

O braço A reproduziu o histórico (Figshare 7,03/0,780/0,777 de CCC/0,773 de P_K ; VitalDB 12,64/0,056/0,051/0,524), validando o harness. O winsor isolado (B) piorou o Figshare (8,19; IC 95% 6,78–10,01) com viés $-3,17$, sem mover o VitalDB (12,04); ou seja, elevar o clip e winsorizar, sozinhos, não ajudam e deslocam a escala. O treino longo com Huber (C) foi o único ganho real no Figshare: 6,63 (IC 95% 6,03–7,67), Pearson 0,824, CCC 0,820 e P_K 0,780, com 46 épocas efetivas (parada na 28 por paciência); no VitalDB, porém, ficou em 12,61, indistinguível do baseline. O z-score por sujeito (D) elevou Pearson (0,833) e CCC (0,830) no Figshare sem reduzir o MAE (7,14; IC 95% 5,75–7,86), e no VitalDB ficou em 12,41: melhora acordo linear, não erro absoluto, e não restaura transporte. Em todos os braços novos, a média por caso no VitalDB (13,4–14,2) supera o agregado (12,0–12,6), reforçando que casos longos puxam o agregado para baixo. Nenhum braço novo foi submetido ao EWMA; a comparação com os números suavizados da Seção 4.6 é, portanto, entre bruto novo e suavizado histórico, sem inferência direta.

Tabela 5. Braços fatoriais novos (brutos, sem EWMA); MAE em pontos BIS; IC 95% por bootstrap agrupado por caso; CCC é o coeficiente de Lin.

Benchmark	Braço	MAE (IC 95%)	Pearson	CCC	P_K
Figshare	A (reprodução)	7,03 (6,36–8,27)	0,780	0,777	0,773
Figshare	B (winsor)	8,19 (6,78–10,01)	0,699	0,661	0,758
Figshare	C (Huber+longo)	6,63 (6,03–7,67)	0,824	0,820	0,780
Figshare	D (z por sujeito)	7,14 (5,75–7,86)	0,833	0,830	0,772
VitalDB	A (reprodução)	12,64 (11,38–14,43)	0,056	0,051	0,524
VitalDB	B (winsor)	12,04 (10,89–13,74)	0,238	0,194	0,528
VitalDB	C (Huber+longo)	12,61 (11,40–14,22)	0,145	0,134	0,553
VitalDB	D (z por sujeito)	12,41 (11,35–13,67)	0,185	0,168	0,536

A leitura conjunta com o modelo contemporâneo é agora direta: o treino longo com Huber aproxima este pipeline da faixa agrupada publicada (6,63 contra $6,03 \pm 0,38$), mas o transporte ao VitalDB continua ausente aqui (12,4–12,6 contra 8,60 do candidato misto histórico, que viu a fonte no ajuste). Nenhum braço novo viu VitalDB no treino, de modo que esses números medem transporte genuíno Figshare–VitalDB, ao contrário do holdout histórico do misto. O CCC acompanha o Pearson nos braços novos (diferença máxima de 0,04), indicando que o viés não domina o desacordo; a exceção é o B no Figshare, onde o viés $-3,17$ abre a maior fenda Pearson–CCC (0,699 contra 0,661).

4.6. Suavização EWMA das predições

A Tabela 6 e a Figura 7 mostram a varredura de spans. No Figshare, o EWMA reduz o MAE do ativo (7,03 para 5,91 no span 15; IC 95% no span 10: 5,27–7,37) e do misto

(6,69 para 5,68; IC 95% no span 10: 4,56–7,62), elevando Pearson (0,784/0,818 para 0,850/0,873) e P_K (0,773/0,774 para 0,803/0,793); o span 10 é adotado como referência por equilibrar ganho e memória (nominal de 50 s; lag médio de cerca de 22 s), com o misto em 5,84. O custo é memória nominal de $\text{span} \times 5$ s (lag médio de cerca de $(\text{span} - 1)/2$ janelas) e, no Figshare, viés um pouco maior (0,79/2,12 para 0,86/2,21). No VitalDB, o ativo quase não muda (12,43 para 12,06; P_K 0,515 para 0,511 no span 10 e 0,509 no span 15), enquanto o misto vai de 8,60 para 7,89 (span 10; IC 95% 6,86–9,38), com Pearson 0,755, P_K 0,703 e 72,9% das janelas com $|\text{erro}| \leq 10$; o ganho pequeno do ativo reforça que ali a perda é de ordenação, não de ruído. Parte do ganho é esperada pelo próprio desenho: o BIS de referência é autocorrelacionado e lento, de modo que suavizar qualquer predição ruidosa aproxima da referência (o baseline espectral também melhora, de 8,86 para 7,56 no Figshare e de 13,62 para 12,62 no VitalDB, como esperado de um pós-processamento genérico); o reinício do estado no primeiro valor de cada caso ainda vicia as primeiras janelas. A calibração acompanha: o ICC(2,1) do misto sobe de 0,81 para 0,86 no Figshare e de 0,67 para 0,71 no VitalDB (span 10), enquanto o ativo no VitalDB vai de 0,02 para 0,03; não há suavização que recupere a ordenação perdida.

Para situar: com a mesma família de suavização, o misto alcança 5,68–5,84 no Figshare agrupado (próximo dos 5,22 da entropia amostral [Liu et al. 2018] e na faixa dos $6,03 \pm 0,38$ do modelo contemporâneo sob validação agrupada [Sukriti et al. 2026]), com 0,15 milhão de parâmetros (cerca de sete vezes menos que os 1,07 milhão do modelo contemporâneo) e dez épocas. A comparação não é ranking: partições, normalização, tunagem da suavização e agregação diferem; o ponto é a faixa de erro de uma cadeia compacta e auditável sob o mesmo tipo de pós-processamento.

Tabela 6. Efeito do EWMA causal por caso; MAE em pontos BIS; predições congeladas, sem retreino.

Benchmark	Braço	Bruto	Span 5	Span 10	Span 15
Figshare	ativo	7,03	6,39	6,10	5,91
Figshare	misto	6,69	6,11	5,84	5,68
Figshare	RF espectral	8,86	7,86	7,56	7,38
VitalDB	ativo	12,43	12,11	12,06	12,06
VitalDB	misto	8,60	7,95	7,89	7,93
VitalDB	RF espectral	13,62	12,75	12,62	12,58




Figura 7. Varredura de spans do EWMA causal por braço: MAE e P_K no Figshare e no VitalDB.

4.7. Painéis de apoio: corpus, qualidade e calibração

As duas figuras seguintes detalham o que as tabelas e os agregados comprimem. A primeira caracteriza o corpus que alimenta o protótipo; a segunda documenta o comportamento do treinamento e uma projeção declarada de planejamento. Os painéis de composição e de qualidade da Figura 8 e o histórico da Figura 9a documentam o corpus e o treinamento; somente a projeção da Figura 9b é cenário ancorado no MAE 7,03 medido, não curva observada.

A Figura 8a separa os 59 casos em três estados mutuamente exclusivos por fonte: 33 elegíveis de desenvolvimento (23 Figshare e 10 VitalDB), 11 em quarentena de desenvolvimento (1 Figshare e 10 VitalDB, como o Figshare 24, de escala incompatível) e 15 do benchmark histórico congelado, todos do VitalDB e fora do pool; 9 desses 15 reprovam nos gates internos, mas permanecem no benchmark por desenho. A leitura é de composição, não de desempenho: barras maiores não indicam melhor qualidade. A Figura 8b cruza a fração de amostras finitas com a fração de janelas aceitas e mostra por que os gates não são redundantes; a linha tracejada marca o gate de 90%, e pontos à sua esquerda foram retidos independentemente do eixo vertical.

A Figura 9a acompanha o treino: a perda cai de 6,2 para 4,7 em dez épocas, o MAE de validação oscila entre 5,49 e 6,38, e o checkpoint salvo é o de melhor validação (época 3). O painel (b) troca a projeção teórica por calibração medida: a inclinação predito-referência cai de 0,72 (0,61–0,80) no Figshare ativo para 0,02 (–0,08–0,13) no VitalDB ativo, com ICC(2,1) 0,02 e 57,2% das janelas com $|\text{erro}| \leq 10$ pontos BIS; o misto recupera 0,55 (0,46–0,64), ICC 0,67 e 68,9%, ainda abaixo do Figshare (misto: 0,82, ICC 0,81 e 80,6%).




Figura 8. Composição e qualidade do corpus.




Figura 9. Treinamento do checkpoint ativo e calibração por braço (inclinação predito–referência com IC 95% por bootstrap de casos).

5. Discussão e limitações

A degradação do ativo do Figshare para o VitalDB é evidência interna de sensibilidade à troca de fonte, não prova de qual diferença (equipamento, ganho, montagem, população ou BIS) a causou. A redução de erro do misto é compatível com adaptação após incorporar participantes VitalDB; como o benchmark é da mesma fonte e já havia sido observado, ele gera hipótese para uma nova coorte travada, não generalização externa [Lee et al. 2022, Collins et al. 2024, International Medical Device Regulators Forum 2025].

A melhora em 14/15 casos convive com piora no caso 16, e os agregados por janela privilegiam cirurgias longas: no VitalDB, a mediana do MAE por caso é 12,96 no ativo e 9,60 no misto, contra 12,43 e 8,60 agregados (nos braços novos, a média por caso supera o agregado em 1,0–1,5 ponto); Pearson pode aumentar mesmo com viés relevante. A referência de 10 unidades é escala de concordância entre medições do monitor, não limiar para MAE [Harada et al. 2021]. As análises de concordância e calibração são exploratórias; validação com mais casos segue necessária [Collins et al. 2024, Archer et al. 2021].

O bootstrap cobre só a variabilidade de reamostrar os casos disponíveis sob o algoritmo escolhido; não cobre incerteza de treinamento, seleção de checkpoint, hiperparâmetros, mudança de centro ou erro do rótulo. O pequeno n Figshare e o reaproveitamento do benchmark VitalDB impedem leitura confirmatória e elevam o risco de viés do relato [Field and Welsh 2007, Archer et al. 2021, Moons et al. 2025]; a avaliação é pré-clínica [Vasey et al. 2022].

O alvo é a saída BIS, sensível a EMG, bloqueio neuromuscular, cetamina e atrasos; baixo erro contra o monitor não equivale a medir consciência ou efeito farmacológico [Schuller et al. 2015, Hans et al. 2005, Pilge et al. 2006]. O modelo usa a banda de 0,5–45 Hz, que inclui gama frontal sensível a EMG, e o *notch* fixo em 50 Hz não corresponde obrigatoriamente à rede de cada centro (o VitalDB é de Seul); nenhuma dessas sensibilidades foi medida. Faixas e limiares de qualidade são heurísticas de engenharia, sem validação clínica; DOSE-I permanece tarefa separada para MOAA/S [Garbe et al. 2026].

A leitura ordinal separa dois diagnósticos: no VitalDB o ativo tem P_K 0,515, quase acaso; no Figshare alcança 0,773, e o misto eleva o Pearson sem mover P_K , o que não caracteriza ganho de ordenação. Como a escala é o BIS de referência, não um desfecho de resposta ao estímulo, esses valores não substituem validação clínica [Smith et al. 1996].

A suavização EWMA é pós-hoc, com span de referência escolhido após os resultados, aumenta a memória nominal (lag médio de cerca de 22 s no span 10) e o viés no Figshare, e não substitui os números brutos da Tabela 4; no VitalDB ativo ela quase não altera o erro, separando ruído de perda de ordenação. A comparação com trabalhos publicados mantém as ressalvas de partição e alvo: os valores situam a ordem de grandeza, não ranqueiam modelos.

Em engenharia, a cadeia registra hashes, partições, pré-processamento e replay; a política de amostragem do checkpoint ativo não foi registrada, limitação histórica. A trajetória individual mostra erros que os agregados ocultam, mas não substitui a análise entre casos; investigar lacunas e concordância são extensões possíveis [Collins et al. 2024].

6. Conclusão

O BrainSniffer entrega um protótipo aberto e reproduzível para estimar uma referência BIS a partir de EEG frontal. Como sintetizado na Seção 4, o ativo superou o baseline espectral internamente, mas perdeu associação no VitalDB; o misto reduziu o erro após exposição a esse domínio, sem independência confirmatória e sem diferença sustentada no Figshare. Com a suavização causal exploratória, o misto alcança 5,68–5,84 no Figshare agrupado (5,84 com IC 95% 4,56–7,62 no span de referência 10), dentro das 10 unidades de variabilidade do próprio monitor [Harada et al. 2021] e na faixa do modelo contemporâneo sob validação agrupada [Sukriti et al. 2026], com 0,15 milhão de parâmetros (cerca de sete vezes menos) e dez épocas. Os resultados são retrospectivos, exploratórios e limitados pelo rótulo, pelos casos, pelo reuso dos benchmarks e pela imputação offline.

A contribuição defensável é uma base auditável para formular e testar hipóteses, não um sistema clínico. O software não mede consciência, não prescreve dose, não controla bomba e não deve acionar alarme ou conduta; uma futura alegação de generalização exigiria avaliação independente [Collins et al. 2024].

Disponibilidade

O código-fonte e os relatórios deste artigo estão em <https://github.com/Bruno-BRG/brainsniffer>, sob licença MIT, no commit 1fade9a; os dados não são redistribuídos (Figshare CC BY 4.0; VitalDB sob seus termos de uso), e relatórios e sidecars registram hashes para auditoria.

Referências

- Archer, L., Snell, K. I. E., Ensor, J., Hudda, M. T., Collins, G. S., and Riley, R. D. (2021). Minimum sample size for external validation of a clinical prediction model with a continuous outcome. *Statistics in Medicine*, 40(1):133–146. DOI: 10.1002/sim.8766.
- Avidan, M. S., Jacobsohn, E., Glick, D., et al. (2011). Prevention of intraoperative awareness in a high-risk surgical population. *New England Journal of Medicine*, 365:591–600. DOI: 10.1056/NEJMoa1100403.
- Avidan, M. S., Zhang, L., Burnside, B. A., et al. (2008). Anesthesia awareness and the bispectral index. *New England Journal of Medicine*, 358:1097–1108. DOI: 10.1056/NEJMoa0707361.
- Collins, G. S., Moons, K. G. M., Dhiman, P., et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378. DOI: 10.1136/bmj-2023-078378.
- Connor, C. W. (2022). Open reimplementations of the BIS algorithms for depth of anesthesia. *Anesthesia & Analgesia*, 135(4):855–864. DOI: 10.1213/ANE.0000000000006119.
- Dahaba, A. A., Xue, J. X., Zhao, G. G., Liu, Q. H., et al. (2010). BIS-vista occipital montage in patients undergoing neurosurgical procedures during propofol-remifentanyl anesthesia. *Anesthesiology*, 112(3):645–651. DOI: 10.1097/ALN.0b013e3181cf4111.
- Field, C. A. and Welsh, A. H. (2007). Bootstrapping clustered data. *Journal of the Royal Statistical Society: Series B*, 69(3):369–390. DOI: 10.1111/j.1467-9868.2007.00593.x.

- Garbe, J., Nguyen, Q. V., Kantelhardt, J. W., Dünninghaus, F., Erffmeier, K., Seeliger, K., and Schmid, T. (2026). DOSE-I: A multimodal biosignal dataset of procedural sedation for endoscopy. Dataset, v1, 171 gravações; licença CC BY 4.0 com acordo de uso; escala MOAA/S.
- Hans, P., Dewandre, P.-Y., Brichant, J. F., and Bonhomme, V. (2005). Comparative effects of ketamine on bispectral index and spectral entropy of the electroencephalogram under sevoflurane anaesthesia. *British Journal of Anaesthesia*, 94(3):336–340. DOI: 10.1093/bja/aei047.
- Harada, H., Muta, S., Kakuma, T., et al. (2021). Accuracy of BIS monitoring using a novel interface device connecting conventional needle-electrodes and BIS sensors during frontal neurosurgical procedures. *PLoS ONE*, 16(10):e0258647. DOI: 10.1371/journal.pone.0258647.
- International Medical Device Regulators Forum (2025). Good machine learning practice for medical device development: Guiding principles. IMDRF/AIML WG/N88 FINAL:2025. Final de 29 jan. 2025. Portal: <https://www.imdrf.org>.
- Johansen, J. W. and Sebel, P. S. (2000). Development and clinical application of electroencephalographic bispectrum monitoring. *Anesthesiology*, 93(5):1336–1344.
- Lee, H.-C., Park, Y., Yoon, S. B., Yang, S. M., Park, D., and Jung, C.-W. (2022). VitalDB, a high-fidelity multi-parameter vital signs database in surgical patients. *Scientific Data*, 9:279. DOI: 10.1038/s41597-022-01411-5.
- Liu, Q., Ma, L., Fan, S.-Z., Abbod, M. F., and Shieh, J.-S. (2018). Sample entropy analysis for the estimating depth of anaesthesia through human EEG signal at different levels of unconsciousness during surgeries. *PeerJ*, 6:e4817.
- Ma, L. (2017). EEG and BIS raw data. Dataset, v1, 24 arquivos; licença CC BY 4.0.
- Moons, K. G. M. et al. (2025). PROBAST+AI: an updated quality, risk of bias, and applicability assessment tool for prediction models using regression or artificial intelligence methods. *BMJ*, 388:e082505. DOI: 10.1136/bmj-2024-082505.
- Myles, P. S., Leslie, K., McNeil, J., Forbes, A., and Chan, M. T. V. (2004). Bispectral index monitoring to prevent awareness during anaesthesia: the B-Aware randomised controlled trial. *The Lancet*, 363:1757–1763. DOI: 10.1016/S0140-6736(04)16300-9.
- Nsugbe, E. and Connelly, S. (2022). Multiscale depth of anaesthesia prediction for surgery using frontal cortex electroencephalography. *Healthcare Technology Letters*, 9:43–53. DOI: 10.1049/htl2.12025.
- Park, Y., Han, S.-H., Byun, W., Kim, J.-H., Lee, H.-C., and Kim, S.-J. (2020). A real-time depth of anesthesia monitoring system based on deep neural network with large EDO tolerant EEG analog front-end. *IEEE Transactions on Biomedical Circuits and Systems*, 14:825–837. DOI: 10.1109/TBCAS.2020.2998172.
- Pilge, S., Zanner, R., Schneider, G., Blum, J., Kreuzer, M., and Kochs, E. F. (2006). Time delay of index calculation: analysis of cerebral state, bispectral, and Narcotrend indices. *Anesthesiology*, 104(3):488–494. DOI: 10.1097/00000542-200603000-00016.

- Saeb, S., Lonini, L., Jayaraman, A., Mohr, D. C., and Kording, K. P. (2017). The need to approximate the use-case in clinical machine learning. *GigaScience*, 6. DOI: 10.1093/gigascience/gix019.
- Schuller, P. J., Newell, S., Strickland, P. A., and Barry, J. J. (2015). Response of bispectral index to neuromuscular block in awake volunteers. *British Journal of Anaesthesia*, 115(Suppl 1):i95–i103. DOI: 10.1093/bja/aev072.
- Shi, M., Huang, Z., Xiao, G., Xu, B., Ren, Q., and Zhao, H. (2023). Estimating the depth of anesthesia from EEG signals based on a deep residual shrinkage network. *Sensors*, 23(2):1008. DOI: 10.3390/s23021008.
- Shiraishi, T., Uchino, H., Sagara, T., and Ishii, N. (2004). A comparison of frontal and occipital bispectral index values obtained during neurosurgical procedures. *Anesthesia & Analgesia*, 98(6):1773–1775. DOI: 10.1213/01.ANE.0000121344.69058.09.
- Smith, W. D., Dutton, R. C., and Smith, N. T. (1996). Measuring the performance of anesthetic depth indicators. *Anesthesiology*, 84(1):38–51. DOI: 10.1097/00000542-199601000-00005.
- Sukriti, Kriplani, C., Kumar, S., and Singh, A. (2026). Predicting depth of anaesthesia from single-channel EEG using a deep TCN-BiLSTM-attention model with EWMA. *Scientific Reports*, 16:25470. DOI: 10.1038/s41598-026-54608-8.
- U.S. Food and Drug Administration and Covidien (2024). BIS Advance Monitoring System: K230693, Indications for Use. 510(k) premarket notification. URL: https://www.accessdata.fda.gov/cdrh_docs/pdf23/K230693.pdf.
- Vasey, B., Nagendran, M., Campbell, B., Clifton, D. A., et al. (2022). Reporting guideline for the early-stage clinical evaluation of decision support systems driven by artificial intelligence: DECIDE-AI. *Nature Medicine*, 28:924–933. DOI: 10.1038/s41591-022-01772-9.
- VitalDB (2026). Open dataset: overview and track list. <https://vitaldb.net/dataset/>. Licença CC BY-NC-SA 4.0 e acordo de uso de dados.