

BrainSniffer: protótipo reproduzível para estimar uma referência BIS a partir de EEG frontal

Bruno Rocha Guimarães¹

¹Ciência da Computação – Centro Universitário Jorge Amado
Salvador, Bahia – Brasil

Abstract. *This paper describes BrainSniffer, a reproducible engineering prototype that estimates a Bispectral Index (BIS) reference label from frontal electroencephalography (EEG). The pipeline uses five-second windows at 128 Hz, a compact one-dimensional convolutional neural network, and partitions grouped by case or subject. The active Figshare-only checkpoint reached mean absolute error (MAE) 7.03 and Pearson correlation 0.784 in a five-case Figshare holdout, but 12.43 and 0.024 in a 15-case VitalDB cross-dataset assessment, where ordinal prediction probability (P_k) dropped to 0.515, indistinguishable from chance. A mixed candidate trained with Figshare and part of VitalDB reached 6.69/0.818 on the Figshare benchmark and 8.60/0.688 on the historical VitalDB participant holdout, with no sustained difference from the active checkpoint on Figshare (paired Δ MAE 0.34, 95% CI $-0.28-0.81$); a causal per-case exponential smoothing (EWMA, exploratory, no retraining) lowers the mixed candidate to 5.84 (95% CI 4.56–7.62) and 7.89 (95% CI 6.86–9.38) (reference span 10), respectively. These results are retrospective and exploratory; Pearson is interpreted as association, not agreement. BrainSniffer neither measures consciousness nor supports clinical decisions, alarms, or drug dosing.*

Keywords: frontal EEG; BIS reference label; one-dimensional CNN; grouped validation; domain shift; causal smoothing; reproducibility.

Resumo. *Este artigo descreve o BrainSniffer, protótipo de engenharia reproduzível que estima, a partir de eletroencefalografia (EEG) frontal, um rótulo de referência do Índice Bispectral (BIS). O pipeline usa janelas de cinco segundos a 128 Hz, uma rede neural convolucional unidimensional compacta (1-D CNN) e partições agrupadas por caso ou pessoa. O checkpoint ativo, treinado apenas no Figshare, obteve erro absoluto médio (MAE) 7,03 e correlação de Pearson 0,784 em cinco casos Figshare, mas 12,43 e 0,024 na avaliação com 15 casos VitalDB, com P_K 0,515, indistinguível do acaso. Um candidato misto, treinado com Figshare e parte do VitalDB, obteve 6,69/0,818 no benchmark Figshare e 8,60/0,688 no holdout histórico VitalDB por participante, sem diferença sustentada em relação ao ativo no Figshare (Δ MAE pareado 0,34; IC 95% $-0,28-0,81$); uma suavização exponencial causal por caso (EWMA, exploratória, sem retreino) reduz o misto para 5,84 (IC 95% 4,56–7,62) e 7,89 (IC 95% 6,86–9,38) (span de referência 10). Os resultados são retrospectivos e exploratórios; Pearson é tratado como associação, não acordo. O BrainSniffer não mede consciência nem apoia decisão clínica, alarme ou dose.*

Palavras-chave: EEG frontal; rótulo BIS; CNN 1-D; validação agrupada; reprodutibilidade.

1. Introdução

Na anestesia geral, é preciso saber se o paciente está suficientemente hipnotizado sem exagerar na dose, e para isso usam-se referências objetivas de profundidade. O Índice Bispectral (Bispectral Index, BIS), calculado a partir da eletroencefalografia (EEG) frontal, é a referência mais usada à beira do leito, mas é uma saída proprietária: sua regra de combinação não é publicada e não pode ser reproduzida exatamente a partir do sinal. Modelos que tentam aproximar esse rótulo enfrentam ainda um risco metodológico silencioso: janelas vizinhas da mesma cirurgia são quase idênticas, então uma partição aleatória entre treino e teste mede o reconhecimento de casos já vistos, não a generalização. Falta um protótipo reproduzível com partições por caso, controle espectral e avaliação entre fontes: este trabalho apresenta o BrainSniffer.

A pesquisa responde a duas perguntas. (i) Quanto uma rede neural convolucional unidimensional compacta (1-D CNN) aproxima o rótulo BIS em casos não usados no ajuste, comparada a um controle mais simples baseado em medidas espectrais (baseline espectral)? (ii) Esse desempenho se mantém ao trocar a fonte dos dados, do Figshare para o VitalDB, com outro equipamento, montagem e população? O objetivo geral é avaliar essa aproximação de forma reproduzível. Os objetivos específicos são: comparar a CNN ao baseline no holdout Figshare; quantificar a queda no VitalDB; testar se incorporar parte do VitalDB ao treino (candidato misto) reduz o erro; caracterizar a ordenação das estimativas (probabilidade de predição P_K) e a incerteza da avaliação (bootstrap agrupado de casos); e testar o efeito de uma suavização causal (EWMA) sobre as predições congeladas, além de um experimento fatorial com as escolhas de um modelo contemporâneo (Seção 4.4).

Vale fixar o vocabulário: o modelo estima um rótulo de referência derivado do BIS, não o BIS como grandeza independente, porque o próprio BIS é a saída de um monitor sobre o mesmo sinal. A contribuição é uma cadeia com partições por grupo, controle espectral, comparação entre fontes, análise de incerteza, suavização causal exploratória e um experimento fatorial com braços novos. O escopo deste trabalho é avaliar essa cadeia, não desenvolver um dispositivo médico. A Seção 2 fundamenta o índice BIS e o problema do vazamento entre janelas; a Seção 3 descreve materiais e métodos; a Seção 4 apresenta os resultados; a Seção 5 discute limitações; e a Seção 6 conclui.

2. Fundamentação e trabalhos relacionados

2.1. O índice BIS e seus limites

O Índice Bispectral (BIS) é uma saída proprietária do EEG frontal, em escala de 0 a 100, com a faixa intermediária como referência de hipnose [Johansen and Sebel 2000]. O cálculo combina características temporais, espectrais e bispectrais por regra não publicada; por ser fechado, não pode ser reproduzido do EEG. O BIS é só auxílio sob supervisão, não medida de consciência ou dose. Sua leitura varia com EMG, fármacos e atrasos [Schuller et al. 2015, Hans et al. 2005, Pilge et al. 2006], e ensaios guiados tiveram resultados dependentes do comparador [Myles et al. 2004, Avidan et al. 2008, Avidan et al. 2011]. O BIS chega suavizado e com atraso [Pilge et al. 2006], e a suavização causal é prática comum no corpus [Sukriti et al. 2026].

2.2. Vazamento entre janelas e partição por grupo

Redes profundas já foram estudadas com alvos, canais, populações e equipamentos distintos para aproximar índices derivados de EEG [Park et al. 2020, Shi et al. 2023]. O problema é que janelas vizinhas da mesma cirurgia são parecidas entre si em amplitude, espectro e nível de BIS, porque refletem o mesmo paciente no mesmo plano anestésico. Se essas janelas forem espalhadas aleatoriamente entre treino e teste, o teste contém trechos quase idênticos aos de treino: é o vazamento (*leakage*), que infla o desempenho. Para evitá-lo, os dados são separados por caso ou pessoa (o grupo), ao custo de uma estimativa mais pessimista e mais realista para um caso novo [Sukriti et al. 2026, Saeb et al. 2017].

2.3. Corpora, transparência e relato de modelos

O conjunto “EEG and BIS raw data” reúne 24 casos anônimos com EEG frontal e valores BIS, publicado no repositório Figshare sob licença CC BY 4.0 [Ma 2017]. Um estudo anterior no mesmo corpus usou características multiescala com análise discriminante linear (LDA) e sustenta a descrição do corpus, mas não é evidência de rede convolucional [Nsugbe and Connelly 2022]. Outros estudos estimaram a concentração anestésica derivada de EEG com cadeia dedicada e o índice de estado do paciente (Patient State Index, PSI) com quatro canais em 18 idosos sedados; ambos demonstram viabilidade em configurações específicas, sem comparabilidade direta com o rótulo, o canal ou a população deste trabalho [Park et al. 2020, Shi et al. 2023].

O VitalDB é um banco de sinais perioperatórios de milhares de cirurgias e inclui os canais de EEG frontal e de BIS usados aqui [Lee et al. 2022, VitalDB 2026]. O conjunto aberto exige licença CC BY-NC-SA 4.0 e acordo de uso de dados, sem redistribuição. Escala, equipamento, montagem e população diferem do Figshare; o VitalDB informa a sensibilidade à troca de fonte, sem isolar a causa. O rótulo também difere no instrumento: BIS a cada 5 s por sensor BIS Quatro no Figshare [Ma 2017, Sukriti et al. 2026] contra BIS de 1 s de monitores BIS Vista no VitalDB [VitalDB 2026, Lee et al. 2022], com algoritmo e suavização não públicos. O DOSE-I não foi incorporado por usar escala observacional MOAA/S, não conversível em BIS [Garbe et al. 2026].

Uma reimplementação aberta do algoritmo do índice não torna um regressor treinado contra o BIS equivalente a um monitor [Connor 2022]. Independência entre desenvolvimento e avaliação, descrição de grupos e análise de acordo e calibração são centrais no relato de modelos [Collins et al. 2024, Archer et al. 2021].

3. Materiais e métodos

A Tabela 1 resume os dois checkpoints e a Figura 1 o fluxo retrospectivo: o “ativo” foi ajustado só no Figshare e testa o limite interno e a queda ao mudar de corpus; o “misto” viu também parte do VitalDB, de modo que seu desempenho nessa fonte não mede transporte para fonte nova.

Modelo	Treinado com	Avaliado em
Modelo A – Figshare (ativo)	Figshare	Figshare (holdout por caso) e VitalDB (avaliação cruzada de dataset)
Modelo B – misto	Figshare + parte do VitalDB	Figshare (benchmark histórico) e VitalDB (holdout histórico por participante)

Tabela 1. Definição conceitual dos dois checkpoints.




Figura 1. Fluxo retrospectivo auditável do BrainSniffer.

3.1. Fontes, unidades de agrupamento e partições

Cada arquivo é uma gravação inteira, tratada como um caso; de cada caso saem janelas de 5 s, unidades de treino e de métrica. O grupo é a unidade que nunca cruza partições. O corpus tem 59 arquivos: 44 no pool de desenvolvimento e 15 casos VitalDB congelados. Após os gates de qualidade, 23 casos Figshare e dez VitalDB ficaram elegíveis (33 casos, 55.471 janelas). No Figshare não há identificador de participante; no VitalDB o agrupamento usa o identificador e reúne reoperações [Ma 2017, Lee et al. 2022].

O ativo usou os 23 Figshare elegíveis (13/5/5 com seed 42). O misto fixo excluiu o holdout Figshare e usou 18 grupos Figshare mais dez VitalDB (28 grupos, 49.948 janelas; ajuste com 12 Figshare e quatro VitalDB). Só o teste interno é lido como resultado; as janelas de validação não aparecem nas tabelas.

Os mesmos cinco Figshare (casos 3, 4, 5, 9 e 19) servem aos dois checkpoints. Para o misto, os 15 VitalDB (arquivos 1–17, sem 11 e 15, que não têm os tracks requeridos) vêm da mesma fonte do desenvolvimento e já haviam sido inspecionados: é um holdout histórico após exposição ao domínio, não validação externa confirmatória [Collins et al. 2024, International Medical Device Regulators Forum 2025].

3.2. Tarefa, pré-processamento e qualidade

Cada exemplo é um trecho curto de EEG frontal em microvolts: 640 amostras, isto é, uma janela de 5 segundos amostrada a 128 Hz, com passo de 5 s na construção offline. Para cada início t , o alvo corresponde a $t + \text{offset}$ (offset padrão 0 s), arredondado ao intervalo do BIS do caso. A Figura 2 mostra duas janelas reais do caso 19 antes e depois

do pipeline causal: um trecho limpo (pico de $38 \mu V$, BIS 30) quase não muda (pico processado de $36 \mu V$), enquanto um trecho com pico de $125 \mu V$ (BIS 75) é contido para $88 \mu V$ pelo clip, filtro e escala. O pipeline mantém a banda de 0,5–45 Hz, notch de 50 Hz de quarta ordem e a escala registrada (clip $\pm 100 \mu V$, divisor $50 \mu V$); o filtro usa só passado e presente (estado causal por caso), com rota de fase zero apenas para análise offline [Ma 2017, Nsugbe and Connelly 2022].




Figura 2. Janelas reais do caso 19: linha de cima, trecho limpo (BIS 30); linha de baixo, trecho com pico (BIS 75). Coluna da esquerda, sinal bruto; coluna da direita, após clip, filtro causal e escala. O pico de $125 \mu V$ é contido para $88 \mu V$; o trecho limpo quase não muda.

Os gates exigem 90% de EEG finito, lacuna máxima de 2 s, qualidade global 0,35, 80% de BIS válido e 0,20 por janela (heurísticas sem calibração clínica; o Figshare 24 está em quarentena). Nos 15 VitalDB do benchmark, a construção offline interpola não finitos (podendo usar amostras futuras) e interpola o BIS para grade de 1 s sem máscara persistida: difere da rejeição do replay e limita a interpretação, mas foi mantida por fidelidade histórica.

3.3. Modelos e treinamento

A CNN histórica recebe a janela de 640 amostras em um canal, é treinada com perda Smooth L1 e tem saída sigmoideal escalada para $[0, 100]$. Os braços novos do experimento fatorial (Seção 4.4) usam perda de Huber com $\delta = 5$, treino de até 120 épocas e normalização por sujeito, mantida a mesma arquitetura. A Tabela 2 explicita a arquitetura e os parâmetros registrados no protocolo, sem carregar pesos. Recursos posteriores do treinador e arquiteturas opcionais não são atribuídos retroativamente a esses pesos.

Item	Configuração registrada
Convolucionais	Canais 1→32→64→128→128; <i>kernel</i> 7, 7, 5, 5; <i>padding</i> 3, 3, 2, 2; <i>stride</i> 1; normalização em lote + GELU
<i>Pooling</i> e cabeça	max-pooling de fator 2 nos 3 primeiros blocos; pooling médio global; camada densa 128–64–1, GELU, <i>dropout</i> 0,20
Treino (ambos)	10 <i>epochs</i> , <i>batch</i> 128, <i>lr</i> 10^{-3} , <i>wd</i> 10^{-4} , <i>seed</i> 42; validação/teste: 20% dos grupos em cada partição
Amostragem	Misto: balanceada por grupo/fonte; ativo: não registrada
Amplitude e <i>notch</i>	<i>Clip</i> $\pm 100 \mu V$, divisor de escala $50 \mu V$, saída em $[-5, 5]$; <i>notch</i> 50 Hz, <i>Q</i> =30
<i>Random Forest</i>	100 árvores, profundidade máxima 12, mínimo de 2 amostras por folha, semente 42

Tabela 2. Configuração histórica dos checkpoints.

A arquitetura compacta permite replay em CPU, sem superioridade presumida sobre alternativas [Park et al. 2020, Shi et al. 2023].

Como controle simples, o baseline espectral resume cada janela de 5 s em 14 atributos clássicos: potências absoluta e relativa das bandas delta (0,5–4 Hz), teta (4–8 Hz), alfa (8–13 Hz), beta (13–30 Hz) e gama (30–45 Hz), frequência de borda espectral em 90% (SEF90), entropia espectral, valor eficaz (RMS) e *line length*. Uma floresta aleatória (*Random Forest*, configuração na Tabela 2) é ajustada nas mesmas 15.894 janelas de treino e avaliada nas mesmas 5.523 janelas de teste do holdout Figshare, sem acesso a informação adicional e herdando a mesma proteção contra vazamento da partição agrupada por caso. O controle responde a uma pergunta prática: se poucas medidas de espectro já alcançam erro parecido, a complexidade da CNN precisa ser justificada; se a CNN supera o controle, há indício de que a representação aprendida captura estrutura além do espectro clássico.

3.4. Métricas, incerteza e análises exploratórias

O desfecho primário é o MAE agregado por janela (casos longos pesam mais); demais métricas são secundárias, sem correção para multiplicidade. Foram calculados MAE, RMSE, viés, Pearson e CCC de Lin para o rótulo contínuo, além de acurácia e macro-F1 em quatro faixas ([0, 40), [40, 60), [60, 80), [80, 100]), lidas com rótulos curtos só para comunicação, sem validar limiar clínico [Collins et al. 2024]. Pearson mede associação, não acordo; a concordância usa inclinação de calibração, limites de concordância, ICC(2,1) e fração de $|\text{erro}| \leq 10$, tudo exploratório. O P_K e o Pearson agregados empilham todas as janelas (pares entre casos distintos entram na conta); por isso a Seção 4 traz também mediana e amplitude por caso.

A ordenação é medida pela probabilidade de predição P_K de Smith, Dutton e Smith [Smith et al. 1996]: sorteados dois momentos com BIS distintos, qual a chance de o indicador ordená-los como a referência? Vale 1 na ordem perfeita e 0,5 no acaso; empates no alvo são excluídos e no indicador contam 0,5. Por depender só da ordem, P_K ignora erro de escala. A incerteza usa bootstrap de casos inteiros ($B = 1.000$, *seed* 42, percentis 2,5/97,5); com cinco casos Figshare, é exploratória (1.000 réplicas não equivalem a 1.000 casos) [Field and Welsh 2007, Archer et al. 2021].

Como referência externa, estudos de acurácia do próprio BIS tratam diferenças de até 10 unidades entre duas medições do monitor como aceitáveis [Dahaba et al. 2010,

Shiraishi et al. 2004, Harada et al. 2021]; como o alvo já varia nessa ordem, um MAE da mesma magnitude fica dentro da variabilidade do rótulo; o valor é escala de leitura, não limiar clínico.

A comparação VitalDB também foi calculada por caso, pareando as janelas de cada caso. A análise de sensibilidade reaplicou o checkpoint ativo aos mesmos cinco casos Figshare, sem retreino, em uma grade de -20 a $+20$ s. Como a grade foi examinada após o treinamento, ela formula hipótese sobre alinhamento e não escolhe o atraso do rótulo [Pilge et al. 2006]. Deslocamentos positivos associam cada janela a um BIS futuro, indisponível no instante de emissão, e por isso não alteram o offset zero do replay.

3.5. Replay retrospectivo e trajetória ilustrativa

Replay é percorrer uma gravação existente (buffer de 5 s, atualização a cada 1 s), sem EEG físico. Para visualizar o comportamento temporal, fixou-se antes da inferência o caso 19 do holdout (4.355 s), com a configuração do checkpoint ativo em CPU, sem treino; a curva bruta posiciona-se no instante do alvo offline, sem representar disponibilidade sem atraso.

3.6. Suavização causal (EWMA) das predições

Como o alvo é uma saída já suavizada pelo monitor, o pipeline também permite uma média móvel exponencial causal por caso (EWMA), aplicada às predições congeladas, sem retreino: $s_t = \alpha y_t + (1 - \alpha)s_{t-1}$, com $\alpha = 2/(\text{span} + 1)$ e reinício por caso; o *span* é medido em janelas de 5 s e $\text{span} = 1$ reproduz a predição bruta. Usar apenas amostras passadas mantém o caminho compatível com o replay. A varredura de spans é retrospectiva e exploratória (examinada após os resultados; não reescolhe checkpoint, treino ou arquitetura), seguindo a prática de suavização temporal de trabalhos contemporâneos [Sukriti et al. 2026, Pilge et al. 2006].

4. Resultados

4.1. Checkpoint ativo e baseline no Figshare

No holdout Figshare do checkpoint ativo, cinco casos e 5.523 janelas produziram MAE 7,03, RMSE 11,08, viés 0,79 e Pearson 0,784. A acurácia por faixa foi 0,585 e o macro-F1 0,548. O baseline espectral, na mesma partição, obteve MAE 8,86, RMSE 13,23, Pearson 0,667, acurácia 0,540 e macro-F1 0,480. No bootstrap pareado por caso, o ΔMAE favorável à CNN é $-1,84$ (IC 95% $-2,37$ – $-0,66$) e o ΔP_K é $+0,051$ ($0,012$ – $0,081$); os intervalos excluem zero, mas com cinco casos o teste é exploratório. A Tabela 3 resume o agregado.

Modelo	MAE	RMSE	Pearson	Acurácia	Macro-F1
CNN ativa	7,03	11,08	0,784	0,585	0,548
Baseline espectral	8,86	13,23	0,667	0,540	0,480

Tabela 3. Holdout Figshare comum (5 casos, 5.523 janelas; MAE e RMSE em pontos BIS).

A Figura 3 mostra queda inicial e elevação final em ambas as curvas, mas a CNN superestima o patamar intermediário e não reproduz várias oscilações da referência. Nas

850 janelas aceitas, MAE 8,72, RMSE 10,21, viés +4,79 e Pearson intra-caso 0,910: associação alta não elimina erro sistemático; é exemplo ilustrativo, não evidência de generalização. Das 871 janelas completas, 21 foram rejeitadas por qualidade e 56 posições ficaram sem previsão (NaN).




Figura 3. Trajetória offline do caso 19: referência e predição bruta (topo) e erro por janela (base).

4.2. Comparação dos checkpoints nos benchmarks históricos

O misto obteve 6,69/0,818 no Figshare e 8,60/0,688 no VitalDB; o ativo, 7,03/0,784 e 12,43/0,024 (Tabela 4). Três dos quatro MAE ficam abaixo das 10 unidades de variabilidade do monitor [Harada et al. 2021]; o ativo no VitalDB (12,43) a ultrapassa, com P_K no acaso. No mesmo corpus, a entropia amostral reportou MAE 5,22 [Liu et al. 2018] (baseline aqui: 8,86 agrupado), e um modelo contemporâneo maior (TCN-BiLSTM com atenção, 1,07M parâmetros, Huber $\delta = 5$) reportou 4,499 por segmentos e $6,03 \pm 0,38$ em GroupKFold com EWMA e CCC 0,819 [Sukriti et al. 2026]; este trabalho (0,15M parâmetros, dez épocas, Smooth L1) fica em 6,69–7,03 brutos. A comparação é de ordem de grandeza: diferem normalização, seleção da suavização, agregação e medida de acordo, e lá a diferença entre kernels não foi significativa (Friedman $p = 0,453$).

Benchmark	Modelo (fontes vistas)	MAE (IC 95%)	Pearson (IC 95%)	P_K (IC 95%)
Figshare	ativo (Figshare)	7,03 (6,38–8,24)	0,784 (0,703–0,881)	0,773 (0,679–0,828)
Figshare	misto (Figshare+VitalDB)	6,69 (5,65–8,53)	0,818 (0,751–0,890)	0,774 (0,676–0,835)
VitalDB	ativo (Figshare)	12,43 (11,05–14,45)	0,024 (–0,126–0,193)	0,515 (0,434–0,581)
VitalDB	misto (Figshare+VitalDB)	8,60 (7,57–9,95)	0,688 (0,606–0,752)	0,672 (0,591–0,737)
VitalDB	RF espectral	13,62 (11,98–16,01)	–0,036 (–0,162–0,111)	0,502 (0,447–0,551)

Tabela 4. Comparação retrospectiva nos benchmarks históricos; 5 casos no benchmark Figshare e 15 no VitalDB; MAE em pontos BIS; IC 95% por bootstrap agrupado por caso; o RF espectral viu apenas o Figshare.

O baseline espectral também foi reavaliado nos 15 casos VitalDB, com o mesmo ajuste e protocolo: MAE 13,62 (11,98–16,01), Pearson $-0,04$ e P_K 0,502, no nível do acaso, e a CNN ativa ainda o supera (Δ MAE $-1,19$; IC $-2,13$ – $-0,34$); o colapso no transporte não é específico da CNN. No bootstrap pareado por caso ($\Delta =$ ativo – misto), o misto melhora o VitalDB (Δ MAE $+3,83$, IC $2,95$ – $4,94$; ΔP_K $-0,157$, IC $-0,216$ – $-0,083$; 14/15 casos, $p < 0,001$), enquanto no Figshare MAE e P_K não sustentam ganho (Δ MAE $0,34$, IC $-0,28$ – $0,81$; ΔP_K IC $-0,013$ – $0,007$). No VitalDB, o MAE do candi-

dato caiu em 14 dos 15 casos pareados (sinal exato bilateral $p = 0,001$; leitura descritiva, sem valor confirmatório); no caso 16, subiu cerca de 0,67 ponto. Na Figura 4c, cada linha é um caso, ordenado pela diferença misto menos ativo; linhas à esquerda indicam menor MAE do misto. A leitura pareada evita que casos longos dominem e revela heterogeneidade: 14 acertos contra 1 piora convivem com margens pequenas, descrevendo adaptação após exposição ao domínio, não transporte para nova fonte.




Figura 4. Agregados por janela e MAE pareado por caso; em (c), cada ponto é um caso e linhas à esquerda indicam menor MAE do misto.

4.3. Ordenação, incerteza e alinhamento

No Figshare (Figura 5), o ativo obtém P_K 0,773 (0,679–0,828) e o misto 0,774 (0,676–0,835): o misto reduz o MAE (7,03 para 6,69) e eleva o Pearson (0,784 para 0,818) sem mudar a ordenação, e as diferenças são pequenas frente aos intervalos. No VitalDB, o ativo fica no acaso (0,515) e o misto em 0,672; por caso, medianas 0,48 e 0,67 (no Figshare, 0,80 e 0,81) [Smith et al. 1996]. A Figura 6 reúne os intervalos de 95% (barras: réplicas; marcadores: observados). Na grade de offset (–20 a +20 s, sem retreino), o MAE variou de 7,22 a 6,76 (Figura 7): tendência pós-hoc, sem valor causal e sem mudar o offset zero [Pilge et al. 2006].




Figura 5. Probabilidade de predição P_K , ativo vs. misto.




Figura 6. Bootstrap agrupado por caso.




Figura 7. Sensibilidade ao offset do rótulo; eixos ampliados (variação total $\leq 0,5$ ponto de MAE e 0,04 de Pearson).

4.4. Experimento fatorial inspirado no modelo contemporâneo

Para testar se as escolhas do modelo contemporâneo transferem ganho para esta cadeia, quatro braços foram treinados do zero no Figshare (mesmo split 13/5/5 por caso, seed 42, checkpoints novos sem tocar nos históricos): A (baseline reproduzido: Smooth L1, dez

épocas, batch 128, clip $\pm 100 \mu V$, sem winsor); B (A com winsorização causal $\pm 200 \mu V$ e clip elevado a $\pm 300 \mu V$, para o winsor ter efeito próprio); C (B com perda de Huber $\delta = 5$, até 120 épocas com paciência 18, batch 64 e paciência 6 no agendador); e D (C com z-score por sujeito, com média e desvio estimados somente no split de treino, congelados no checkpoint e fallback global para sujeito novo). Cada braço foi avaliado nos mesmos benchmarks (cinco Figshare e 15 VitalDB congelados), com CCC de Lin e média por caso ao lado do agregado por janela. A Tabela 5 resume os números brutos, sem EWMA. O braço A reproduziu o histórico (Figshare 7,03/0,780/0,777 de CCC/0,773 de P_K ; VitalDB 12,64/0,056/0,051/0,524), validando o harness. O winsor isolado (B) piorou o Figshare (8,19; IC 95% 6,78–10,01) com viés $-3,17$, sem mover o VitalDB (12,04). O treino longo com Huber (C) foi o único ganho real no Figshare: 6,63 (IC 95% 6,03–7,67), Pearson 0,824, CCC 0,820 e P_K 0,780, com 46 épocas efetivas (parada na 28 por paciência); no VitalDB, porém, ficou em 12,61. O z-score por sujeito (D) elevou Pearson (0,833) e CCC (0,830) no Figshare sem reduzir o MAE (7,14; IC 95% 5,75–7,86), e no VitalDB ficou em 12,41. Nenhum braço novo foi submetido ao EWMA; a comparação com os números suavizados da Seção 4.5 é entre bruto novo e suavizado histórico, sem inferência direta.

Benchmark	Braço	MAE (IC 95%)	Pearson	CCC	P_K
Figshare	A (reprodução)	7,03 (6,36–8,27)	0,780	0,777	0,773
Figshare	B (winsor)	8,19 (6,78–10,01)	0,699	0,661	0,758
Figshare	C (Huber+longo)	6,63 (6,03–7,67)	0,824	0,820	0,780
Figshare	D (z por sujeito)	7,14 (5,75–7,86)	0,833	0,830	0,772
VitalDB	A (reprodução)	12,64 (11,38–14,43)	0,056	0,051	0,524
VitalDB	B (winsor)	12,04 (10,89–13,74)	0,238	0,194	0,528
VitalDB	C (Huber+longo)	12,61 (11,40–14,22)	0,145	0,134	0,553
VitalDB	D (z por sujeito)	12,41 (11,35–13,67)	0,185	0,168	0,536

Tabela 5. Braços fatoriais novos (brutos, sem EWMA); MAE em pontos BIS; IC 95% por bootstrap agrupado por caso; CCC é o coeficiente de Lin.

O treino longo aproxima esta cadeia da faixa publicada (6,63 contra $6,03 \pm 0,38$), mas o transporte genuíno Figshare–VitalDB segue ausente (12,4–12,6 contra 8,60 do misto, que viu a fonte).

4.5. Suavização EWMA das predições

A Tabela 6 e a Figura 8 mostram a varredura de spans (referência: span 10, lag médio de 22 s). No Figshare, o misto cai de 6,69 para 5,84, com Pearson 0,755 e P_K 0,703; no VitalDB vai de 8,60 para 7,89 (IC 6,86–9,38), enquanto o ativo quase não muda (12,43 para 12,06; P_K 0,515 para 0,511), reforçando perda de ordenação, não de ruído. Parte do ganho é esperada (alvo autocorrelacionado; baseline também melhora), e o ICC do misto sobe de 0,81 para 0,86 no Figshare e de 0,67 para 0,71 no VitalDB. O misto suavizado (5,68–5,84) situa-se na faixa dos trabalhos no corpus [Liu et al. 2018, Sukriti et al. 2026], com 0,15M parâmetros e sem ranking.

Benchmark	Braço	Bruto	Span 5	Span 10	Span 15
Figshare	ativo	7,03	6,39	6,10	5,91
Figshare	misto	6,69	6,11	5,84	5,68
Figshare	RF espectral	8,86	7,86	7,56	7,38
VitalDB	ativo	12,43	12,11	12,06	12,06
VitalDB	misto	8,60	7,95	7,89	7,93
VitalDB	RF espectral	13,62	12,75	12,62	12,58

Tabela 6. Efeito do EWMA causal por caso; MAE em pontos BIS; predições congeladas, sem retreino.




Figura 8. Varredura de spans do EWMA causal por braço: MAE e P_K no Figshare e no VitalDB.

4.6. Corpus e calibração

O corpus tem 59 casos: 33 elegíveis (23 Figshare e dez VitalDB), 11 em quarentena (incluindo o Figshare 24, de escala incompatível) e 15 VitalDB congelados para o benchmark, dos quais 9 reprovam nos gates internos por desenho (Figura 9). No treino do ativo, a perda cai de 6,2 para 4,7 em dez épocas (melhor validação na época 3); a inclinação predito-referência cai de 0,72 (0,61–0,80) no Figshare ativo para 0,02 (–0,08–0,13) no VitalDB ativo, com ICC(2,1) 0,02 e 57,2% das janelas com $|\text{erro}| \leq 10$, e o misto recupera 0,55 (0,46–0,64), ICC 0,67 e 68,9% (Figura 10). A calibração do Figshare com o misto chega a 0,82 de inclinação, ICC 0,81 e 80,6% das janelas com $|\text{erro}| \leq 10$.




Figura 9. Composição e qualidade do corpus (59 casos).




Figura 10. Treinamento do ativo e calibração por braço.

5. Discussão e limitações

A degradação do ativo do Figshare para o VitalDB é evidência interna de sensibilidade à troca de fonte, não prova de qual diferença (equipamento, ganho, montagem, população ou BIS) a causou. A redução de erro do misto é compatível com adaptação após incorporar participantes VitalDB; como o benchmark é da mesma fonte e já havia sido observado, ele gera hipótese para uma nova coorte travada, não generalização externa [Lee et al. 2022, Collins et al. 2024, International Medical Device Regulators Forum 2025]. Os braços fatoriais reforçam o diagnóstico: nenhum treino Figshare-only restaurou o transporte (12,0–12,6 em todos), de modo que a exposição ao domínio, não a arquitetura ou a perda, explica o ganho do misto; o treino longo ao menos aproximou o erro interno da faixa publicada (6,63 contra 6,03 $\pm$ 0,38), sugerindo que capacidade de otimização não era o gargalo. Em termos práticos, isso desloca a prioridade de “modelo maior” para “dados da fonte”: antes de aumentar capacidade, o próximo experimento deveria expor o treino a mais fontes com partição travada, mantida a auditoria por hashes.

A melhora em 14/15 casos convive com piora no caso 16, e os agregados por janela privilegiam cirurgias longas: no VitalDB, a mediana do MAE por caso é 12,96 no ativo e 9,60 no misto, contra 12,43 e 8,60 agregados (nos braços novos, a média por caso supera

o agregado em 1,0–1,5 ponto); Pearson pode aumentar mesmo com viés relevante. A referência de 10 unidades é escala de concordância entre medições do monitor, não limiar para MAE [Harada et al. 2021]. As análises de concordância e calibração são exploratórias; validação com mais casos segue necessária [Collins et al. 2024, Archer et al. 2021]. Para essa validação futura, o desenho mínimo seria uma coorte travada de outra fonte, com partição por participante definida antes de qualquer inspeção, métricas primárias pré-registradas (MAE por janela e P_K) e relato de calibração; sem isso, qualquer novo candidato repete o estatuto exploratório deste trabalho.

O bootstrap cobre só a variabilidade de reamostrar os casos disponíveis sob o algoritmo escolhido; não cobre incerteza de treinamento, seleção de checkpoint, hiperparâmetros, mudança de centro ou erro do rótulo. O pequeno n Figshare e o reaproveitamento do benchmark VitalDB impedem leitura confirmatória e elevam o risco de viés do relato [Field and Welsh 2007, Archer et al. 2021, Moons et al. 2025]; a avaliação é pré-clínica [Vasey et al. 2022].

O alvo é a saída BIS, sensível a EMG, bloqueio neuromuscular, cetamina e atrasos; baixo erro contra o monitor não equivale a medir consciência ou efeito farmacológico [Schuller et al. 2015, Hans et al. 2005, Pilge et al. 2006]. O modelo usa a banda de 0,5–45 Hz, que inclui gama frontal sensível a EMG, e o *notch* fixo em 50 Hz não corresponde obrigatoriamente à rede de cada centro (o VitalDB é de Seul); nenhuma dessas sensibilidades foi medida. Faixas e limiares de qualidade são heurísticas de engenharia, sem validação clínica; DOSE-I permanece tarefa separada para MOAA/S [Garbe et al. 2026].

A leitura ordinal separa dois diagnósticos: no VitalDB o ativo tem P_K 0,515, quase acaso; no Figshare alcança 0,773, e o misto eleva o Pearson sem mover P_K , o que não caracteriza ganho de ordenação. Como a escala é o BIS de referência, não um desfecho de resposta ao estímulo, esses valores não substituem validação clínica [Smith et al. 1996]. A suavização EWMA é pós-hoc, com span de referência escolhido após os resultados, aumenta a memória nominal (lag médio de cerca de 22 s no span 10) e o viés no Figshare, e não substitui os números brutos da Tabela 4; no VitalDB ativo ela quase não altera o erro, separando ruído de perda de ordenação. A comparação com trabalhos publicados mantém as ressalvas de partição e alvo: os valores situam a ordem de grandeza, não ranqueiam modelos. Em engenharia, a cadeia registra hashes, partições, pré-processamento e replay; a política de amostragem do checkpoint ativo não foi registrada, limitação histórica [Collins et al. 2024].

6. Conclusão

O BrainSniffer entrega um protótipo aberto e reproduzível para estimar uma referência BIS a partir de EEG frontal. Como sintetizado na Seção 4, o ativo superou o baseline espectral internamente (MAE 7,03 contra 8,86, Δ pareado $-1,84$), mas perdeu associação no VitalDB (P_K no acaso); o misto reduziu o erro após exposição a esse domínio (8,60, 14/15 casos), sem independência confirmatória e sem diferença sustentada no Figshare. Com a suavização causal exploratória, o misto alcança 5,68–5,84 no Figshare agrupado (5,84 com IC 95% 4,56–7,62 no span de referência 10), dentro das 10 unidades de variabilidade do próprio monitor [Harada et al. 2021] e na faixa do modelo contemporâneo sob validação agrupada [Sukriti et al. 2026], com 0,15 milhão de parâmetros (cerca de sete vezes menos) e dez épocas; o treino longo com Huber chega a 6,63 brutos (IC 6,03–7,67).

Os resultados são retrospectivos, exploratórios e limitados pelo rótulo, pelos casos, pelo reuso dos benchmarks e pela imputação offline.

A contribuição defensável é uma base auditável para formular e testar hipóteses, não um sistema clínico. O software não mede consciência, não prescreve dose, não controla bomba e não deve acionar alarme ou conduta; uma futura alegação de generalização exigiria avaliação independente [Collins et al. 2024].

Disponibilidade

Código em <https://github.com/Bruno-BRG/brainsniffer> (MIT); dados não redistribuídos; relatórios com hashes.

Referências

- Archer, L., Snell, K. I. E., Ensor, J., Hudda, M. T., Collins, G. S., and Riley, R. D. (2021). Minimum sample size for external validation of a clinical prediction model with a continuous outcome. *Statistics in Medicine*, 40(1):133–146. DOI: 10.1002/sim.8766.
- Avidan, M. S., Jacobsohn, E., Glick, D., et al. (2011). Prevention of intraoperative awareness in a high-risk surgical population. *New England Journal of Medicine*, 365:591–600. DOI: 10.1056/NEJMoa1100403.
- Avidan, M. S., Zhang, L., Burnside, B. A., et al. (2008). Anesthesia awareness and the bispectral index. *New England Journal of Medicine*, 358:1097–1108. DOI: 10.1056/NEJMoa0707361.
- Collins, G. S., Moons, K. G. M., Dhiman, P., et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378. DOI: 10.1136/bmj-2023-078378.
- Connor, C. W. (2022). Open reimplementations of the BIS algorithms for depth of anesthesia. *Anesthesia & Analgesia*, 135(4):855–864. DOI: 10.1213/ANE.00000000000006119.
- Dahaba, A. A., Xue, J. X., Zhao, G. G., Liu, Q. H., et al. (2010). BIS-vista occipital montage in patients undergoing neurosurgical procedures during propofol-remifentanyl anesthesia. *Anesthesiology*, 112(3):645–651. DOI: 10.1097/ALN.0b013e3181cf4111.
- Field, C. A. and Welsh, A. H. (2007). Bootstrapping clustered data. *Journal of the Royal Statistical Society: Series B*, 69(3):369–390. DOI: 10.1111/j.1467-9868.2007.00593.x.
- Garbe, J., Nguyen, Q. V., Kantelhardt, J. W., Dünninghaus, F., Erffmeier, K., Seeliger, K., and Schmid, T. (2026). DOSE-I: A multimodal biosignal dataset of procedural sedation for endoscopy. Dataset, v1, 171 gravações; licença CC BY 4.0 com acordo de uso; escala MOAA/S.
- Hans, P., Dewandre, P.-Y., Brichant, J. F., and Bonhomme, V. (2005). Comparative effects of ketamine on bispectral index and spectral entropy of the electroencephalogram under sevoflurane anaesthesia. *British Journal of Anaesthesia*, 94(3):336–340. DOI: 10.1093/bja/aei047.
- Harada, H., Muta, S., Kakuma, T., et al. (2021). Accuracy of BIS monitoring using a novel interface device connecting conventional needle-electrodes and BIS sensors during

- frontal neurosurgical procedures. *PLoS ONE*, 16(10):e0258647. DOI: 10.1371/journal.pone.0258647.
- International Medical Device Regulators Forum (2025). Good machine learning practice for medical device development: Guiding principles. IMDRF/AIML WG/N88 FINAL:2025. Final de 29 jan. 2025. Portal: <https://www.imdrf.org>.
- Johansen, J. W. and Sebel, P. S. (2000). Development and clinical application of electroencephalographic bispectrum monitoring. *Anesthesiology*, 93(5):1336–1344.
- Lee, H.-C., Park, Y., Yoon, S. B., Yang, S. M., Park, D., and Jung, C.-W. (2022). VitalDB, a high-fidelity multi-parameter vital signs database in surgical patients. *Scientific Data*, 9:279. DOI: 10.1038/s41597-022-01411-5.
- Liu, Q., Ma, L., Fan, S.-Z., Abbod, M. F., and Shieh, J.-S. (2018). Sample entropy analysis for the estimating depth of anaesthesia through human EEG signal at different levels of unconsciousness during surgeries. *PeerJ*, 6:e4817.
- Ma, L. (2017). EEG and BIS raw data. Dataset, v1, 24 arquivos; licença CC BY 4.0.
- Moons, K. G. M. et al. (2025). PROBAST+AI: an updated quality, risk of bias, and applicability assessment tool for prediction models using regression or artificial intelligence methods. *BMJ*, 388:e082505. DOI: 10.1136/bmj-2024-082505.
- Myles, P. S., Leslie, K., McNeil, J., Forbes, A., and Chan, M. T. V. (2004). Bispectral index monitoring to prevent awareness during anaesthesia: the B-Aware randomised controlled trial. *The Lancet*, 363:1757–1763. DOI: 10.1016/S0140-6736(04)16300-9.
- Nsugbe, E. and Connelly, S. (2022). Multiscale depth of anaesthesia prediction for surgery using frontal cortex electroencephalography. *Healthcare Technology Letters*, 9:43–53. DOI: 10.1049/htl2.12025.
- Park, Y., Han, S.-H., Byun, W., Kim, J.-H., Lee, H.-C., and Kim, S.-J. (2020). A real-time depth of anesthesia monitoring system based on deep neural network with large EDO tolerant EEG analog front-end. *IEEE Transactions on Biomedical Circuits and Systems*, 14:825–837. DOI: 10.1109/TBCAS.2020.2998172.
- Pilge, S., Zanner, R., Schneider, G., Blum, J., Kreuzer, M., and Kochs, E. F. (2006). Time delay of index calculation: analysis of cerebral state, bispectral, and Narcotrend indices. *Anesthesiology*, 104(3):488–494. DOI: 10.1097/00000542-200603000-00016.
- Saeb, S., Lonini, L., Jayaraman, A., Mohr, D. C., and Kording, K. P. (2017). The need to approximate the use-case in clinical machine learning. *GigaScience*, 6. DOI: 10.1093/gigascience/gix019.
- Schuller, P. J., Newell, S., Strickland, P. A., and Barry, J. J. (2015). Response of bispectral index to neuromuscular block in awake volunteers. *British Journal of Anaesthesia*, 115(Suppl 1):i95–i103. DOI: 10.1093/bja/aev072.
- Shi, M., Huang, Z., Xiao, G., Xu, B., Ren, Q., and Zhao, H. (2023). Estimating the depth of anesthesia from EEG signals based on a deep residual shrinkage network. *Sensors*, 23(2):1008. DOI: 10.3390/s23021008.
- Shiraishi, T., Uchino, H., Sagara, T., and Ishii, N. (2004). A comparison of frontal and occipital bispectral index values obtained during neurosurgical procedures. *Anesthesia & Analgesia*, 98(6):1773–1775. DOI: 10.1213/01.ANE.0000121344.69058.09.

- Smith, W. D., Dutton, R. C., and Smith, N. T. (1996). Measuring the performance of anesthetic depth indicators. *Anesthesiology*, 84(1):38–51. DOI: 10.1097/00000542-199601000-00005.
- Sukriti, Kriplani, C., Kumar, S., and Singh, A. (2026). Predicting depth of anaesthesia from single-channel EEG using a deep TCN-BiLSTM-attention model with EWMA. *Scientific Reports*, 16:25470. DOI: 10.1038/s41598-026-54608-8.
- Vasey, B., Nagendran, M., Campbell, B., Clifton, D. A., et al. (2022). Reporting guideline for the early-stage clinical evaluation of decision support systems driven by artificial intelligence: DECIDE-AI. *Nature Medicine*, 28:924–933. DOI: 10.1038/s41591-022-01772-9.
- VitalDB (2026). Open dataset: overview and track list. <https://vitaldb.net/dataset/>. Licença CC BY-NC-SA 4.0 e acordo de uso de dados.