

BrainSniffer: protótipo reproduzível para estimar uma referência BIS a partir de EEG frontal

Bruno Rocha Guimarães¹

¹Ciência da Computação – Centro Universitário Jorge Amado
Salvador, Bahia – Brasil

Abstract. *This paper describes BrainSniffer, a reproducible engineering prototype that estimates a Bispectral Index (BIS) reference label from frontal electroencephalography (EEG). The pipeline uses five-second windows at 128 Hz, a compact one-dimensional convolutional neural network, and partitions grouped by case or subject. The active Figshare-only checkpoint reached mean absolute error (MAE) 7.03 and Pearson correlation 0.784 in a five-case Figshare holdout, but 12.43 and 0.024 in a 15-case VitalDB cross-dataset assessment, where ordinal prediction probability (P_k) dropped to 0.515, indistinguishable from chance. A mixed candidate trained with Figshare and part of VitalDB reached 6.69/0.818 on the Figshare benchmark and 8.60/0.688 on the historical VitalDB participant holdout. These results are retrospective and exploratory; Pearson is interpreted as association, not agreement. BrainSniffer neither measures consciousness nor supports clinical decisions, alarms, or drug dosing.*

Keywords: *frontal EEG; BIS reference label; one-dimensional CNN; grouped validation; domain shift; reproducibility.*

Resumo. *Este artigo descreve o BrainSniffer, protótipo de engenharia reproduzível que estima, a partir de eletroencefalografia (EEG) frontal, um rótulo de referência do Índice Bispectral (BIS). O pipeline usa janelas de cinco segundos a 128 Hz, uma rede neural convolucional unidimensional compacta (1-D CNN) e partições agrupadas por caso ou pessoa. O checkpoint ativo, treinado apenas no Figshare, obteve erro absoluto médio (MAE) 7,03 e correlação de Pearson 0,784 em cinco casos Figshare, mas 12,43 e 0,024 na avaliação com 15 casos VitalDB, com P_K 0,515, indistinguível do acaso. Um candidato misto, treinado com Figshare e parte do VitalDB, obteve 6,69/0,818 no benchmark Figshare e 8,60/0,688 no holdout histórico VitalDB por participante. Os resultados são retrospectivos e exploratórios; Pearson é tratado como associação, não acordo. O BrainSniffer não mede consciência nem apoia decisão clínica, alarme ou dose.*

Palavras-chave: *EEG frontal; rótulo BIS; CNN unidimensional; validação agrupada; mudança de domínio; reprodutibilidade.*

1. Introdução

Na anestesia geral, é preciso saber se o paciente está suficientemente hipnotizado sem exagerar na dose, e para isso usam-se referências objetivas de profundidade. O Índice Bispectral (Bispectral Index, BIS), calculado a partir da eletroencefalografia (EEG) frontal, é a referência mais usada à beira do leito, mas é uma saída proprietária: sua regra de combinação não é publicada e não pode ser reproduzida exatamente a partir do sinal. Modelos que tentam aproximar esse rótulo enfrentam ainda um risco metodológico

silencioso: janelas vizinhas da mesma cirurgia são quase idênticas, então uma partição aleatória entre treino e teste mede o reconhecimento de casos já vistos, não a generalização. Falta um protótipo reproduzível que estime o rótulo BIS com partições por caso ou pessoa, um controle simples baseado em medidas espectrais e avaliação entre fontes distintas de dados. Este trabalho apresenta e avalia o BrainSniffer, um protótipo para arquivos e repetição retrospectiva de gravações (replay), com esse desenho.

A pesquisa responde a duas perguntas. (i) Quanto uma rede neural convolucional unidimensional compacta (1-D CNN) aproxima o rótulo BIS em casos não usados no ajuste, comparada a um controle mais simples baseado em medidas espectrais (baseline espectral)? (ii) Esse desempenho se mantém ao trocar a fonte dos dados, do Figshare para o VitalDB, com outro equipamento, montagem e população? O objetivo geral é avaliar essa aproximação de forma reproduzível. Os objetivos específicos são: comparar a CNN ao baseline espectral no holdout Figshare; quantificar a degradação do modelo ao aplicá-lo ao VitalDB; testar se incorporar parte do VitalDB ao treino (candidato misto) reduz o erro; e caracterizar a ordenação das estimativas (probabilidade de predição P_K) e a incerteza da avaliação (bootstrap agrupado de casos).

Vale fixar o vocabulário: o modelo estima um rótulo de referência derivado do BIS, não o BIS como grandeza independente, porque o próprio BIS é a saída de um monitor sobre o mesmo sinal. A contribuição é uma cadeia com partições por grupo, controle espectral, comparação entre fontes e análise de incerteza. O escopo deste trabalho é avaliar essa cadeia, não desenvolver um dispositivo médico. A Seção 2 fundamenta o índice BIS e o problema do vazamento entre janelas; a Seção 3 descreve materiais e métodos; a Seção 4 apresenta os resultados; a Seção 5 discute limitações; e a Seção 6 conclui.

2. Fundamentação e trabalhos relacionados

2.1. O índice BIS e seus limites

O Índice Bispectral (Bispectral Index, BIS) é uma saída proprietária calculada a partir da eletroencefalografia (EEG), o registro da atividade elétrica cerebral captada no couro cabeludo; a formulação deriva da análise bispectral do EEG e de suas primeiras aplicações clínicas [Johansen and Sebel 2000]. Sua escala vai de 0, próximo de silêncio elétrico, a 100, tipicamente associado à vigília; a faixa intermediária costuma ser usada como referência de hipnose em anestesia geral, sem que isso defina um limiar clínico único ou uma fronteira nítida entre estados. O cálculo combina características no domínio do tempo e da frequência (incluindo componentes bispectrais e de supressão de surto) por uma regra de combinação não publicada; por ser fechado, o índice não pode ser reproduzido exatamente a partir do EEG, e qualquer modelo treinado contra ele herda esse limite. O BIS é indicado apenas como auxílio, em contexto e sob supervisão definidos, não como medida direta de consciência, de adequação anestésica ou de dose. Sua leitura varia com a atividade elétrica muscular (eletromiografia, EMG), o bloqueio neuromuscular, os fármacos usados e o atraso de processamento: estudos controlados documentaram queda do índice após bloqueio em voluntários acordados, resposta paradoxal à cetamina e atrasos distintos entre monitores processados [U.S. Food and Drug Administration and Covidien 2024, Connor 2022, Schuller et al. 2015, Hans et al. 2005, Pilge et al. 2006]. Ensaios com protocolos guiados pelo índice também produziram resultados que dependem do grupo de comparação e da população, o que impede extrapolar um único número para benefício

clínico universal [Myles et al. 2004, Avidan et al. 2008, Avidan et al. 2011].

2.2. Vazamento entre janelas e partição por grupo

Redes profundas já foram estudadas com alvos, canais, populações e equipamentos distintos para aproximar índices derivados de EEG [Park et al. 2020, Shi et al. 2023]. O problema é que janelas vizinhas da mesma cirurgia são parecidas entre si em amplitude, espectro e nível de BIS, porque refletem o mesmo paciente no mesmo plano anestésico. Se essas janelas forem espalhadas aleatoriamente entre treino e teste, o teste contém trechos quase idênticos aos de treino, e a métrica mede a capacidade de reconhecer um caso já visto, não de generalizar: é o vazamento (*leakage*), que infla o desempenho de forma silenciosa. Para evitar isso, este trabalho separa os dados por caso ou por pessoa (o grupo), de modo que nenhum grupo contribua simultaneamente para treino e para teste; o custo é uma estimativa mais pessimista e mais realista do uso em um caso novo. Essa unidade de separação altera a estimativa de desempenho [Sukriti et al. 2026, Saeb et al. 2017].

2.3. Corpora, transparência e relato de modelos

O conjunto “EEG and BIS raw data” reúne 24 casos anônimos com EEG frontal e valores BIS, publicado no repositório Figshare sob licença CC BY 4.0 [Ma 2017]. No mesmo corpus, um estudo anterior usou características multiescala com análise discriminante linear (Linear Discriminant Analysis, LDA); esse trabalho sustenta a descrição do corpus e das faixas, mas não é evidência de rede convolucional [Nsugbe and Connelly 2022]. Outros estudos estimaram a concentração anestésica derivada de EEG com cadeia dedicada e o índice de estado do paciente (Patient State Index, PSI) com quatro canais em 18 idosos sedados; ambos demonstram viabilidade em configurações específicas, sem comparabilidade direta com o rótulo, o canal ou a população deste trabalho [Park et al. 2020, Shi et al. 2023].

O VitalDB é um banco de sinais perioperatórios de milhares de cirurgias e inclui os canais de EEG e de BIS usados aqui (BIS/EEG1_WAV e BIS/BIS) [Lee et al. 2022, VitalDB 2026]. O conjunto aberto (vitaldb.net) exige licença CC BY-NC-SA 4.0 e acordo de uso de dados, sem redistribuição. Escala, equipamento, montagem e população diferem do Figshare; por isso, o VitalDB informa a sensibilidade à troca de fonte de dados, sem isolar a causa. As fontes também diferem no instrumento do rótulo: o corpus Figshare registra BIS a cada 5 s por sensor BIS Quatro (Aspect Medical Systems) [Ma 2017, Sukriti et al. 2026], enquanto o VitalDB registra BIS numérico de 1 s de monitores BIS Vista (Covidien/Medtronic) [VitalDB 2026, Lee et al. 2022]; versões de algoritmo e suavização não são públicas, então o rótulo não é o mesmo instrumento entre as fontes. O conjunto DOSE-I (Zenodo, CC BY 4.0) não foi incorporado à regressão porque usa uma escala clínica de sedação por observação (Modified Observer’s Assessment of Alertness/Sedation, MOAA/S) e estado de consciência, não conversíveis em BIS [Garbe et al. 2026].

Uma reimplementação aberta do algoritmo do índice não torna um regressor treinado contra o BIS equivalente a um monitor [Connor 2022]. Independência entre desenvolvimento e avaliação, descrição de grupos e análise de acordo e calibração são centrais no relato de modelos [Collins et al. 2024, Archer et al. 2021].

3. Materiais e métodos

Para reduzir a ambiguidade dos nomes usados neste artigo, a Tabela 1 resume as fontes vistas no treinamento e os conjuntos de avaliação de cada checkpoint. Os dois checkpoints respondem a perguntas diferentes. O “ativo” foi ajustado apenas no Figshare e testa o limite do modelo dentro da própria fonte e a sua queda ao mudar de corpus; o “misto” foi ajustado também com parte do VitalDB e testa se incorporar a fonte de destino reduz o erro. Como o misto viu o domínio VitalDB, o desempenho dele nessa fonte não mede transporte para uma fonte nova. “Ativo” e “misto” são apenas abreviações desses dois modelos.

Tabela 1. Definição conceitual dos dois checkpoints.

Modelo	Treinado com	Avaliado em
Modelo A – Figshare (ativo)	Figshare	Figshare (holdout por caso) e VitalDB (avaliação cruzada de dataset)
Modelo B – misto	Figshare + parte do VitalDB	Figshare (benchmark histórico) e VitalDB (holdout histórico por participante)

A Figura 1 resume esse fluxo retrospectivo, da composição do pool à avaliação sem reajuste.




Figura 1. Fluxo retrospectivo auditável do BrainSniffer.

3.1. Fontes, unidades de agrupamento e partições

Cada arquivo é uma gravação inteira, tratada como um caso; de cada caso saem janelas de 5 s, unidades de treino e de métrica. O grupo é a unidade que nunca cruza partições. O

corpus tem 59 arquivos: 44 no pool de desenvolvimento e 15 casos VitalDB congelados. Os gates de qualidade são filtros prévios ao ajuste que descartam casos ou janelas com escala problemática, valores inválidos ou sinal insuficiente; depois deles, 23 casos Figshare e dez VitalDB ficaram elegíveis: 33 casos e 55.471 janelas. Janelas medem volume disponível, não desempenho, e casos longos pesam mais. No Figshare não há `subject_id`; `case_id` evita compartilhar janelas da mesma cirurgia, mas não prova independência entre cirurgias da mesma pessoa. No VitalDB o agrupamento usa `subjectid` e reúne reoperações conhecidas [Ma 2017, Lee et al. 2022].

O checkpoint ativo foi desenvolvido só com os 23 casos Figshare elegíveis, divididos com seed 42 em 13 de treino, cinco de validação e cinco de teste. O candidato misto fixo excluiu os cinco casos do holdout Figshare histórico e usou 18 grupos Figshare mais dez VitalDB: 28 grupos e 49.948 janelas, com partição registrada de 16/6/6 grupos. O ajuste usa 12 casos Figshare e quatro participantes VitalDB (34.792 janelas); a validação, dois Figshare e quatro VitalDB (7.235); o teste interno, quatro Figshare e dois VitalDB (7.921). O treino atualiza os pesos, a validação apoia a parada e só o teste interno é lido como resultado; por isso as janelas de validação não aparecem nas tabelas. As contagens seguem o protocolo de partição; dizer “corpus de 28 grupos” não significa que os 28 entraram no ajuste.

Os mesmos cinco casos Figshare são o benchmark histórico dos dois checkpoints. Para o ativo, os 15 casos VitalDB são avaliação cruzada de dataset. Para o misto, esses 15 participantes não entraram no ajuste, mas vêm da mesma fonte do desenvolvimento e o benchmark já havia sido inspecionado antes da criação do candidato; por isso ele é descrito como holdout VitalDB histórico, por participante e após exposição ao domínio, não como validação externa confirmatória. Manter o candidato fora do painel de demonstração não restaura a independência de benchmarks já inspecionados [Collins et al. 2024, International Medical Device Regulators Forum 2025]. Os IDs ficam registrados: o holdout Figshare é `case3`, `case4`, `case5`, `case9` e `case19`; os 15 congelados do VitalDB vão de `vitaldb_case1` a `vitaldb_case17`, sem `case11` e `case15`.

3.2. Tarefa, pré-processamento e qualidade

Cada exemplo é um trecho curto de EEG: 640 amostras, isto é, uma janela de 5 segundos amostrada a 128 Hz, com passo de 5 s na construção offline. Para cada início t , o alvo corresponde a $t + \text{offset}$, arredondado ao intervalo do BIS do caso (5 s no Figshare e 1 s nos arquivos VitalDB normalizados). Como a emissão só pode ocorrer depois de completar a janela (aproximadamente em $t + 5$ s) e somar o tempo de processamento, com offset zero o sistema não faz previsão de um BIS futuro nem leitura contemporânea ao fim da janela. O pipeline mantém a banda de 0,5–45 Hz, remove a interferência da rede elétrica (notch de 50 Hz, filtro de quarta ordem) e aplica a escala de amplitude registrada, com o rótulo BIS associado ao início da janela (offset padrão 0 s). O filtro usa apenas amostras passadas e presentes (estado causal), preservado por caso e entre blocos; uma rota de fase zero existe somente para análise offline explícita. Essas escolhas seguem o protocolo do estudo, não uma definição das fontes externas [Ma 2017, Nsugbe and Connolly 2022].

O controle de qualidade do corpus exige, entre outros critérios internos, pelo menos 90% de EEG com valores finitos, lacuna inválida máxima de 2 s, qualidade global

mínima 0,35, pelo menos 80% de BIS válido e qualidade mínima 0,20 por janela; o caso Figshare 24 está em quarentena por escala incompatível. Esses limiares são heurísticas de engenharia não calibradas para risco clínico; no replay, trechos inválidos são rejeitados antes do filtro e trechos de baixa qualidade levam o modelo a se abster.

Esse controle não se aplica aos 15 casos do benchmark VitalDB histórico. Na construção offline, `make_windows` preenche valores não finitos por interpolação linear entre vizinhos válidos, repetindo o extremo nas bordas, sem limite de lacuna e podendo usar amostras futuras, mesmo com filtro causal; vetor todo inválido vira zeros. A qualidade é calculada sobre a janela bruta, e BIS inválido ou fora de $[0, 100]$ é descartado. Antes disso, a normalização ordena os dados e interpola o BIS válido para uma grade de 1 s entre o primeiro e o último ponto, sem limite de lacuna e sem máscara persistida (válido significa finito). Como os 15 arquivos contêm EEG inválido, sua avaliação offline difere da política de rejeição do replay; o preenchimento pode suavizar lacunas longas e limita a interpretação, mas política e métricas históricas foram mantidas.

3.3. Modelos e treinamento

A CNN histórica (`Conv1DDepthEstimator`) recebe a janela de 640 amostras em um canal, é treinada com perda Smooth L1 e tem saída sigmoidal escalada para $[0, 100]$. A Tabela 2 explicita a arquitetura e os parâmetros registrados no protocolo, sem carregar pesos. Recursos posteriores do treinador e arquiteturas opcionais não são atribuídos retroativamente a esses pesos.

Tabela 2. Configuração histórica dos checkpoints.

Item	Configuração registrada
Convolucionais (<code>Conv1d</code>)	Canais 1→32→64→128→128; <i>kernel</i> 7, 7, 5, 5; <i>padding</i> 3, 3, 2, 2; <i>stride</i> 1; <code>BatchNorm1d</code> + GELU
<i>Pooling</i> e cabeça	<code>MaxPool1d</code> (2) nos 3 primeiros blocos; <code>AdaptiveAvgPool1d</code> (1); <code>Linear</code> 128→64→1, GELU, <i>dropout</i> 0,20
Treino (ambos)	10 <i>epochs</i> , <i>batch</i> 128, <i>lr</i> 10^{-3} , <i>wd</i> 10^{-4} , <i>seed</i> 42; validação/teste: 20% dos grupos em cada partição
Amostragem	Misto: balanceada por grupo/fonte; ativo: não registrada
Amplitude e <i>notch</i>	<i>Clip</i> $\pm 100 \mu V$, divisor de escala $50 \mu V$, saída em $[-5, 5]$; <i>notch</i> 50 Hz, Q=30
<i>Random Forest</i>	<i>n_estimators</i> =100, <i>max_depth</i> =12, <i>min_samples_leaf</i> =2, <i>random_state</i> =42

A arquitetura compacta permite replay em CPU, mas não implica superioridade sobre redes temporais, atenção ou representações tempo-frequência [Park et al. 2020, Shi et al. 2023].

Como controle simples, o baseline espectral resume cada janela de 5 s em 14 atributos clássicos: potências absoluta e relativa das bandas delta (0,5–4 Hz), teta (4–8 Hz), alfa (8–13 Hz), beta (13–30 Hz) e gama (30–45 Hz), frequência de borda espectral em 90% (SEF90), entropia espectral, valor eficaz (RMS) e *line length*. Uma floresta aleatória (*Random Forest*, configuração na Tabela 2) é ajustada nas mesmas 15.894 janelas de treino e avaliada nas mesmas 5.523 janelas de teste do holdout Figshare, sem acesso a informação adicional e herdando a mesma proteção contra vazamento da partição agrupada

por caso. O controle responde a uma pergunta prática: se poucas medidas de espectro já alcançam erro parecido, a complexidade da CNN precisa ser justificada; se a CNN supera o controle, há indício de que a representação aprendida captura estrutura além do espectro clássico.

3.4. Métricas, incerteza e análises exploratórias

Foram calculados o erro absoluto médio (Mean Absolute Error, MAE), a raiz do erro quadrático médio (Root Mean Squared Error, RMSE), o viés e a correlação de Pearson para o rótulo contínuo, além de acurácia e macro-F1 para quatro faixas de BIS. Em leitura simples: RMSE penaliza mais os erros grandes e macro-F1 é o acerto médio entre faixas. As métricas incluem MAE e RMSE, definidos por

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad \text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (1)$$

O resultado principal agrega todas as janelas aceitas (casos longos pesam mais), em vez de tirar a média por pessoa. As faixas são $[0, 40)$, $[40, 60)$, $[60, 80)$ e $[80, 100]$, aqui lidas com rótulos curtos apenas para comunicação — profunda, geral adequada, leve/transicional e acordado — sem validar limiar clínico. Pearson quantifica associação linear e não acordo; a concordância é analisada separadamente por inclinação de calibração, limites de concordância, ICC(2,1) e fração de $|\text{erro}| \leq 10$, tudo exploratório. As quatro faixas são apenas uma apresentação interna e não constituem classes clínicas independentes [Collins et al. 2024].

A associação ordinal entre estimativa e referência é medida pela probabilidade de predição P_K (na literatura de anestesia, P_k), proposta por Smith, Dutton e Smith [Smith et al. 1996] como variante reescalada da medida $d_{y.x}$ de Kim. A pergunta que ela responde é direta: sorteados dois momentos com profundidades de referência distintas, qual é a chance de o indicador ordená-los na mesma ordem da referência? Vale 1 na ordem perfeita e 0,5 no acaso, como cara-ou-coroa.

Na prática, pares com o mesmo BIS de referência são excluídos (não informam ordenação) e pares empatados no indicador contam 0,5. Por depender só da ordem, P_K ignora erro sistemático de escala: um modelo que erra sempre por 10 pontos, mas preserva a ordem, pode ter P_K alto com MAE ruim.

O comando `evaluate-pk` reaproveita as janelas e as predições dos mesmos benchmarks, sem retreino, e grava `pk_*.json`; os intervalos vêm de reamostragem de casos ($B = 1.000$, seed 42), na mesma unidade agrupada do bootstrap [Smith et al. 1996].

O bootstrap estima a incerteza sorteando casos inteiros com reposição, juntando todas as janelas sorteadas e recalculando a métrica. Assim, respeita melhor a dependência dentro de cada caso do que sortear janelas, mas o resultado continua ponderado pela duração. Foram usadas $B = 1.000$ réplicas, seed 42 e percentis 2,5/97,5 para o intervalo de 95%. Com apenas cinco casos Figshare, o intervalo é exploratório; 1.000 réplicas não equivalem a 1.000 casos [Field and Welsh 2007, Archer et al. 2021].

Como referência externa para dimensionar esses números, adota-se um critério consolidado em estudos de acurácia do próprio monitor BIS: diferenças de

até 10 unidades entre duas medições são clinicamente aceitáveis [Dahaba et al. 2010, Shiraishi et al. 2004, Harada et al. 2021]; aqui o valor serve de escala para ler o MAE e a fração de janelas com $|erro| \leq 10$, não de alvo de desempenho.

A comparação VitalDB também foi calculada por caso, pareando `case_id` e número de janelas por caso. A análise de sensibilidade reaplicou o checkpoint ativo aos mesmos cinco casos Figshare, sem retreino, em uma grade de -20 a $+20$ s. Como a grade foi examinada após o treinamento, ela formula hipótese sobre alinhamento e não escolhe o atraso do rótulo [Pilge et al. 2006].

3.5. Replay retrospectivo e trajetória ilustrativa

Replay significa percorrer uma gravação existente, não adquirir EEG: preenche-se um buffer de 5 s e depois emite-se atualização a cada 1 s, separando valor bruto, média móvel exponencial (Exponentially Weighted Moving Average, EWMA), qualidade, instante e origem. O escopo deste trabalho é exclusivamente retrospectivo, sem conexão a EEG físico. A implementação distingue o instante de emissão do alvo histórico no início da janela.

Para visualizar o comportamento temporal, fixou-se antes da inferência o `case19` do holdout Figshare (escolha declarada antes da inferência e não guiada pelo desempenho), usando toda a gravação (4.355 s). O procedimento reutiliza `make_windows`, a configuração do checkpoint ativo e loader restrito, em CPU, sem treino. A curva bruta (sem EWMA) é posicionada no instante do alvo offline (início mais offset 0 s), em passos de 5 s; não representa disponibilidade sem atraso. Métricas e hashes ficam registrados na auditoria; a execução padrão não faz inferência nem download.

4. Resultados

4.1. Checkpoint ativo e baseline no Figshare

No holdout Figshare do checkpoint ativo, cinco casos e 5.523 janelas produziram MAE 7,03, RMSE 11,08, viés 0,79 e Pearson 0,784. A acurácia por faixa foi 0,585 e o macro-F1 0,548. O baseline espectral, na mesma partição, obteve MAE 8,86, RMSE 13,23, Pearson 0,667, acurácia 0,540 e macro-F1 0,480. No bootstrap pareado por caso, o MAE favorável à CNN é $-1,84$ (IC 95% $-2,37$ — $-0,66$) e o P_K é $+0,051$ ($0,012$ — $0,081$); os intervalos excluem zero, mas com cinco casos o teste é exploratório. A Tabela 3 resume o agregado.

Tabela 3. Holdout Figshare comum (5 casos, 5.523 janelas; MAE e RMSE em pontos BIS).

Modelo	MAE	RMSE	Pearson	Acurácia	Macro-F1
CNN ativa	7,03	11,08	0,784	0,585	0,548
Baseline espectral	8,86	13,23	0,667	0,540	0,480

A Figura 2 mostra queda inicial e elevação final em ambas as curvas, mas a CNN superestima o patamar intermediário e não reproduz várias oscilações da referência. Nas 850 janelas aceitas, MAE 8,72, RMSE 10,21, viés $+4,79$ e Pearson intra-caso 0,910:

associação alta não elimina erro sistemático; é exemplo ilustrativo, não evidência de generalização. Das 871 janelas completas, 21 foram rejeitadas por qualidade e 56 posições ficaram sem previsão (NaN).




Figura 2. Trajetória offline do Figshare case19: referência e predição bruta (topo) e erro por janela (base).

4.2. Comparação dos checkpoints nos benchmarks históricos

O candidato misto apresentou MAE 6,69, RMSE 10,67, viés 2,12, Pearson 0,818 e macro-F1 0,574 no holdout Figshare. Nos 15 participantes e 38.730 janelas do holdout VitalDB histórico, obteve 8,60, 11,74, $-1,01$, 0,688 e 0,486. O ativo obteve, respectivamente, 7,03/11,08/0,79/0,784/0,548 no Figshare e 12,43/18,80/1,40/0,024/0,398 no VitalDB. A Tabela 4 organiza esses agregados. Três dos quatro MAE ficam abaixo de 10 unidades BIS (6,69; 7,03 e 8,60) — inclusive o do misto nessa fonte, embora ele tenha visto participantes dela no ajuste —; o ativo no VitalDB (12,43) ultrapassa essa escala, compatível com a perda de ordenação medida pelo P_K . Como referência no mesmo corpus, a entropia amostral com floresta aleatória reportou MAE $5,22 \pm 2,12$ [Liu et al. 2018] e um modelo contemporâneo, $6,03 \pm 0,38$ sob validação agrupada com suavização [Sukriti et al. 2026]; com protocolos distintos, o MAE obtido (6,69–7,03) fica na mesma ordem de grandeza, sem ranking.

Tabela 4. Comparação retrospectiva nos benchmarks históricos; 5 casos no benchmark Figshare e 15 no VitalDB; MAE em pontos BIS; IC 95% por bootstrap agrupado por caso; o RF espectral viu apenas o Figshare.

Benchmark	Modelo (fontes vistas)	MAE (IC 95%)	Pearson (IC 95%)	P_K (IC 95%)
Figshare	ativo (Figshare)	7,03 (6,38–8,24)	0,784 (0,703–0,881)	0,773 (0,679–0,828)
Figshare	misto (Figshare+VitalDB)	6,69 (5,65–8,53)	0,818 (0,751–0,890)	0,774 (0,676–0,835)
VitalDB	ativo (Figshare)	12,43 (11,05–14,45)	0,024 ($-0,126$ – $0,193$)	0,515 (0,434–0,581)
VitalDB	misto (Figshare+VitalDB)	8,60 (7,57–9,95)	0,688 (0,606–0,752)	0,672 (0,591–0,737)
VitalDB	RF espectral	13,62 (11,98–16,01)	$-0,036$ ($-0,162$ – $0,111$)	0,502 (0,447–0,551)

O baseline espectral também foi reavaliado nos 15 casos VitalDB, com o mesmo ajuste e protocolo: MAE 13,62 (11,98–16,01), Pearson $-0,04$ e P_K 0,502, no nível do acaso, e a CNN ativa ainda o supera (MAE $-1,19$; IC $-2,13$ – $-0,34$); o colapso no transporte não é específico da CNN. No bootstrap pareado por caso (= ativo – misto), o misto melhora o VitalDB (MAE $+3,83$, IC $2,95$ – $4,94$; P_K $-0,157$, IC $-0,216$ – $-0,083$; 14/15 casos, $p < 0,001$), enquanto no Figshare MAE e P_K não sustentam ganho (MAE $0,34$, IC $-0,28$ – $0,81$; P_K IC $-0,013$ – $0,007$).

No VitalDB, o MAE do candidato caiu em 14 dos 15 casos pareados; no `vitaldb_case16`, subiu cerca de 0,67 ponto BIS. Na Figura 3c, cada linha é um caso, ordenado pela diferença misto menos ativo; linhas à esquerda indicam menor MAE do misto. A leitura é pareada de propósito, para que um grupo de casos longos não domine a comparação, e revela a heterogeneidade: o ganho não é uniforme, e 14 acertos contra 1 piora convivem com margens pequenas. Como os agregados são calculados por janela, a média pode não corresponder à de um caso típico; essa comparação descreve adaptação após exposição ao VitalDB, não transporte para nova fonte.




Figura 3. Agregados por janela e MAE pareado por caso; em (c), cada ponto é um caso e linhas à esquerda indicam menor MAE do misto.

4.3. Probabilidade de predição P_K

A associação ordinal é medida pela probabilidade de predição P_K de Smith, Dutton e Smith [Smith et al. 1996]: com que frequência o indicador ordena corretamente duas profundidades observadas distintas? A Tabela 4 e a Figura 4 trazem os valores e os intervalos de 95%. No Figshare (Figura 4), o ativo obtém P_K 0,773 (0,679–0,828) e o misto 0,774 (0,676–0,835). O achado desta seção está na leitura conjunta com a Tabela 4: o misto reduz o MAE (7,03 para 6,69) e eleva o Pearson (0,784 para 0,818), mas mantém P_K

praticamente idêntico (0,773 para 0,774): não há evidência de mudança na ordenação, e as diferenças são pequenas frente à incerteza dos intervalos. No VitalDB, o ativo tem P_K 0,515 (0,434–0,581), indistinguível do acaso, e o misto 0,672 (0,591–0,737). Como P_K ignora erro sistemático, ele separa duas leituras que o MAE confunde [Smith et al. 1996]. Por caso, o P_K do ativo no VitalDB varia de 0,39 a 0,74 (mediana 0,48) e o do misto, de 0,48 a 0,81 (mediana 0,67); no Figshare, as medianas são 0,80 e 0,81.




Figura 4. Probabilidade de predição P_K , ativo vs. misto.

4.4. Bootstrap agrupado e sensibilidade ao offset

A Tabela 4 reúne os intervalos de 95% do bootstrap agrupado por caso; na Figura 5, os marcadores são as métricas observadas e as barras, as réplicas, cujas médias não substituem esses pontos.




Figura 5. Bootstrap agrupado por caso.

Na grade de offset, o ativo variou de MAE 7,22/Pearson 0,766 em -20 s para 7,03/0,784 em 0 s e 6,76/0,799 em $+20$ s. Um offset positivo associa a janela EEG a um BIS posterior. A Figura 6 mostra essa grade. A tendência foi observada pós-hoc, sem retreino, e não identifica causalmente atraso do monitor nem autoriza mudar o offset padrão. Contexto sobre atraso de índices processados em [Pilge et al. 2006].




Figura 6. Sensibilidade ao offset do rótulo; eixos ampliados (variação total $\leq 0,5$ ponto de MAE e 0,04 de Pearson).

4.5. Painéis de apoio: corpus, qualidade e projeção

As duas figuras seguintes detalham o que as tabelas e os agregados comprimem. A primeira caracteriza o corpus que alimenta o protótipo; a segunda documenta o comportamento do treinamento e uma projeção declarada de planejamento. Os painéis de composição e de qualidade da Figura 7 e o histórico da Figura 8a documentam o corpus e o treinamento; somente a projeção da Figura 8b é cenário ancorado no MAE 7,03 medido, não curva observada.

A Figura 7a separa os 59 casos em três estados mutuamente exclusivos por fonte: 33 elegíveis de desenvolvimento (23 Figshare e 10 VitalDB), 11 em quarentena de desenvolvimento (1 Figshare e 10 VitalDB, como o Figshare 24, de escala incompatível) e 15 do benchmark histórico congelado, todos do VitalDB e fora do pool; 9 desses 15 reprovam nos gates internos, mas permanecem no benchmark por desenho. A leitura é de composição, não de desempenho: barras maiores não indicam melhor qualidade. A Figura 7b cruza a fração de amostras finitas com a fração de janelas aceitas e mostra por que os gates não são redundantes; a linha tracejada marca o gate de 90%, e pontos à sua esquerda foram retidos independentemente do eixo vertical.




Figura 7. Composição e qualidade do corpus.

A Figura 8a acompanha o treino: a perda cai de 6,2 para 4,7 em dez épocas, o MAE de validação oscila entre 5,49 e 6,38, e o checkpoint salvo é o de melhor validação (época 3). O painel (b) troca a projeção teórica por calibração medida: a inclinação predito-referência cai de 0,72 (0,61–0,80) no Figshare ativo para 0,02 (–0,08–0,13) no VitalDB ativo, com ICC(2,1) 0,02 e 57,2% das janelas com $|erro| \leq 10$ pontos BIS; o misto recupera 0,55 (0,46–0,64), ICC 0,67 e 68,9%, ainda abaixo do Figshare (misto: 0,82, ICC 0,81 e 80,6%).




Figura 8. Treinamento do checkpoint ativo e calibração por braço (inclinação predito-referência com IC 95% por bootstrap de casos).

5. Discussão e limitações

A degradação do ativo do Figshare para o VitalDB é evidência interna de sensibilidade à troca de fonte, não prova de qual diferença (equipamento, ganho, montagem, população ou BIS) a causou. A redução de erro do misto é compatível com adaptação após incorporar participantes VitalDB; como o benchmark é da mesma fonte e já havia sido observado, ele gera hipótese para uma nova coorte travada, não generalização externa [Lee et al. 2022, Collins et al. 2024, International Medical Device Regulators Forum 2025].

A melhora em 14/15 casos convive com piora no caso 16, e os agregados por janela privilegiam cirurgias longas: no VitalDB, a mediana do MAE por caso é 12,96 no ativo e 9,60 no misto, contra 12,43 e 8,60 agregados; Pearson pode aumentar mesmo com viés relevante. A referência de 10 unidades é escala de concordância entre medições do monitor, não limiar para MAE [Harada et al. 2021]. As análises de concordância e calibração são exploratórias; validação com mais casos segue necessária [Collins et al. 2024, Archer et al. 2021].

O bootstrap cobre só a variabilidade de reamostrar os casos disponíveis sob o algoritmo escolhido; não cobre incerteza de treinamento, seleção de checkpoint, hiperparâmetros, mudança de centro ou erro do rótulo. O pequeno n Figshare e o reaproveitamento do benchmark VitalDB impedem leitura confirmatória e elevam o risco de viés do relato [Field and Welsh 2007, Archer et al. 2021, Moons et al. 2025]; a avaliação é pré-clínica [Vasey et al. 2022].

O alvo é a saída BIS, sensível a EMG, bloqueio neuromuscular, cetamina e atrasos; baixo erro contra o monitor não equivale a medir consciência ou efeito farmacológico [Schuller et al. 2015, Hans et al. 2005, Pilge et al. 2006]. O modelo usa a banda de 0,5–45 Hz, que inclui gama frontal sensível a EMG, e o *notch* fixo em 50 Hz não corresponde

obrigatoriamente à rede de cada centro (o VitalDB é de Seul); nenhuma dessas sensibilidade foi medida. Faixas e limiares de qualidade são heurísticas de engenharia, sem validação clínica; DOSE-I permanece tarefa separada para MOAA/S [Garbe et al. 2026].

A leitura ordinal separa dois diagnósticos: no VitalDB o ativo tem P_K 0,515, quase acaso; no Figshare alcança 0,773, e o misto eleva o Pearson sem mover P_K , o que não caracteriza ganho de ordenação. Como a escala é o BIS de referência, não um desfecho de resposta ao estímulo, esses valores não substituem validação clínica [Smith et al. 1996].

Em engenharia, a cadeia registra hashes, partições, pré-processamento e replay; a política de amostragem do checkpoint ativo não foi registrada, limitação histórica. A trajetória individual mostra erros que os agregados ocultam, mas não substitui a análise entre casos; investigar lacunas e concordância são extensões possíveis [Collins et al. 2024].

6. Conclusão

O BrainSniffer entrega um protótipo aberto e reproduzível para estimar uma referência BIS a partir de EEG frontal. Como sintetizado na Seção 4, o ativo superou o baseline espectral internamente, mas perdeu associação no VitalDB; o misto reduziu o erro após exposição a esse domínio, sem independência confirmatória. Os resultados são retrospectivos, exploratórios e limitados pelo rótulo, pelos casos, pelo reuso dos benchmarks e pela imputação offline.

A contribuição defensável é uma base auditável para formular e testar hipóteses, não um sistema clínico. O software não mede consciência, não prescreve dose, não controla bomba e não deve acionar alarme ou conduta; uma futura alegação de generalização exigiria avaliação independente [Collins et al. 2024].

Disponibilidade

O código-fonte e os relatórios deste artigo estão em <https://github.com/Bruno-BRG/brainsniffer>, sob licença MIT, no commit 114f3d7 (ou posterior); os dados não são redistribuídos (Figshare CC BY 4.0; VitalDB sob seus termos de uso), e relatórios e sidecars registram hashes para auditoria.

Referências

- Archer, L., Snell, K. I. E., Ensor, J., Hudda, M. T., Collins, G. S., and Riley, R. D. (2021). Minimum sample size for external validation of a clinical prediction model with a continuous outcome. *Statistics in Medicine*, 40(1):133–146. DOI: 10.1002/sim.8766.
- Avidan, M. S., Jacobsohn, E., Glick, D., et al. (2011). Prevention of intraoperative awareness in a high-risk surgical population. *New England Journal of Medicine*, 365:591–600. DOI: 10.1056/NEJMoa1100403.
- Avidan, M. S., Zhang, L., Burnside, B. A., et al. (2008). Anesthesia awareness and the bispectral index. *New England Journal of Medicine*, 358:1097–1108. DOI: 10.1056/NEJMoa0707361.
- Collins, G. S., Moons, K. G. M., Dhiman, P., et al. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385:e078378. DOI: 10.1136/bmj-2023-078378.
- Connor, C. W. (2022). Open reimplementations of the BIS algorithms for depth of anesthesia. *Anesthesia & Analgesia*, 135(4):855–864. DOI: 10.1213/ANE.00000000000006119.
- Dahaba, A. A., Xue, J. X., Zhao, G. G., Liu, Q. H., et al. (2010). BIS-vista occipital montage in patients undergoing neurosurgical procedures during propofol-remifentanyl anesthesia. *Anesthesiology*, 112(3):645–651. DOI: 10.1097/ALN.0b013e3181cf4111.

- Field, C. A. and Welsh, A. H. (2007). Bootstrapping clustered data. *Journal of the Royal Statistical Society: Series B*, 69(3):369–390. DOI: 10.1111/j.1467-9868.2007.00593.x.
- Garbe, J., Nguyen, Q. V., Kantelhardt, J. W., Dünninghaus, F., Erffmeier, K., Seeliger, K., and Schmid, T. (2026). DOSE-I: A multimodal biosignal dataset of procedural sedation for endoscopy. Dataset, v1, 171 gravações; licença CC BY 4.0 com acordo de uso; escala MOAA/S.
- Hans, P., Dewandre, P.-Y., Brichant, J. F., and Bonhomme, V. (2005). Comparative effects of ketamine on bispectral index and spectral entropy of the electroencephalogram under sevoflurane anaesthesia. *British Journal of Anaesthesia*, 94(3):336–340. DOI: 10.1093/bja/aei047.
- Harada, H., Muta, S., Kakuma, T., et al. (2021). Accuracy of BIS monitoring using a novel interface device connecting conventional needle-electrodes and BIS sensors during frontal neurosurgical procedures. *PLoS ONE*, 16(10):e0258647. DOI: 10.1371/journal.pone.0258647.
- International Medical Device Regulators Forum (2025). Good machine learning practice for medical device development: Guiding principles. IMDRF/AIML WG/N88 FINAL:2025. Final de 29 jan. 2025. Portal: <https://www.imdrf.org>.
- Johansen, J. W. and Sebel, P. S. (2000). Development and clinical application of electroencephalographic bispectrum monitoring. *Anesthesiology*, 93(5):1336–1344.
- Lee, H.-C., Park, Y., Yoon, S. B., Yang, S. M., Park, D., and Jung, C.-W. (2022). VitalDB, a high-fidelity multi-parameter vital signs database in surgical patients. *Scientific Data*, 9:279. DOI: 10.1038/s41597-022-01411-5.
- Liu, Q., Ma, L., Fan, S.-Z., Abbod, M. F., and Shieh, J.-S. (2018). Sample entropy analysis for the estimating depth of anaesthesia through human EEG signal at different levels of unconsciousness during surgeries. *PeerJ*, 6:e4817.
- Ma, L. (2017). EEG and BIS raw data. Dataset, v1, 24 arquivos; licença CC BY 4.0.
- Moons, K. G. M. et al. (2025). PROBAST+AI: an updated quality, risk of bias, and applicability assessment tool for prediction models using regression or artificial intelligence methods. *BMJ*, 388:e082505. DOI: 10.1136/bmj-2024-082505.
- Myles, P. S., Leslie, K., McNeil, J., Forbes, A., and Chan, M. T. V. (2004). Bispectral index monitoring to prevent awareness during anaesthesia: the B-Aware randomised controlled trial. *The Lancet*, 363:1757–1763. DOI: 10.1016/S0140-6736(04)16300-9.
- Nsugbe, E. and Connelly, S. (2022). Multiscale depth of anaesthesia prediction for surgery using frontal cortex electroencephalography. *Healthcare Technology Letters*, 9:43–53. DOI: 10.1049/htl2.12025.
- Park, Y., Han, S.-H., Byun, W., Kim, J.-H., Lee, H.-C., and Kim, S.-J. (2020). A real-time depth of anesthesia monitoring system based on deep neural network with large EDO tolerant EEG analog front-end. *IEEE Transactions on Biomedical Circuits and Systems*, 14:825–837. DOI: 10.1109/TB-CAS.2020.2998172.
- Pilge, S., Zanner, R., Schneider, G., Blum, J., Kreuzer, M., and Kochs, E. F. (2006). Time delay of index calculation: analysis of cerebral state, bispectral, and Narcotrend indices. *Anesthesiology*, 104(3):488–494. DOI: 10.1097/00000542-200603000-00016.
- Saeb, S., Lonini, L., Jayaraman, A., Mohr, D. C., and Kording, K. P. (2017). The need to approximate the use-case in clinical machine learning. *GigaScience*, 6. DOI: 10.1093/gigascience/gix019.
- Schuller, P. J., Newell, S., Strickland, P. A., and Barry, J. J. (2015). Response of bispectral index to neuromuscular block in awake volunteers. *British Journal of Anaesthesia*, 115(Suppl 1):i95–i103. DOI: 10.1093/bja/aev072.
- Shi, M., Huang, Z., Xiao, G., Xu, B., Ren, Q., and Zhao, H. (2023). Estimating the depth of anesthesia from EEG signals based on a deep residual shrinkage network. *Sensors*, 23(2):1008. DOI: 10.3390/s23021008.
- Shiraishi, T., Uchino, H., Sagara, T., and Ishii, N. (2004). A comparison of frontal and occipital bispectral index values obtained during neurosurgical procedures. *Anesthesia & Analgesia*, 98(6):1773–1775. DOI: 10.1213/01.ANE.0000121344.69058.09.
- Smith, W. D., Dutton, R. C., and Smith, N. T. (1996). Measuring the performance of anesthetic depth indicators. *Anesthesiology*, 84(1):38–51. DOI: 10.1097/00000542-199601000-00005.
- Sukriti, Kriplani, C., Kumar, S., and Singh, A. (2026). Predicting depth of anaesthesia from single-channel EEG using a deep TCN-BiLSTM-attention model with EWMA. *Scientific Reports*, 16:25470. DOI: 10.1038/s41598-026-54608-8.

- U.S. Food and Drug Administration and Covidien (2024). BIS Advance Monitoring System: K230693, Indications for Use. 510(k) premarket notification. URL: https://www.accessdata.fda.gov/cdrh_docs/pdf23/K230693.pdf.
- Vasey, B., Nagendran, M., Campbell, B., Clifton, D. A., et al. (2022). Reporting guideline for the early-stage clinical evaluation of decision support systems driven by artificial intelligence: DECIDE-AI. *Nature Medicine*, 28:924–933. DOI: 10.1038/s41591-022-01772-9.
- VitalDB (2026). Open dataset: overview and track list. <https://vitaldb.net/dataset/>. Licença CC BY-NC-SA 4.0 e acordo de uso de dados.